

R을 활용한 산업인력개발통계

Su Jung Choi (Seoul National University)

2026-09-20

차례

1	Introduction	1
1.1	R을 왜 사용해야할까?	1
1.2	이 책의 구성	3
1.3	배우지 않는 내용들	4
1.4	당부의 말	4
2	R 자료 구조의 이해	7
2.1	명령어의 구조와 자료 입력	7
2.2	R에서 쓰이는 자료의 유형	8
2.3	R에서 쓰이는 자료의 구조	9
2.4	factor 변수	15
2.5	NA와 NULL	17
2.6	R 내장함수를 활용한 기술통계량 산출	18
3	데이터 전처리	23
3.1	들어가며	23
3.2	dplyr 패키지의 이해	27
3.3	dplyr의 주요 기능	29
3.4	데이터 결합하기	38
3.5	데이터를 타이디하게 만들기 : pivot_longer와 pivot_wider	45
3.6	패널데이터를 활용한 데이터 전처리 실습	50
4	데이터 시각화	65
4.1	들어가며	65
4.2	ggplot2의 설치 및 소개	65

4.3	변인이 1개인 graph	67
4.4	변인이 2개인 graph	82
4.5	Miscellaneous items	96
5	추론통계와 가설검정	99
5.1	추론통계와 확률	100
5.2	대표적인 확률분포	105
5.3	중심극한정리	110
5.4	추정과 가설검정	117
6	t검정과 ANOVA	121
6.1	모집단 평균에 관한 가설검정	121
6.2	t 검정 (t-test)	122
6.3	t 검정 (t-test)의 개념 및 가정	122
6.4	분산분석 (ANOVA)	138
7	분산, 공분산 그리고 상관	151
7.1	두 변수의 관계	151
7.2	분산과 공분산	152
7.3	상관계수	161
7.4	편상관계수	166
8	직관으로 이해하는 회귀분석	167
8.1	산업인력개발에서의 회귀분석	168
8.2	회귀분석과 1차 함수	168
8.3	회귀분석과 2차함수	178
8.4	회귀분석에서 더미변수 활용	186
8.5	회귀식으로 이해하는 조절효과	194
8.6	회귀식으로 이해하는 매개효과	199
9	회귀분석 심화 및 기본가정	201
9.1	simple regression analysis	202
9.2	multiple regression analysis	204
10	regression	207
10.1	simple regression analysis	208
10.2	multiple regression analysis	210

제 1 장

Introduction

이 책을 쓰게 된 계기는 간단하다. 약 8년간 서울대학교 산업인력개발 전공의 학부와 대학원 통계 수업을 진행하면서 인력개발 분야의 통계 서적의 필요성을 실감했기 때문이다. 기존의 서적들을 각기 조합하여 수업을 진행하다보니, 학생들은 물론 교수자도 힘들었던 점들이 많았다. 수많은 서적들이 제각기의 시각으로 통계 관련 이론과 실무적인 내용들을 잘 풀어내고 있지만, 우리 분야에 적합한 책을 찾기는 어려웠다. 두번째 이유는 코로나로 인해 대부분의 출장과 회의가 온라인으로 이뤄지면서, 이동시간이 절약되어 집필에 필요한 시간이 확보되었다. 물론 코로나 이후에도 계속 수정완화였고, 아직도 현재진행중이다.

이 책은 일종의 조각 모음으로 집필이 진행되었다. 매년 수업을 진행하며 조각 조각 만들어냈던 자료들을 통합함으로써 하나의 스토리를 만들어내고자 노력했다.

1.1 R을 왜 사용해야할까?

책의 제목에서 알 수 있듯이 기본이 되는 통계 패키지는 R을 사용하였다. 사실 교육학 분야의 많은 오래된 학자들은 SPSS가 익숙하고, 나 역시 첫 통계 공부는 SPSS로 시작했다. 관행은 계기가 없으면 바뀌기 어렵기 때문에, 학교에 부임한 이후에도 수년간은 SPSS를 이용한 수업을 진행하기도 했다. 하지만 다음과 같은 네 가지 이유로 SPSS는 나의 컴퓨터에서 사라지게 되었다.

- 첫째, SPSS는 비싼 라이선스를 사용해야 하기 때문에 개인 연구자에 적합하지 않다. 서울대 역시 SPSS 제조사와 지리한 라이선스 가격 협상을 이어가고

있는 실정이다. 하물며 개인이 라이선스에 지갑을 열어야 하는 경우 SPSS는 좋은 선택이 아니다.

- 둘째, SPSS가 갖고 있는 직관적인 인터페이스와 간단한 분석방법은 종종 초보 연구자의 오류를 촉진한다. 모든 종류의 프로그램이 그렇듯이 이들은 분석의 적합성을 검토해주지 않는다. 자판기에 동전을 넣으면 음료수가 나오듯이 데이터를 입력하면 분석결과가 나오지만, 그것이 잘못된 선택인지 알수가 없다. 반면에 R 등의 스크립트 기반의 통계패키지는 적어도 내가 무엇을 분석하려고 하는지에 대한 기본적인 이해를 필요로 한다.
- 셋째, 복잡한 분석(이라 쓰고 삽질이라 읽는다)을 실시할 때 click to click 방식의 통계패키지는 삽질의 시간을 더 길게 만든다. 보통 우리가 마주하는 데이터는 다양한 변형(manipulation)을 요구하는데, 이때 (1) 어떠한 형태로 데이터를 변형할 것인지, (2) 변형을 위한 각 단계는 어떻게 구성해야 하는지에 대한 사전정보를 알고 있는 경우는 드물다. R과 같이 스크립트를 기반으로 데이터를 핸들링하고 분석할 수 있는 경우는 일주일간 작업한 내용의 오류를 발견했을 때, 그간 작성해놓은 코드에 일부만 수정하고 실행함으로써 간단히 오류를 고칠 수 있다. SPSS 같은 프로그램들은 데이터 변형 및 분석의 복원이 불가능하다는 점을 고려해보면 어마어마한 장점이 아닐 수 있다. 보통 고통스러운 오류 개선 작업을 10시간정도 하게 되면, R을 시작하는데 필요한 약간의 허들은 쉽게 느껴질 것이다.
- 넷째, R은 빠르게 변화하는 최신 분석기법들을 빠르게 설치, 활용할 수 있다. 종종 R을 스마트폰에 비유하곤하는데, ios나 android와 같은 플랫폼에 여러가지 어플을 설치하는 방식을 생각하면 간단하다. 플랫폼의 업데이트는 느리고 무겁지만, 각각의 어플은 가볍고, 빠르며, 쉽게 적용이 가능하다. 결국 확장성의 장점이 R이 갖고 있는 가장 큰 장점이라고 볼 수 있다.

R의 기본적인 설치, 구조 이해, 분석의 기초와 함께, 이 책에서는 통계학의 기본적인 내용들도 알기 쉽게 설명하고자 노력했다. 두 내용 모두 방대하기 때문에 보통 하나의 책에서 통계패키지의 분석 테크닉과 통계학 이론을 한꺼 번에 다루지는 않는다. 하지만 수년간 학생들을 가르치다보니 두 내용을 연결하는 책이 절실하게 필요했다. 두마리의 토끼를 과연 잡았을지는 모르겠지만, 부디 이 책이 의도한 바를 달성했기를 바란다.

1.2 이 책의 구성

이 책은 크게 2부로 구성된다.

1부. R의 기초 이해

1부는 R이라는 데이터 분석 도구tool에 대해 이해하도록 한다. 앞서 언급했던것 처럼 R은 특히 복잡한 데이터 전처리에서 진가를 발휘한다. 우리가 접하는 데이터들은 전처리가 거의 필요없는 유형(내 연구 가설에 딱 맞는 형태로 직접 수집한 데이터, 예를 들어 학위논문 등을 위해 직접 수집해서 코딩까지한 자료)부터 매우 복잡한 전처리를 해야만 분석이 가능한 유형(보통 행정 및 관리를 위해 조직에 축적된 chunky한 데이터들)까지 다양하다. 1부에서는 이러한 데이터 전처리를 용이하게 하기 위해 필요한 다양한 기법들에 대해 소개할 예정이다. 1부에서 다룰 내용들은 다음과 같다.

- 1장. R 자료 구조의 이해
- 2장. R을 활용한 데이터 전처리 (dplyr)
- 3장. R을 활용한 데이터 시각화 (ggplot2)

2부. R을 활용한 기초 다변량 분석

2부는 연구를 위해 활용되는 다양한 다변량 분석 기법의 이론에 대해 소개한다. 1부는 R이라는 분석도구를 사용하는 테크닉에 대한 소개일 뿐이다. 다시 말해 못을 박는 망치 사용법일뿐이지 어디에다 못을 박아야 하는지, 몇개를 박아야 하는지, 얼마나 깊숙히 박아야 하는지에 대한 답을 주지는 못한다. 2부에서는 추론통계와 가설 검정에 대한 이해를 바탕으로 t검정과 ANOVA, 상관분석, 회귀분석, 로지스틱, 매개분석과 조절분석에 대해 다룰 예정이다. 이 밖에 더 많은 다변량 분석기법들이 존재하지만, 산업인력개발 분야에서 가장 빈번하게 다루는 기초적인 분석기법들을 선택하였다. 각 장별로 개념이해, 결과 해석, R을 활용한 분석코드 순서로 기술되었다.

- 5장. 추론통계와 가설검정
- 6장. t 검정과 ANOVA
- 7장. 분산, 공분산, 그리고 상관
- 8장. 직관으로 이해하는 회귀분석
- 9장. 회귀분석 심화 및 기본가정
- 10장. 로지스틱 회귀분석

1.3 배우지 않는 내용들

이 책에서 다루지 않는 내용은 그야말로 산더미 같이 많이 있다. 정확히 숫자로 표현 할수는 없겠지만 한 90%정도는 책에 담지 못한 내용들일 것이다!! 아마 10년 정도 후에는 99% 정도로 늘어날지 모르겠다. 하지만 이 책에 담긴 내용들을 충분히 숙지하였다면 나머지 90%의 내용은 여러분 스스로 학습할 수 있는 좋은 기본기를 갖췄다고 생각해도 무방하다. 개인적으로는 이 책이 (1) 여러분들의 통계포비아를 없애주고, (2) 새로운 개념, 기법에 대한 자기주도학습이 가능하도록 하는 일종의 밑바탕으로 기능했으면 하는 바람이다.

좀 더 구체적으로 이 책에서 제외된 내용은 다음과 같다. 우선 1부에서 R을 활용한 데이터 전처리의 맛보기만 기술하였기 때문에, 이른바 빅데이터라고 불리는 청키한 데이터를 다루는 기법까지 설명하지는 못했다. 특히 다양한 DB 등에서 데이터를 끌어와 분석에 용이한 형태로 만드는 것은 좀더 심화된 기법이 필요하다. 이와 관련해서는 관련한 기존 서적들을 충분히 참조했으면 하는 바람이다(물론 1부를 모두 이해한 후에)

2부에서도 다루지 못한 내용들이 많다. 특히 15년 전부터 사회과학분야에 거대한 유행으로 자리잡은 구조방정식structural equation modeling, 다층선형모형hierarchical linear modeling 등 굵직한 기법들이 모두 빠져있다. 이러한 분석 기법들은 각각의 대표적인 기본서들이 있으므로, 이를 참조하였으면 하는 바람이다. 이들 역시 일종의 회귀분석의 변형이기 때문에 기초를 탄탄하게 쌓았다면 이해를 확장하는데 어려움이 없을 것이라 생각한다. 이와 더불어 다양한 longitudinal data를 다루는 분석기법들도 생략되어 있다.

이밖에도 저자의 또 다른 강의인 “직업연구”나 “산업인력개발 노동시장분석론”에서 다루었던 다양한 통계기법에 대한 내용들도 빠져있다. 아마도 빠른 시간 안에 위의 두 강의에서 다루었던 내용을 별도의 책으로 출간할 수 있지 않을까 기대한다(기대만 하고 있다....)

1.4 당부의 말

마지막으로 우연히 이 책을 접한 독자들에게 하고 싶은 말은 책의 내용을 이해하는 것을 포기 하지 말라는 것이다. 고등학교 때 '수학의 정석'의 첫 챕터인 집합 부분만 까맣게 손때가 묻어있던것을 기억할 것이다. 많은 사람들이 2부의 첫 챕터에서 흥미를 잃겠지만, 포기하지 않고 여러번 완독을 한다면 분명 많은 도움이 될 것이다.

설사 이해하지 못하는 내용이 있다하더라도 여러번 읽고, 손으로 문제를 풀어보는 버릇을 들이면 더 빠르게 이해할 수 있다.

또 간단한 소논문 등을 작성해보고 다시 책을 읽어보면 이해가 안되었던 부분들이 새롭게 보이는 날들이 있을 것이라 믿어 의심치 않는다. 또한 이 책이 정답이 아니므로, 설명이 부족한 부분들이 있다면 구글이나 유튜브 등에 키워드 검색을 통해 추가적인 설명자료와 강의등의 도움을 받길 바란다.

제 2 장

R 자료 구조의 이해

2.1 명령어의 구조와 자료 입력

R의 명령어는 일종의 언어language이기 때문에 나름의 문법을 갖고 있다. 처음 R의 언어를 접하는 독자들은 다소 어렵게 느껴지기때문에, 손에 익을때까지 자주 연습해볼 필요가 있다. 텅 비어있는 스크립트 창에 a라는 객체를 만드는 작업을 해보자. 이때 객체object는 다양한 형태의 자료를 담고있는 바구니라고 생각하자. a라는 객체에 2라는 데이터 하나를 삽입해보자. 명령어 구조를 보면 객체는 왼쪽, 넣을 데이터는 오른쪽에 위치시킨다. 중간의 화살표의 방향을 보면 직관적으로 이해가 가능하다. 스크립트 창에 있는 명령어를 실행시키기 위해서는 해당 명령어를 드래그 한후 “run” 버튼을 누르거나 Ctrl+Enter를 누르면 된다. 명령어로 실행시키고 싶지 않은 comment나 각주는 문장 앞에 #을 삽입하면 된다. 회색 박스안에는 스크립트창, 흰색 박스 안에는 콘솔에 나타나는 output을 보여준다. 한 가지 주의해야 할 부분은 R의 실행 구조는 누적이 아니라 덮어쓰기 방식이라는 것이다. 객체 a에 다시 3이라는 데이터를 넣는다고 정의하면, 2의 데이터는 사라지게 된다. 만일 두 개 이상의 데이터를 하나의 객체에 삽입하고 싶다면 c(연결concatenate의 약자)라는 명령어를 사용하자.

```
a<-2 # a라는 객체에 2를 삽입
a #a 객체를 출력
## [1] 2
a<-3
```

```
a
## [1] 3
a<-c(3,4,5)
a
## [1] 3 4 5
```

이상의 설명을 요약하면 R의 언어는 다음과 같은 규칙이 있다

- 화살표의 방향은 데이터 또는 함수로 객체를 정의하는 것을 뜻한다(객체 <- 데이터 또는 함수)
- 문장 앞에 #을 붙이면 명령어로 실행되지 않는다(comment, 각주 등)
- 객체의 이름을 실행시키면, 객체에 담겨있는 데이터가 출력된다
- R의 명령어 실행은 덮어쓰기 방식이다.
- 다수의 데이터를 연결하기 위해서는 c를 사용한다(c(1,2,3) 등)

2.2 R에서 쓰이는 자료의 유형

본격적으로 R의 자료구조를 살펴보기 전에 R에서 쓰이는 자료의 유형에 대해서 알아보자. 연구에서 쓰이는 자료들은 다양한 유형이 있다. 키(168cm, 170cm)와 같은 수치형 자료나, 이름(홍길동, 김영희)과 같은 문자형 자료 등이 여기에 포함된다. 자료의 유형이 중요한 이유는 특정 작업은 특정한 자료의 유형에만 작동하기 때문이다. 예를 들어 덧셈, 뺄셈 등의 연산 작업은 수치형 자료에서만 작동한다. 글자의 앞 한자리만 삭제하는 것은 문자형 자료에만 작동한다. 또한 숫자를 문자형으로 인식한다면 연산 작업은 작동을 하지 않을 것이다. R에서 쓰이는 자료의 유형은 다음과 같이 요약할 수 있다.

- 수치형 값(numeric value) : 소수점을 포함하는 숫자값 (1, 2.2, pi)
- 문자형 값(character value) : 문자로 표현된 값, 큰따옴표로 표현 ("a", "work", "1")
- 복소수형 값(complex value) : 실수와 허수(i)의 합으로 표현한 값(1+4i)
- 논리형 값(logical value) : 참(true) 혹은 거짓(false)으로 출력되는 논리형 값
- 정수형 값(integer value) : 수치형 자료의 특수한 형태, 정수로 표현되는 숫자 (1, 2, 10)

2.3 R에서 쓰이는 자료의 구조

이제 자료구조(data structure)에 대해 알아보자. 자료구조란 간단히 이야기해서 자료가 갖고 있는 골격, 형태를 의미한다. 사회과학에서 쓰이는 상당수의 자료는 행과 열의 구조를 갖고있는 2차원의 매트릭스 형태를 띤다. 간단히 이야기해서 엑셀의 데이터시트를 생각해보자. 행(row) 하나는 개인의 자료 set을 의미한다. 열(column)은 보통 각 개인의 특성을 나타내는 변수를 의미한다. 100명의 사례의 ID, 성별, 시험점수를 조사한 자료를 생각해보면 100 * 3의 매트릭스 형태가 될 것이다. 앞으로 설명할 자료 구조는 이처럼 자료가 갖고 있는 형태와 특성을 의미한다. SPSS나 STATA와 같은 통계 패키지에서는 엑셀 자료와 같은 매트릭스 형태(R에서는 dataframe이라 부른다)만을 사용하지만, R에서는 총 7개의 자료구조가 있다. 조금 복잡하지만 처음부터 제대로 이해해놓는 것이 중요하다.

2.3.1 스칼라 scalar

구성인자element가 하나인 자료를 의미한다. 일반적으로 사회과학에서 구성인자가 하나인 데이터를 쓰는 경우는 많지 않다. 따라서 스칼라scalar는 이후에 살펴볼 벡터vector의 하위구조로 생각해둘 필요가 있다. 자료를 입력할 때 문자형 자료는 큰따옴표로 정의해주는 것을 염두에 두자.

```
scalar<-1
scalar
## [1] 1
scalar<-"bts"
scalar
## [1] "bts"
```

2.3.2 벡터 vector

구성인자element가 두 개 이상인 자료를 의미한다. 따라서 스칼라는 특수한 형태의 벡터이다. 벡터를 만들때는 c() 명령어를 주로 쓴다. 심표로 연결해주면 무한대로 복수의 스칼라를 연결할 수 있다.

```
vector <-c(1,2,3)
vector
## [1] 1 2 3
vector <-c("v", "rm", "suga")
```

```
vector
## [1] "v"      "rm"      "suga"
```

2.3.3 매트릭스 matrix

매트릭스는 벡터를 여러 개의 row(행) 또는 column(열)으로 쌓은 자료를 의미한다. 2 by 2, 100 by 100 등의 행렬의 형태가 대표적이다. 벡터가 1차원이라면, 매트릭스는 2차원 형태의 데이터 구조를 띤다. 따라서 매트릭스부터는 생성을 위해 별도의 명령어가 필요하다.

- 매트릭스를 만들기 위한 명령어는 `matrix()`이다. 대체로 R의 명령어는 이렇게 직관적이다. 괄호 안에 자료에 들어갈 값을 `c()`를 활용해 지정해주고, 행 또는 열의 개수를 `nrow=`, `ncol=`의 옵션으로 지정해준다.
- 1열(by column)부터 값이 부여된다. 1행(by row)부터 값을 부여하고 싶다면 `byrow=TRUE`의 옵션을 사용한다.
- `matrix()` 명령어를 찬찬히 살펴보면 R의 명령어 구조에 대한 힌트를 얻을 수 있다. 다시 말해, 부수적인 옵션들은 쉼표로 연결하는 구조이다. 당연하게도 옵션을 나열하는 순서도 변경가능하다.
- `c(1:10)`은 1부터 10까지의 수를 차례대로 삽입하라는 뜻이다.

```
matrix <-matrix(c(1,2,3,4,5,6), nrow=3)
matrix
##      [,1] [,2]
## [1,]    1    4
## [2,]    2    5
## [3,]    3    6
matrix <-matrix(c(1,2,3,4,5,6), nrow=2)
matrix
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
matrix <-matrix(c(1:20), nrow=4, ncol=5, byrow=TRUE)
matrix
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    1    2    3    4    5
## [2,]    6    7    8    9   10
```

```
## [3,] 11 12 13 14 15
## [4,] 16 17 18 19 20
```

매트릭스는 벡터를 행 또는 열로 쌓은 자료이기 때문에, 실제로 이러한 방식으로 데이터를 만들수도 있다. 즉, 벡터를 연결하는 방식으로 매트릭스를 만들 수 있다. 사회과학에서 쓰는 자료 구조에서 하나의 벡터는 하나의 변수(variable) 또는 하나의 케이스(case)로 이해할 수 있다.

- mat1과 mat2는 각각 1에서 3, 4에서 6의 값을 갖는 벡터이다. 이 벡터를 행 또는 열로 연결하면 매트릭스가 된다.
- 행으로 연결하기 위해서는 rbind(), 열로 연결하기 위해서는 cbind()의 명령어를 사용하면 된다. 행으로 연결한다면 몇 개의 case를 추가하는 것, 열로 연결한다면 몇 개의 변수를 추가하는 것으로 이해할 수 있다.
- c(vector1, vector2)를 사용하게 되면 1차원의 벡터로 만들어진다는 점을 유념하자.

```
mat1 <-c(1:3)
mat2 <-c(4:6)
matrix1 <-rbind(mat1, mat2) #rbind : row을 기준으로 종으로 붙이기
matrix1
##      [,1] [,2] [,3]
## mat1  1   2   3
## mat2  4   5   6
matrix2 <-cbind(mat1, mat2) #cbind : column을 기준으로 횡으로 붙이기
matrix2
##      mat1 mat2
## [1,]    1    4
## [2,]    2    5
## [3,]    3    6
matrix3<-c(mat1, mat2) #c()를 사용하면 벡터와 벡터를 하나의 차원으로 연결
matrix3
## [1] 1 2 3 4 5 6
```

매트릭스에서 추가로 이해해야 할 개념은 특정 요소(element)의 위치를 행과 열의 자릿수로 설명할수 있다는 것이다. “행렬”이라는 이름에서 직관적으로 이해할 수 있듯이 행렬의 원소의 위치는 [n번째 행, k번째 열]의 순서로 표기한다. 원소의 위

치를 특정하는 것은 어떠한 작업과 연결될까? 예를 들어 내가 갖고 있는 데이터의 103번째 사례(행번호 103)의 3번째 변수(열번호 3번)를 수정하고 싶을 때 사용할 수 있다.

- 매트릭스의 특정 위치의 원소 추출을 위해서는 대괄호[] 를 사용한다.
- [1,2]는 1번째 행, 2번째 열에 위치를 의미한다
- 쉼표는 “전체”를 의미한다 예를 들어 [1,]는 첫번째 행과 모든 열을 의미한다. 다시 이야기하면 첫번째 행의 모든 원소를 의미한다.
- 복수의 위치를 지정하고 싶다면 만능키인 c()를 사용한다. 행 또는 열 위치에 삽입하면 된다.
- 원소를 치환하고 싶으면 equal(=)을 사용하여 간단히 정의하면 된다.

```
matrix2[1,2]
## mat2
##      4
matrix2[1,] #첫번째 row의 모든 원소를 추출
## mat1 mat2
##      1      4
matrix2[,1] #첫번째 col의 모든 원소를 추출
## [1] 1 2 3
matrix2[c(1,2),] #1,2번째 row의 모든 원소를 추출
##      mat1 mat2
## [1,]      1      4
## [2,]      2      5
matrix2[1,2]=100 # 첫번째 행, 두 번째 열의 원소를 100으로 치환한다.
matrix2
##      mat1 mat2
## [1,]      1 100
## [2,]      2      5
## [3,]      3      6
```

2.3.4 배열 array

array는 matrix를 여러 층으로 쌓은 것이다. matrix가 2차원 구조이므로, array는 3차원 구조이다. 행렬로 표현된 데이터를 켜켜히 쌓아올린다고 생각하면 된다. 통상 사회과학연구에서 자주 볼수 없는 데이터 구조이나, 시계열적인 자료나 청키한

데이터들이 array의 형태를 띈다.

- array를 생성하는 명령어는 array()이다.
- 보통 2개 이상의 매트릭스를 연결하여 만든다(c(matrix1, matrix2, ...))
- matrix와 유사하게 dimension의 구조도 옵션으로 제시해준다. dim=c()의 명령어를 사용한다.

```
matrix1<- matrix(c(1:9), nrow=3)
matrix1
##      [,1] [,2] [,3]
## [1,]    1    4    7
## [2,]    2    5    8
## [3,]    3    6    9
matrix2<- matrix(c(10:18), nrow=3)
matrix3<- matrix(c(19:27), nrow=3)
matrix2
##      [,1] [,2] [,3]
## [1,]   10   13   16
## [2,]   11   14   17
## [3,]   12   15   18
matrix3
##      [,1] [,2] [,3]
## [1,]   19   22   25
## [2,]   20   23   26
## [3,]   21   24   27
array <-array(c(matrix1, matrix2, matrix3), dim=c(3,3,3))
array
## , , 1
##
##      [,1] [,2] [,3]
## [1,]    1    4    7
## [2,]    2    5    8
## [3,]    3    6    9
##
## , , 2
```

```
##
##      [,1] [,2] [,3]
## [1,]   10   13   16
## [2,]   11   14   17
## [3,]   12   15   18
##
##      , , 3
##
##      [,1] [,2] [,3]
## [1,]   19   22   25
## [2,]   20   23   26
## [3,]   21   24   27
```

2.3.5 데이터프레임 dataframe

지금까지 살펴본 vector, matrix, array는 모두 같은 유형의 데이터로만 구성되어 있다. 즉 문자형(character), 논리형(logic), 숫자형(numeric) 등 통일된 한종류로만 구성이 되어 있다. 우리가 일반적으로 쓰는 데이터는 문자형 변수, 숫자형 변수 등이 혼재되어 하나의 데이터셋에 담겨있다. 이러한 경우 R은 데이터 프레임(dataframe)이라는 별도의 데이터 구조를 사용한다. 앞으로 우리가 사용할 대부분의 데이터는 데이터프레임일 것이다.

간단한 형태의 데이터 프레임을 직접 만들어 보자. 저자가 좋아하는 방탄소년단의 정보를 하나의 자료로 구성해보겠다. 방탄소년단 멤버들의 이름(문자형변수), 생년(숫자형 변수), 포지션(“반복”되는 문자형변수) 등 이다.

- 데이터 프레임을 만드는 명령어는 data.frame()이다.
- 통상적으로 c(원소1, 원소2...)로 벡터를 만들면 행이 아니라 종의 방향의 벡터가 만들어진다는 따라서, 각각의 벡터는 하나의 열(column)이 된다. 사회 과학분야에서는 주로 변수(variable)가 된다.
- bts라는 데이터 프레임을 만들면, R studio의 오른쪽 상단의 Environment 패널에 해당 데이터 프레임이 생성된다. 더블클릭하게 되면 명령어 창에 우리에게 친숙한 형태의 데이터시트가 나타난다.
- str()은 데이터 프레임의 구조(structure)를 보여준다. 3개의 변수를 가진 7개의 관측치(observation)를 가지고 있으며, 각각의 변수들을 요약해서 보여주고 있다.

- bts라는 데이터 프레임의 3개의 변수명 앞에 \$ 표시가 있는것을 기억하자. \$는 변수를 의미하는 표시로 앞으로 자주 사용하게 될 것이다.
- 변수별로 chr, num 등의 약어가 제시되는데, 이는 자료의 유형(문자형(character), 수치형(numeric) 등)을 의미한다.
- 어떠한 데이터프레임이던 분석을 시작하기 전에 반드시 str()를 사용해서 자료 구조를 확인하는 것이 좋다.
- stringAsFactors=FALSE는 문자형(string) 변수를 factor 변수로 처리하지 말라는 뜻이다. factor 변수에 대해서는 아래에서 설명할 예정이다.

```
btsname <-c("RM", "Jin", "Suga", "Jhope", "Jimin", "V", "JK")
btsyear <-c(1994, 1992, 1993, 1994, 1995, 1995, 1997)
btsposition <-c("rap", "vocal", "rap", "rap", "vocal", "vocal", "vocal")
bts <-data.frame(btsname, btsyear, btsposition, stringsAsFactors = FALSE)
bts
```

##	btsname	btsyear	btsposition
## 1	RM	1994	rap
## 2	Jin	1992	vocal
## 3	Suga	1993	rap
## 4	Jhope	1994	rap
## 5	Jimin	1995	vocal
## 6	V	1995	vocal
## 7	JK	1997	vocal

```
str(bts)
## 'data.frame': 7 obs. of 3 variables:
## $ btsname : chr "RM" "Jin" "Suga" "Jhope" ...
## $ btsyear : num 1994 1992 1993 1994 1995 ...
## $ btsposition: chr "rap" "vocal" "rap" "rap" ...
```

2.4 factor 변수

bts 데이터 프레임에서 btsname 변수와 btsposition 변수는 모두 문자형 변수이지만 차이점이 있다. btsposition 변수는 “rap”과 “vocal”이라는 두개의 값(value)이 반복된다. 이러한 형태의 변수를 R에서는 요인(factor)라는 특별한 데이터유형으로 취급한다. 사회과학연구에서 주로 사용하는 요인분석에서의 요인과는 구별되는 개념이다. R에서의 factor 변수는 주로 범주형 변수이다. 흔히 사용되는 변수 중에

성별(“남”, “여”), 학년(“1학년”, “2학년”, “3학년”), 학업성취도(“상”, “중”, “하”) 등이 factor 변수의 대표적인 예다. 범주변수를 factor로 변환하기 위해서는 다음의 사항을 기억하자.

- factor 변수로 지정하기 위해서는 factor() 명령어를 사용한다.
- factor 변수는 “값(일반 벡터)”에 “level”이라는 정보를 추가한 것이다. default로 level의 값이 부여되지만 이를 수정할 수도 있다.
- level의 순서는 알파벳 순서가 default이다.
- 경우에 따라서는 level의 순서를 바꾸고 싶을 때가 있다. 예를 들어 성별의 경우 알파벳 순서에 따라 female, male의 순서가 default이다. 이후에 그래프 등을 그릴 때 이 순서를 따르기 때문에 levels=c() 명령어를 사용해서 새롭게 지정이 가능하다.

factor() 명령어를 활용하여 btspostion 변수를 문자형 변수에서 factor 변수로 변환을 해보자. str()를 활용하여 자료의 구조를 살펴보면 factor로 잘 변환되어 있는것을 확인할 수 있다. factor로 변환하는 순간 원래의 데이터가 숫자의 정보로 변하고(1, 2,1,1,2,2,2), level(1=rap, 2=vocal)의 정보가 추가로 생성된다. 만약에 1=vocal, 2=rap의 순서로 바꾸고 싶다면, levels=c(“vocal”, “rap”)의 옵션을 추가하면 된다.

```
bts$btspostion <-factor(btspostion)
str(bts$btspostion)
## Factor w/ 2 levels "rap","vocal": 1 2 1 1 2 2 2
levels(bts$btspostion)
## [1] "rap" "vocal"
bts$btspostion <-factor(btspostion, levels=c("vocal", "rap"))
str(bts$btspostion)
## Factor w/ 2 levels "vocal","rap": 2 1 2 2 1 1 1
summary(bts$btspostion)
## vocal rap
##      4      3
```

factor 변수를 활용할 때 조심해야할 것들이 있다. 문자형변수를 수치형변수 +level의 정보로 축약하기 때문이다. 아래와 같이 as.numeric() 명령어를 활용해서 변수를 팩터에서 숫자형으로 변환해보면, 팩터의 원래값이 나타난다.

```
bts$btspostion <- as.numeric(bts$btspostion)
str(bts$btspostion)
##  num [1:7] 2 1 2 2 1 1 1
```

이러한 특징은 가끔 팩터형 자료를 붙이거나 자를때 문제를 일으키는 경우가 많다. 따라서 전처리 과정에서는 계속해서 문자형 변수로 두다가, 통계적 분석 과정 직전에(즉, 데이터 전처리가 모두 끝난 후에) 팩터형 변수로 바꾸는 것을 권장한다. 팩터형 변수를 다루는 것이 까다롭기 때문에 종종 별도의 패키지를 쓰곤한다. 대표적인것이 FORCAT 패키지인데, 이는 3장에서 다시 구체적으로 다루도록 하겠다.

2.5 NA와 NULL

마지막으로 R에서 결측치를 표현하는 두가지 방식에 대해 이해해보도록 하자. 어떠한 데이터든지 결측치는 흔하게 존재한다. 특히 다른 곳에서 수집된 자료를 2차 가공을 하는 경우에는 더욱 빈번하게 출현한다. R에서 벡터 또는 데이터 프레임에서 비어있는 값, 결측치를 표현하는 방식은 다음과 같다.

- NA는 not available의 약자로, 결측치를 의미한다.
- NA는 우리가 사용하는 데이터에서 흔히 볼 수 있는 결측치이기 때문에 특정 변수(벡터)의 한 요소(element)로 존재한다. 원래 있어야 하는 값이 기 때문에 NA는 평균 등 통계량 산출에 영향을 미친다.
- NA를 무시하고 통계량을 계산하고 싶다면 `na.rm=TRUE` 옵션을 명령어 뒤에 붙이면 된다. `na.rm`은 NA를 제거(removing)하라는 뜻이다.
- NULL은 원래 존재하지 않는 값을 의미한다. NA와 달리 벡터 자체가 정의되지 않은 것이라는 점을 이해해야 한다. 일반적으로는 특정한 목적으로 데이터를 담지 않은(“즉, 텅 비어있는”) 객체(object)를 만들어야 할 때 사용된다.

데이터 분석시 자주 활용하게 될 NA를 중심으로 살펴보면 아래와 같다. `age` 변수의 첫번째 값을 결측치(NA)로 변경하면, 평균값을 산출할때 조심할 필요가 있다. `na.rm=FALSE`가 기본옵션(default)이기 때문에 `mean()` 함수를 사용하면 NA가 산출된다. 반면에 `na.rm=TRUE` 옵션을 사용하게 되면 결측치를 제거하고 6개의 자료의 평균을 산출해준다.

```
#btsyear 변수를 활용(computation)해서 age 변수를 새로 만든다
bts$age <- 2021-bts$btsyear+1
bts
##   btsname btsyear btsposition age
## 1      RM   1994         rap  28
## 2      Jin   1992        vocal  30
## 3      Suga   1993         rap  29
## 4     Jhope   1994         rap  28
## 5     Jimin   1995        vocal  27
## 6         V   1995        vocal  27
## 7       JK   1997        vocal  25
bts[1,4] <-NA
bts
##   btsname btsyear btsposition age
## 1      RM   1994         rap  NA
## 2      Jin   1992        vocal  30
## 3      Suga   1993         rap  29
## 4     Jhope   1994         rap  28
## 5     Jimin   1995        vocal  27
## 6         V   1995        vocal  27
## 7       JK   1997        vocal  25
mean(bts$age)
## [1] NA
mean(bts$age, na.rm=TRUE)
## [1] 27.66667
```

2.6 R 내장함수를 활용한 기술통계량 산출

장을 마무리하기 전에 데이터의 간단한 통계량을 산출하는 방법을 알아보자. 좀 더 복잡한 분석은 다음 장에서 다룰 dplyr 패키지를 활용하는 것이 좋다. 그러나 R에 내장되어 있는 함수를 활용해서도 내가 갖고 있는 데이터 프레임의 구조를 확인하고, 간단한 통계량을 확인할 수 있다. R 내장함수중에 빈번하게 사용되는 명령어를 정리해보면 아래와 같다.

데이터 구조 및 요약

- `str()` : 데이터 프레임의 사례수, 변수, 변수별 자료 유형등을 제시해준다
- `summary()` : 데이터프레임의 각 변수별 최솟값, 최대값, 길이, 평균, 사분위수등을 제시해준다.

기술통계량 확인

- `mean()` : 데이터 프레임, 또는 데이터 프레임의 특정변수(`dataframe$variable`)의 평균값
- `median()` : 데이터 프레임, 또는 데이터 프레임의 특정변수의 중앙값
- `min()`, `max()` : 데이터프레임 또는 특정변수의 최솟값, 최대값
- `var()`, `sd()` : 데이터 프레임 또는 특정변수의 분산, 표준편차
- `sum()` : 데이터 프레임 또는 특정변수의 합
- `length()` : 길이, 관측값의 갯수

테이블 또는 교차표 산출

- `table()` : 데이터 프레임의 각 변수별 분할표를 제시
- `table(변수, 변수)` : \$인자를 활용해서 특정변수간의 교차표 생성
- `addmargin()` : 마진에 소계값을 계산
- `prop.table()` : 테이블의 비율 계산
- `margin=` : `prop.table()`의 옵션, 1의 값인 경우 행(row)의 비율 합을 1로, 2의 값인 경우 열(column)의 비율 합을 1로 계산

```
summary(bts)
##      btsname          btsyear    btsposition      age
## Length:7          Min.   :1992    vocal:4      Min.   :25.00
## Class :character  1st Qu.:1994    rap  :3      1st Qu.:27.00
## Mode  :character  Median :1994                      Median :28.00
##                      Mean  :1994                      Mean  :27.71
##                      3rd Qu.:1995                      3rd Qu.:28.50
##                      Max.   :1997                      Max.   :30.00

str(bts)
## 'data.frame':   7 obs. of  4 variables:
##  $ btsname      : chr  "RM" "Jin" "Suga" "Jhope" ...
##  $ btsyear      : num  1994 1992 1993 1994 1995 ...
```

```
## $ btsposition: Factor w/ 2 levels "vocal","rap": 2 1 2 2 1 1 1
## $ age       : num  28 30 29 28 27 27 25
table(bts$age)
##
## 25 27 28 29 30
##  1  2  2  1  1
#소숫점 두번째에서 반올림
round(prop.table(table(bts$age)),2)
##
##    25    27    28    29    30
## 0.14 0.29 0.29 0.14 0.14
#분할표를 백분율로 계산
round(prop.table(table(bts$age)),2)*100
##
##    25    27    28    29    30
## 14 29 29 14 14
#마진에 소계값을 계산
addmargins(table(bts$age))
##
##    25    27    28    29    30 Sum
##    1     2     2     1     1     7
# 변수 * 변수의 교차표를 산출
table(bts$age, bts$btsposition)
##
##      vocal rap
## 25      1   0
## 27      2   0
## 28      0   2
## 29      0   1
## 30      1   0
# 교차표의 셀별 비율 계산(열의 합을 1로)
prop.table(table(bts$age, bts$btsposition), margin=2)
##
##      vocal      rap
```

```
## 25 0.2500000 0.0000000
## 27 0.5000000 0.0000000
## 28 0.0000000 0.6666667
## 29 0.0000000 0.3333333
## 30 0.2500000 0.0000000
```


제 3 장

데이터 전처리

3.1 들어가며

R 명령어와 데이터 구조에 대한 기본적인 이해를 마쳤다면, 이제 실제 데이터를 다뤄보자. 데이터를 다룬다는 말에는 여러가지 절차가 포함되어 있다. 첫번째는 데이터를 불러와야(import)한다. 두 번째는 데이터를 예쁘게 정리해야 한다. R의 확산에 큰 기여를 한 해들리 위컴은 이러한 작업을 타이디하게(tidy, 깔끔한) 만든다고 표현한다. 데이터셋을 예쁘게 정리한다는 것은 연구의 목적에 맞게 데이터를 자르고, 붙이고, 조정한다는 뜻을 의미한다. 해들리 위컴의 정의에 따르면 타이디한 데이터는 다음과 같다.

- 데이터의 각 열은 변수(variable)이다.
- 데이터의 각 행은 관측값(observations)이다.
- 각 유형의 관측단위(observational unit)는 하나의 표(table)를 이룬다. 즉, 학생과 학교처럼 서로 다른 수준의 대상을 관측하는 경우에는 각각을 별도의 표로 구성하는 것이 원칙이다.

혹자는 이러한 정의가 무슨 뜻인지 의아할 것이다. 왜냐하면 타이디하지 못한 데이터를 본적이 없기 때문이다. 일반적으로 연구 목적이 아닌 방식으로 수집된 자료(일반적인 행정데이터들이 대표적이다)가 대표적으로 언타이드 데이터이다. 연구자 인생에서 언타이드 데이터를 가급적 마주치지 않는 것이 정신건강에 이롭지만, 세상일이 그렇게 호락호락하지 않는다. 다양한 조직에서 언타이드 데이터를 그것도 어마어마한 사이즈로 보유하고 있기 때문이다. 많은 사람들이 엑셀을 사용해서

수작업(!!!)으로 데이터를 정리하다가 포기한다. 이 장에서는 언타이드 데이터를 정리하는 방법까지 포함해서 다룰 예정이다.

세번째 단계는 데이터의 변형이다. 행과 열이 변수와 관측값으로 정리된 타이드 데이터를 나의 연구의 목적에 맞게 정리하는 것이다. 불필요한 관측값을 삭제하고(예: 취업자만 선택), 불필요한 변수값을 삭제하고(예: 1~10번째 변수만 선택하고 나머지는 drop), 결측치 를 처리하고, 새로운 변수를 생성하고(1~3의 변수의 평균값을 4번째 변수로 생성), 범주형 변수를 더미화하거나(), 또는 factor형 변수로 변환하여 level 정보를 추가한다.

통상적으로 이 장에서 다루는 데이터 전처리 과정은 통계 분석 과정에서 투입되는 시간의 70% 이상을 차지한다. 특히 원자료가 untidy 할 수록 그 시간은 늘어난다. 개인적으로 학생들이 가장 어려워하고, 중간에 포기하기 쉬운 장이라고 생각한다. 그러나 데이터 전처리 스킬이 연구자의 통계분석역량의 바로미터이기 때문에 꾸준히 공부하는 것이 중요하다. 이 장을 잘 마치게 되면, 이후의 다양한 분석들이 너무 쉽게 느껴질 것이다.

데이터 전처리는 R의 강점을 피부로 느낄 수 있는 단계중 하나이다. 통상 데이터 전처리의 전 단계는 약 50~100줄정도의 코드로 구성이 된다. 각 단계별로 작업중에 문제가 생기면 간단히 이전의 코드를 수정함으로써 재작업이 용이하다. 만일 데이터 전처리를 GUI 방식의 통계패키지로 작업하게 되면 한순간의 실수로 그간의 작업을 통째로 날리는 경험을 할 수 있다. 이보다 더 끔찍한 일은 내가 어느 단계에서 실수했는지 확인이 안된다는 사실이다!(물론 로그를 리뷰하면 알 수 있지만, GUI를 쓰는 사람이 로그를 볼 가능성은 0프로에 가깝다). 이러한 실패(라쓰고 삽질이라 읽는다)를 몇번하고 나면, R을 배우는데 필요한 약간의 허들은 가볍게 느껴질 것이다.

3.1.1 패키지 준비하기

데이터 전처리는 R의 내장함수로도 어느정도 작업이 가능하지만, 이 책에서는 해들리 위컴이 개발한 tidyverse 패키지를 활용하여 데이터 전처리와 시각화 작업을 수행할 예정이다. R은 일종의 플랫폼과 같기 때문에 다양한 분석/작업에 특화된 패키지를 설치(install)하고, 실행(library)할 수 있다. 스마트폰에 기본 카메라와 어플에서 다운받은 필터 카메라를 실행시키는 작업과 매우 유사하다. 기본 카메라로도 사진을 찍을 수 있지만, 특화된 카메라 어플은 더 나은 기능을 제공한다는 점을 유념하라. 따라서 데이터 전처리부터는 별도의 패키지를 R에 설치하고 실행하는 단계부터 시작하도록 하겠다.

tidyverse 패키지 설치 및 실행

R에서 패키지를 설치하는 방법은 크게 두가지이다. 콘솔창에 `install.packages("패키지 이름")`를 사용하거나, RStudio menu -> Tools -> Install Packages에서 패키지 이름을 찾거나 입력해서 설치하는 방법이다. 통상적으로는 콘솔창에 `install.packages("")` 명령어를 활용한다. 데이터 전처리에 주로 사용할 패키지는 `dplyr` 이다. 이 패키지를 단독으로 설치해줘도 좋지만, 앞으로 R을 사용할때 자주 활용할 패밀리 패키지를 한꺼번에 설치해보도록 하겠다. tidyverse라는 이름의 패키지는 데이터 시각화의 필수 패키지인 "ggplot2"를 비롯해서 "tibble", "tidyr", "readr", "purrr", "dplyr", "stringr", "forcats" 등이 포함되어 있다.

- `install.packages("")`를 입력하고 Windows/Linux에서는 Ctrl+Enter, Mac에서는 Command+Enter를 누르면 패키지 설치 명령이 실행된다. 콘솔창에 빨간버튼(stop)이 사라질때까지 기다린다.
- 복수의 패키지를 한꺼번에 설치하고 싶으면 `c` 명령어를 이용한다: `install.packages(c("A package", "B package"))`
- 패키지를 인스톨할때 error 메시지가 뜨면 해당 메시지를 복사해서 구글링하는 것이 가장 간편한 해결방법이다. 대체로 dependency 문제일 가능성이 높다. R의 패키지들은 종종 선행해서 설치되어야하는 패키지들을 갖고 있는 종속된 관계이기 때문이다. 이에 대해 더욱 잘 알고 싶다면 패키지의 설치 안내문을 참조하길 바란다. 이러한 문제 해결을 위해서는 처음부터 R과 RStudio 설치를 꼼꼼히 하는 것이 필요하다. Windows에서 소스 패키지를 직접 컴파일해야 하는 경우에는 Rtools가 추가로 필요할 수 있다.
- 급하게 해결하기 위해서는 다음의 옵션을 사용하자. `install.packages("패키지 이름", dependencies=TRUE, repos="https://cran.rstudio.com")`
- 패키지가 설치된 후에는 `library()` 명령어를 사용하여 실행시키자. 패키지 설치하는 처음에만, library는 해당 스크립트 또는 프로젝트를 실행시킬때마다 수행이 필요하다.

```
install.packages("tidyverse")
library(tidyverse)
```

3.1.2 작업 디렉토리 설정하기

패키지 설치가 완료되었다면 작업 디렉토리를 설정하는 것이 필요하다. 작업 디렉토리(working directory)란 내가 사용할 데이터, 작성한 코드, 아웃풋 파일 등을 저장하고 불러올 기준 폴더를 지정하는 것을 의미한다. R에서 작업 디렉토리를

지정하는 방식은 크게 두 가지가 있다.

R project 생성 방식

첫번째는 폴더 자체를 하나의 프로젝트(project)로 지정하는 방법이다. 대부분의 작업을 이 방식으로 수행하는 것을 강력히 권한다. 프로젝트는 하나의 폴더와 동일해지는 개념으로 생각하면 쉽다.

- 프로젝트 생성은 R studio -> File -> New project를 클릭
- 프로젝트는 1) 내컴퓨터 안에 새로운 폴더를 생성하는 방법, 2) 기존의 폴더를 프로젝트로 지정하는 방법 3) version control 방법으로 세가지가 존재한다. version control은 github 등과 연결하는 방법으로 부록을 참조하라
- 내컴퓨터 안에 새로운 폴더를 생성하는 방법을 기준으로 설명해보겠다. New Project -> New Directory -> New Project -> project 이름 입력 및 폴더 생성을 누르면 완성된다.
- 프로젝트를 생성하면 projectname.Rproj이라는 파일이 해당 폴더 안에 생성된다. 이 프로젝트 안에서 생성되는 script, output 파일들이 해당 폴더 안에서 내보내기/가져오기가 자유롭게 된다.




그림 3.1: R project 생성

working directory 설정 방식

두번째는 간단하게 나의 로컬 디렉토리(내컴퓨터안의 폴더)를 지정하는 방식이다. 간단한 작업을 수행할때 사용한다. 강력한 권고에도 불구하고 간단한 방식을 쓰고 싶은 사람들은 아래의 코드를 참고하라. (하지 말라는 뜻) * getwd()를 실행하면 현재 working directory를 보여준다. * setwd()를 실행하면 괄호안의 경로의 폴더가 working directory로 지정된다. 내가 작성한 R script나 output이 이 폴더에 저장됨을 뜻한다. 또한 working directory안의 파일들은 별도의 경로를 지정하지

않아도 파일이름만 쓰면 알아서 R이 인지한다.

```
getwd()
setwd("C:\\Users\\Owner\\Documents\\new")
```

3.1.3 데이터 불러오기

패키지 설치가 완료되었다면 데이터를 불러와보자. 엑셀, txt, spss 파일 등 외부 데이터를 불러오기 위해서는 가져오기(import)를 실행해야 한다. 데이터를 불러온다는 뜻은 외부데이터를 불러와서 R의 dataframe 또는 tibble 객체로 저장한다는 것을 의미한다. 대표적인 import 명령어는 다음과 같다.

- readr::read_csv()는 쉼표로 값이 구분된 텍스트파일(.csv)을 불러올때 활용한다.
- readxl::read_excel()은 엑셀파일(.xlsx)을 불러올때 활용한다.
- haven::read_sav()는 SPSS로 저장된 파일(.sav)을 불러올때 활용한다.
- read.delim()은 탭으로 구분된 텍스트파일을 불러올때 활용한다.
- 데이터를 불러올때는 파일의 구분자, 인코딩, 변수형 등을 잘 확인해야 한다.
- SPSS 파일의 변수 라벨과 값 라벨은 haven::read_sav()으로 불러오면 속성 정보로 함께 유지된다. 필요에 따라 활용하라

아래의 코드를 좀더 자세히 살펴보자. 첫번째 코드는 나의 프로젝트 또는 작업 디렉토리 안에 있는 data_csv.csv파일을 불러와서 data_csv라는 데이터 프레임 객체를 생성하라는 뜻이다. 마찬가지로 두번째 코드는 spss 파일을 불러오는 코드이다. csv, xlsx, sav 등 주요 파일 형식은 R에서 직접 import할 수 있다. 특히 SPSS의 변수 라벨이나 값 라벨 정보를 유지해야 한다면 sav 파일을 haven::read_sav()으로 직접 불러오는 것이 좋다.

```
data_csv <- readr::read_csv("data_csv.csv")
data_excel <- readxl::read_excel("data_excel.xlsx")
data_spss <- haven::read_sav("data_sav.sav")
```

3.2 dplyr 패키지의 이해

앞서서 데이터 전처리는 크게 두가지 단계 1) untidy한 데이터를 tidy 데이터로 만들기, 2) 데이터의 변형(연구목적에 맞게 데이터의 관측치 및 변수를 삭제, 조합하는 것)으로 나뉜다고 설명하였다. 이 장에서는 먼저 데이터의 변형에 대해

다루도록 하겠다. 그 이유는 untidy 데이터를 다루는 것이 더 높은 난이도이기 때문이다. 먼저 데이터 변형을 손쉽게 하는 수준에 오르게 되면, 그 다음 tidy화에 대해 배우는게 좋다. 다시말하면 이 챕터에서는 행에는 관측치가, 열에는 변수가 들어있는 데이터를 연구 목적에 맞게 변형하는것에 초점을 맞추도록 하겠다.

데이터 전처리 과정에서 주로 사용할 패키지는 dplyr다. tidyverse패키지 안에 들어있는 패키지로 단독설치도 가능하다. dplyr의 강점은 다음과 같다.

- R의 내장함수보다 직관적인 명령어 구조를 갖고 있다.
- R보다 복잡한 자료변형이 가능하다.
- pipe operator(%>%)를 사용하여 코드를 심플하게 짤 수 있다.

3.2.1 pipe operator

먼저 pipe operator에 대해 이해하면 dplyr의 강점을 십분 이해할 수 있다. 남이 짜둔 코드를 보다보면 마치 에러메시지와 같은 형태의 %>% 가 자주 등장한다. %>% 은 pipe operator라 불리며 “and then”의 문법과 같은 의미로 사용된다. 원래 R의 기본 코드는 괄호()가 이 기능을 수행한다. 빠른 이해를 위해 다음과 같은 짧은 코드를 살펴보자. x라는 객체를 만들고, 이 안에 30,20,10,0이라는 4개의 값을 지정한다. 만일 객체 x의 절대값(abs)을 구하고, 4개의 절대값의 평균값을 구한다 음(mean), 다시 이 평균값의 제곱근(sqrt)을 구하고 싶다면 아래와 같이 코드를 짜야한다. 결국 괄호의 가장 안쪽부터 바깥쪽 까지 and then의 문법으로 계산이 이루어지는 것이다. 절대값을 구하고 and then 평균값을 구하고 and then 제곱근을 구하라는 명령이 sqrt(mean(abs()))의 코드로 구현된다.

```
x<-c(30, 20, 10, 0)
sqrt(mean(abs(x)))
```

문제는 코드가 조금만 복잡해져도 괄호 갯수 등의 실수가 자주 발생한다는 것이다. 또한 가장 나중에 수행해야할 명령이 가장 먼저 코딩되어야하기 때문에 직관적으로도 이해가 쉽지 않다. pipe operator는 이러한 R코드의 문법구조를 좀더 직관적으로 바꾸는 역할을 한다. 위의 코드를 pipe operator를 활용해서 바꿔보면 아래와 같다

```
x %>%
  abs() %>%
  mean() %>%
  sqrt()
```

위의 코드에서 pipe operator를 and then으로 바꾸어보면 마치 구어로 설명하듯이 편안하게 코드를 짤 수 있다는 점을 확인할 수 있다. X를 가지고 와서 and then 절대값을 구하고, and then 평균값을 구하고, and then 제곱근값을 구하라는 뜻이다. pipe operator는 코드가 복잡해지고, ggplot2 등을 활용하여 그래프를 그릴 때 강점이 잘 드러난다. 앞으로 이 책에서는 pipe operator를 최대한 활용하여 코드를 설명할 예정이다. 다만 dplyr 패키지가 설치(install)되고 실행(library)된 상태에서 pipe operator가 정상적으로 실행된다는 점을 주의하자.

3.3 dplyr의 주요 기능

지금부터 dplyr의 가장 기본적이고 대표적인 기능을 하나하나 알아보도록 하겠다.

3.3.1 filter

filter 함수는 특정한 행(row)을 선택하는 기능이다. 시각적으로 생각하면 데이터를 횡의 방향으로 절단 또는 선택하는 기능이다. 예를 들어 데이터 중에 취업한 사람의 케이스만 선택하고 싶다면 filter 함수를 쓰면 된다.

코드 시현에 앞서서 R에 내장된 데이터를 불러와보자. R에는 연구자가 코드를 연습해볼 수 있는 다양한 종류의 데이터가 많이 있다. 여기서는 nycflights13 패키지가 제공하는 flights 데이터를 사용한다. 이 데이터에는 2013년 뉴욕의 세 공항에서 출발한 항공편 정보가 담겨 있다.

패키지 설치의 컴퓨터에서 한 번만 하면 된다. 아래 설치 코드는 수업 중 콘솔에서 직접 실행하되, 책을 빌드할 때마다 다시 설치되지 않도록 실행하지 않는 예시로 둔다.

```
install.packages("nycflights13", repos = "https://cloud.r-project.org")
```

설치된 패키지를 불러온 다음 flights를 일반 데이터 프레임으로 변환한다.

```
library(nycflights13)
flight_df <- data.frame(nycflights13::flights)
print(head(nycflights13::flights), width = 70) # 처음 6개 행을 간결하게 출력
## # A tibble: 6 x 19
##   year month   day dep_time sched_dep_time dep_delay arr_time
##   <int> <int> <int>   <int>         <int>         <dbl>   <int>
## 1  2013     1     1     517             515           2     830
```

```
## 2 2013      1      1      533          529          4      850
## 3 2013      1      1      542          540          2      923
## 4 2013      1      1      544          545         -1     1004
## 5 2013      1      1      554          600         -6      812
## 6 2013      1      1      554          558         -4      740
## # i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
## #   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
## #   minute <dbl>, time_hour <dtm>
str(flight_df)
## 'data.frame':   336776 obs. of  19 variables:
##  $ year          : int  2013 2013 2013 2013 2013 2013 2013 2013 2013 2013 ...
##  $ month         : int   1  1  1  1  1  1  1  1  1  1 ...
##  $ day           : int   1  1  1  1  1  1  1  1  1  1 ...
##  $ dep_time      : int  517 533 542 544 554 554 555 557 557 558 ...
##  $ sched_dep_time: int  515 529 540 545 600 558 600 600 600 600 ...
##  $ dep_delay     : num   2  4  2 -1 -6 -4 -5 -3 -3 -2 ...
##  $ arr_time      : int  830 850 923 1004 812 740 913 709 838 753 ...
##  $ sched_arr_time: int  819 830 850 1022 837 728 854 723 846 745 ...
##  $ arr_delay     : num  11 20 33 -18 -25 12 19 -14 -8 8 ...
##  $ carrier       : chr  "UA" "UA" "AA" "B6" ...
##  $ flight        : int  1545 1714 1141 725 461 1696 507 5708 79 301 ...
##  $ tailnum       : chr  "N14228" "N24211" "N619AA" "N804JB" ...
##  $ origin        : chr  "EWR" "LGA" "JFK" "JFK" ...
##  $ dest          : chr  "IAH" "IAH" "MIA" "BQN" ...
##  $ air_time      : num  227 227 160 183 116 150 158 53 140 138 ...
##  $ distance      : num  1400 1416 1089 1576 762 ...
##  $ hour          : num   5  5  5  5  6  5  6  6  6  6 ...
##  $ minute        : num  15 29 40 45  0 58  0  0  0  0 ...
##  $ time_hour     : POSIXct, format: "2013-01-01 05:00:00" "2013-01-01 05:00:00" ...
```

nycflights13을 실행시키면 flights라는 데이터를 사용할 수 있게 된다. 가장 먼저 데이터의 구조를 판단하고, dataframe으로 변환하는 작업이 필요하다.

- head()는 자료의 처음 6개 행을 보여준다. 출력 너비에 따라 화면에 표시되지

앞은 열은 아래에 별도로 안내된다. 출력 결과를 살펴보면 year, month, day, dep_time 등의 변수가 정수형 자료로 제시되어 있다.

- data.frame()은 tibble의 자료 구조를 dataframe으로 바꾸는 명령어이다.
- str()은 데이터 프레임의 구조(행과 열의 갯수, 변수명, 변수의 자료 유형 등)를 보여준다.

dataframe으로 변환한 flight_df라는 객체는 R studio의 오른쪽 상단 environment 창에 뜨게 된다. 이를 더블 클릭하게 되면 script 창에 우리에게 친숙한 데이터시트가 뜬다. 콘솔창에 나타난 결과를 보면 flight_df는 336776개의 관측치(=행의 갯수가 336,776개)와 19개의 변수(=열의 갯수가 19개)인 것을 확인할 수 있다. 대부분의 변수가 정수 또는 수치형 자료이고, 출발지(origin), 도착지(dest) 등은 문자형 변수이다.

본격적으로 filter 함수에 대해 알아보자. filter는 자료를 횡으로 자르는 것이다. 바꿔말하면 어떠한 변수가 특정값인 관측치만 선택하는 것이다. 예를 들어 month가 1인 자료만 선택하고 싶다면 month=1로 필터링을 하는 것이다.

```
##month=2인 자료만 필터링
flight_df %>%
  filter(month==2)
##month=2 or day=1 자료만 필터링
flight_df %>%
  filter(month==2 | day==1)  #shift+\
##month=2 and day=1 자료만 필터링
flight_df %>%
  filter(month==2, day==1) #쉼표나 & 모두 사용 가능

##month=2가 아닌 자료만 필터링
flight_df %>%
  filter(month!=2)  #느낌표는 not의 의미
##month가 5이상인 자료만 필터링
flight_df %>%
  filter(month >=5)
##month가 5, 7, 10인 자료만(복수의 조건) 필터링
flight_df %>%
  filter(month %in% c(5,7,10))
```

```
##na 값 표시 또는 제거 해서 필터링
flight_df %>%
  filter(is.na(month)) #na인 row만 표시/
flight_df %>%
  filter(!is.na(month)) #na가 아닌 row만 표시/
```

- 주로 equal(==), and(&), or(|), not equal(!=), greater than or equal to(>=), greater than(>), less than(<), less than or equal to(<=) 를 사용하여 관측치를 필터링한다.
- na값만 필터링하기 위해서는 is.na(), na값을 제외하여 필터링하기 위해서는 !is.na()를 사용한다.
- 복수의 조건을 사용하여 필터링하기 위해서는 %in% c()의 구문을 사용한다.
- dplyr의 모든 명령어는 tibble을 활용하여 임시적으로 데이터를 변형한다. 다시 말해 원래의 dataframe을 변형시키지는 않는다. 따라서 별도의 데이터 셋으로 저장하는 절차가 필요하다.
- 만일 변형한 데이터를 저장하고 싶다면 새로운 데이터 프레임 또는 기존의 데이터 프레임에 저장하는 명령어를 추가해야한다. 저장은 아주 간단하게 -> 또는 <- 를 사용하면된다. summary 명령어를 통해 데이터 변형이 잘 이루어졌는지 꼭 확인이 필요하다.

```
flight_df %>%
  filter(month %in% c(5,7,10)) -> filter_df2

summary(filter_df2$month)
```

3.3.2 select

select는 특정 변수(열, column)을 선택하는 명령어이다. filter와는 정반대로 dataset을 종으로 절단하는 기능이다. 1차 자료를 연구 목적에 맞게 간추릴때 필요없는 변수를 삭제하거나 필요한 변수만을 선택해야하는 경우가 있다. 이때 select가 유용하게 사용된다.

- select() 명령어의 괄호안에 선택할 변수명을 쉼표로 이어가며 작성하는 방식이 일반적이다.
- 콜론(:)은 연속적인 변수를 선택할때 사용한다.
- 느낌표(!)는 해당 변수를 제외한 변수들을 선택할때 사용한다. 복수의 변수를

제외하고 싶다면 `c()`로 연결하면 된다.

- `starts_with`, `ends_with`, `contains`를 활용하면 변수명을 조합하여 선택도 가능하다.

```
#month, day 변수만 선택
flight_df %>%
  select(month, day)
#year에서 day까지의 변수만 선택
flight_df %>%
  select(year:day)
#year에서 day까지의 변수만 제외해서 선택
flight_df %>%
  select(-(year:day))
#복수의 변수를 제외하고 싶은 경우 -c()를 사용
flight_df %>%
  select(-c(year, month))
#dep이라는 단어로 시작하는 변수들 선택
flight_df %>%
  select(starts_with("dep"))
#time이라는 단어로 끝나는 변수들 선택
flight_df %>%
  select(ends_with("time"))
#time 또는 delay 중 하나라도 포함되어 있는 변수들 선택
flight_df %>%
  select(contains(c("time", "delay")))
```

3.3.3 arrange

`arrange`는 특정한 변수를 기준으로 정렬을 할때 사용하는 명령어이다. 오름차순과 내림차순, 그리고 두개 이상의 변수를 활용한 2차 이상의 정렬도 가능하다.

```
##month, day 순으로 오름차순
flight_df %>%
  arrange(month, day)
##month는 오름차순, day는 내림차순
```

```
flight_df %>%
  arrange(month, -day)
flight_df %>%
  arrange(month, desc(day))
##month, day 순으로 내림차순
flight_df %>%
  arrange(-month, -day)
flight_df %>%
  arrange(desc(month), desc(day))
```

3.3.4 mutate

mutate는 기존의 변수를 활용하여 새로운 변수를 만드는 명령어이다. 보통 이런 변수를 파생변수(derived variables)라고 부른다. 예를 들어 소요시간(time)과 거리(distance)라는 원변수가 있다면, 거리/소요시간으로 속력(speed)이라는 새로운 변수를 만드는 방식이다. 또는 x1~x5의 5개의 문항의 평균값을 의미하는 새로운 변수를 만드는 것도 mutate 명령어를 활용할 수 있다. mutate는 크게 두가지 방식이 있다. 첫째는 덧셈, 뺄셈, 곱셈, 나눗셈, 로그, 제곱근 등 다양한 연산을 통해 파생변수를 만드는 방식, 둘째는 ifelse 구문을 활용하여 조건을 만족하는 경우 특정 값을 부여하는 방식(dummy coding) 이다.

- mutate(새로운변수명=수식 또는 논리식)의 구조를 따른다.
- 연산의 경우 +, -, *, /, log, sqrt 등 대부분의 연산자를 활용하여 수식을 작성한다.
- 더미 코딩을 위해 ifelse를 사용하는 경우 mutate(새로운변수명 = ifelse(조건, TRUE값, FALSE값))의 구조를 따른다.
- mutate의 결과를 이후에도 사용하고 싶다면 새로운 데이터 프레임 또는 기존 데이터 프레임에 저장하는 명령어(->newdataframename)를 추가한다.
- 만일 기존 변수를 삭제(drop)하고 새로 만든 변수만 남기고 싶은 경우에는 mutate(.keep="none")을 사용한다.
- 변수의 이름을 바꾸고 싶다면 rename(새로운변수=기존변수)를 사용한다.

#연산하여 새로운 변수를 생성

```
flight_df %>%
  mutate(speed=distance/air_time*60) -> flight_df_mutate1
```

```
#ifelse를 활용하여 category 변수 생성, ifelse(조건, 조건이 true일때, 조건이 false)
flight_df %>%
  mutate(arr_delay_group=ifelse(arr_delay>0, "delay", "no delay")) -> flight_df_mutate
#기존 변수를 제외하고 새로운 변수만 남기는 경우
flight_df %>%
  mutate(total_min=hour*60+minute, .keep="none") -> flight_df_mutate2
```

3.3.5 group_by와 summarise

데이터의 전처리 단계에서는 집단별 평균값이나 빈도를 비교해야 하는 경우가 종종 발생한다. 예를 들어 성별에 따라 특정변수에 값에 차이가 있는지? 연도에 따라 평균값이 어떻게 변하는지? 학년별로 결측치 빈도가 어떻게 다른지? 등이 이에 해당된다. 이러한 상황을 시각적으로 생각해보면 데이터가 일종의 축소 또는 요약되는 것을 쉽게 이해할 수 있다. 예를 들어 남성 50명, 여성 50명의 IQ, GPA, 학습시간의 데이터가 있다고 생각해보자. dataframe의 형태로 생각해보면 100개의 행(row, 관측치 갯수)과 4개의 열(column, 변수의 갯수)의 100x4의 매트릭스일 것이다. 만일 성별에 따라 IQ, GPA, 학습시간의 평균값을 비교하고 싶다면 2개의 행(group의 수)과 성별을 포함한 4개의 열(성별+3개 변수)의 새로운 데이터 프레임으로 결과가 제시된다. dplyr는 이러한 과정을 group_by(집단으로 데이터를 쪼개서 비교하고)와 summarise(데이터를 요약)의 두개의 명령어 조합으로 수행한다. 통상 group_by와 summarise는 짝꿍처럼 떼려야 뗄수없는 사이로 표현된다. 왜냐하면 summarise 없이 group_by는 의미가 거의 없기 때문이다.




그림 3.2: 성별로 자료를 묶고 집단별 평균을 계산하는 과정

다시 flight 데이터로 돌아와보자. group_by 변수로 쓸만한 것들은 무엇이 있을까? 연속적인 수치형 변수보다는 factor 변수나 값의 갯수에 제한이 있는 수치형 자료가 group 변수로 적절하다는 것을 직감했을 거라 생각한다. 왜냐하면 출발시간(dep_time)처럼 수천개의 값을 가진 연속형 변수들을 기준으로 집단을 구분하는 것은 의미가 없기 때문이다. 앞서 mutate에서 도착 시간 지연여부(arr_delay_group)를 만들어낸 것을 기억하자. 도착시간보다 지연 도착한 비행기는 delay, 그렇지 않은 경우는 no delay로 변형을 시켰다. 먼저 summary 명령어를 활용하여 arr_delay_group 변수의 현황을 살펴보자. 어떤 변수의 빈도를 확인하고 싶다면 r 내장함수인 table()을 써도 좋지만, dplyr에서 제공하는 count() 함수가 훨씬 간편하다. 아래 코드를 보면 (1)mutate1_flihgt_df 데이터프레임을 불러와서, (2) arr_delay_group 변수의 빈도를 count 하라는 뜻이다.

```
flight_df_mutate %>%
  count(arr_delay_group)
##   arr_delay_group      n
## 1           delay 133004
## 2          no delay 194342
## 3             <NA>   9430
```

결과를 살펴보면 delay인 사례는 133,004개, no delay는 194,342개, 그리고 na값이 9,430개이다. 만일 na값을 그대로 두고 group_by와 summarise 함수를 적용하면 어떻게 될까? 아래 코드는 arr_delay_group별로 arr_delay 변수의 최대값(max), 최솟값(min), 평균값(mean), 중위값(median), 4분위값(quantile)을 산출하라는 뜻이다.

- group_by는 반드시 summarise 전에 코드가 작성되어야 한다.
- summarise는 새로운 tibble을 만들어내는 방식이다. 다시이야기하면 observation x variables의 데이터 프레임을 활용해서 변수 x 통계값의 새로운 요약된 데이터 프레임을 만들어내는 방식이다. 따라서 각 통계값에 해당되는 일종의 변수명을 지정해주는 것이 필요하다.
- mean(x, na.rm=TRUE) : 결측값제외하고 평균
- median(x, na.rm=TRUE) : 중앙값
- sd(x, na.rm=TRUE) : 표준편차
- min(x, na.rm=TRUE) : 최솟값
- max(x, na.rm=TRUE) : 최대값
- IQR(x, na.rm=TRUE) : 사분위범위 : Q3-Q1

- `sum(x, na.rm=TRUE)` : 합
- `n()` 관측치 개수 계산, x변수 입력 하지 않음
- `n_distinct(x)` : 중복없는 유일한 관측치 개수 계산

```
flight_df_mutate %>%
  group_by(arr_delay_group) %>%
  summarise(max_s=max(arr_delay),
            min_s=min(arr_delay),
            mean_s=mean(arr_delay),
            med_s=median(arr_delay),
            per25_s=quantile(arr_delay, 0.25))
## Error in `summarise()`:
## i In argument: `per25_s = quantile(arr_delay, 0.25)`.
## i In group 3: `arr_delay_group = NA`.
## Caused by error in `quantile.default()`:
## ! missing values and NaN's not allowed if 'na.rm' is FALSE
```

결과값을 살펴보면 no delay 집단의 경우 arr_delay 값이 음수값을 가지기 때문에 통계값 역시 음수값을 갖는 것으로 확인되었다. 문제는 na 집단이다. 에러메시지가 뜨는 것을 확인할 수 있다. na 집단을 제외하고 다시 summarise를 해보도록 하자. 앞에서 쓴 코드에 filter 명령어만 삽입하면 간단하게 해결된다. `is.na()`가 na가 아닌 row만 선택하는 옵션임을 기억하자. 마지막으로 summarise 함수의 작동방식을 제대로 이해하기 위해 아웃풋을 final이라는 dataframe으로 별도로 저장해보자. 또는 특정한 통계량만 na를 제외하고 분석하고 싶다면 `na.rm=TRUE` 옵션을 삽입하면 된다(예: `per25_s = quantile(arr_delay, 0.25, na.rm = TRUE)`)

```
flight_df_mutate %>%
  filter(!is.na(arr_delay)) %>% #na가 아닌 row만 표시
  mutate(arr_delay_group=ifelse(arr_delay>0, "delay", "no delay")) %>%
  group_by(arr_delay_group) %>%
  summarise(max_s=max(arr_delay),
            min_s=min(arr_delay),
            mean_s=mean(arr_delay),
            med_s=median(arr_delay),
            per25_s=quantile(arr_delay, 0.25),
            n_s=n())->final
```

```
final
## # A tibble: 2 x 7
##   arr_delay_group max_s min_s mean_s med_s per25_s    n_s
##   <chr>          <dbl> <dbl> <dbl> <dbl>   <dbl> <int>
## 1 delay          1272     1  40.3   21     8 133004
## 2 no delay         0    -86 -16.0  -15    -23 194342
```

3.4 데이터 결합하기

연구를 진행하다보면 두개 이상의 데이터를 결합해야 하는 경우가 종종 발생한다. 시계열 데이터를 연결하는 것이 가장 대표적인 사례다. 또는 몇개의 변수를 더 추가하거나, 몇 개의 사례를 더 추가하는 등의 간단한 결합도 자주 발생한다. dplyr는 다양한 종류의 데이터 결합에 탁월한 기능을 갖고 있다. 혹자는 엑셀로 데이터를 붙이는 무모한 시도를 하는 경우가 있는데 대체로 많은 오류를 발생시킨다. 특히 데이터에 빈 구멍이 있는 경우에는 더욱 그러하다. 예를 들어 어떤 패널 데이터의 1차년도 자료와 2차년도 자료를 결합하는 상황을 생각해보자. 종단데이터의 경우 각 관측치(사례)를 연결하는 key 변수인 ID를 제공한다. 하지만 1차년도 자료와 2차년도 자료는 완전히 동일한 ID가 아닌 경우가 많다. 1차년도에는 응답하였지만 2차년도에는 응답하지 않은 사람은 어떻게 처리해야할까? 또 1차년도 자료와 2차년도 자료와 동일한 변수는 어떻게 drop 해야 할까? dplyr는 이러한 다양한 데이터 결합에 최적의 기능을 제공한다. 이 챕터에서는 아주 간단한 결합(단순히 columns과 rows를 추가하는 형태)부터 복잡한 결합(두 자료의 교집합 또는 한자료의 여집합만 결합하는 형태 등)을 구분하여 설명해보도록 하겠다.

3.4.1 bind_cols와 bind_rows로 데이터 결합하기

bind 명령어는 말그대로 두개의 벡터를 결합하는 기능이다. 좀더 손쉬운 이해를 위해 간단한 데이터 셋 두개를 직접 만들어서 붙여보자. 2장을 복습할 겸 BTS 데이터를 다시 만들어보자. BTS 멤버 7명의(row 7개) 이름, 출생년도, 포지션의 3개의 변수(column 3개)로 구성되어 있는 bts1이라는 데이터 프레임을 생성해보았다. 다음으로는 각 멤버별 솔로곡의 이름을 문자형 변수로 지정한 bts2라는 데이터 프레임을 추가로 생성하였다. 두 데이터 프레임을 결합한다는 것은 변수를 한개 추가하는 것이기 때문에 bind_cols의 명령어를 사용한다. 결합해야하는 2개 이상의 데이터 프레임 이름을 심표를 활용하여 연결시켜준다.

```
#bts1 dataframe 만들기
btsname <-c("RM", "Jin", "Suga", "Jhope", "Jimin", "V", "JK")
btsyear <-c(1994, 1992, 1993, 1994, 1995, 1995, 1997)
btsposition <-c("rap", "vocal", "rap", "rap", "vocal", "vocal", "vocal")
bts1 <-data.frame(btsname, btsyear, btsposition, stringsAsFactors = FALSE)
#bts2 dataframe 만들기
soloSong <-c("her", "epiphany", "seesaw", "justDance", "serendipity", "singularity", "euphoria")
bts2<-data.frame(soloSong)
#bts1과 bts2를 횡으로 결합하기 (변수추가)
bind_cols(bts1, bts2)
```

##	btsname	btsyear	btsposition	soloSong
## 1	RM	1994	rap	her
## 2	Jin	1992	vocal	epiphany
## 3	Suga	1993	rap	seesaw
## 4	Jhope	1994	rap	justDance
## 5	Jimin	1995	vocal	serendipity
## 6	V	1995	vocal	singularity
## 7	JK	1997	vocal	euphoria

결과를 살펴보면 bts1 데이터 프레임에 soloSong이라는 변수가 잘 결합되어 있는 것을 볼 수 있다. 만일 새로 추가하는 변수에 missing 값이 있다면 어떻게 될까? NA가 포함되어 있는 bts3, bts4의 데이터 프레임을 추가로 생성하여 bind_cols를 사용하여 결합해보았다. 결과에서 볼 수 있듯이 NA가 포함되어 잘 연결되어 있는 것을 볼 수 있다.

```
singularity <-c(NA, "vocal", NA, NA, "vocal", "vocal", "vocal")
tear <-c("rap", NA, "rap", "rap", NA, NA, NA)
bts3<-data.frame(singularity)
bts4<-data.frame(tear)
bind_cols(bts1, bts2, bts3, bts4)->bts
```

bind_cols를 사용할때 유의할 점과 장점은 다음과 같다.

- bind_cols(dataframe1, dataframe 2,...)의 명령어 구조를 사용한다.
- NA가 포함되어 있는 셀들은 이상없이 결합된다.
- 데이터 프레임의 행(rows)의 갯수는 원칙적으로 서로 같아야 한다. 다만 행이

1개인 객체는 다른 데이터의 행 수에 맞게 재활용(recycle)될 수 있다. 예를 들어 `bts1`의 행의 갯수가 7개, `bts2`의 행의 갯수가 6개이면 결합되지 않는다.

두번째로 `rows`를 추가하는 방식은 `bind_rows`를 사용한다. 이를 위해 제8의 멤버로 `army`를 추가해보도록 하겠다. 이름에만 `army`를 추가하고 나머지 변수에는 `NA`값을 할당하였다. `bind_rows` 역시 `bind_cols`와 유사하게 괄호안에 데이터프레임명을 심표로 연결하면 된다.

```
army <-data.frame(btsname="army", btsyear=NA, btsposition=NA, soloSong=NA, singularity=NA,
bind_rows(bts, army)
```

##	btsname	btsyear	btsposition	soloSong	singularity	tear
## 1	RM	1994	rap	her	<NA>	rap
## 2	Jin	1992	vocal	epiphany	vocal	<NA>
## 3	Suga	1993	rap	seesaw	<NA>	rap
## 4	Jhope	1994	rap	justDance	<NA>	rap
## 5	Jimin	1995	vocal	serendipity	vocal	<NA>
## 6	V	1995	vocal	singularity	vocal	<NA>
## 7	JK	1997	vocal	euphoria	vocal	<NA>
## 8	army	NA	<NA>	<NA>	<NA>	<NA>

`bind_rows`는 `column`이 서로 동일하지 않아도 결합된다. 즉, 두개의 데이터 프레임이 서로 동일한 변수가 아니어도 결합이 된다는 의미이다. 예를 들어 `ARMY`의 국적이라는 변수를 하나 추가해보자. `army2`에는 `bts` 데이터 프레임에 없는 변수(`nations`)가 존재하지만 두 데이터 프레임이 종의 방향으로 잘 결합된 것을 확인할 수 있다.

```
army2 <-data.frame(btsname="army", btsyear=NA, btsposition=NA, soloSong=NA, singularity=NA,
bind_rows(bts, army2)
```

##	btsname	btsyear	btsposition	soloSong	singularity	tear	nations
## 1	RM	1994	rap	her	<NA>	rap	<NA>
## 2	Jin	1992	vocal	epiphany	vocal	<NA>	<NA>
## 3	Suga	1993	rap	seesaw	<NA>	rap	<NA>
## 4	Jhope	1994	rap	justDance	<NA>	rap	<NA>
## 5	Jimin	1995	vocal	serendipity	vocal	<NA>	<NA>
## 6	V	1995	vocal	singularity	vocal	<NA>	<NA>
## 7	JK	1997	vocal	euphoria	vocal	<NA>	<NA>
## 8	army	NA	<NA>	<NA>	<NA>	<NA>	worldwide

또한 id 변수를 추가하여 데이터프레임의 소스를 알 수 있는 방법도 있다. 여러개의 데이터 프레임을 붙이다보면 어떤 케이스가 어떤 데이터 프레임에서 왔는지를 알아야 하는 경우가 있다. column을 추가하는 경우에는 변수명에 기입이 가능하지만 row를 추가하는 경우에는 새로운 flag 변수를 만들어주는 방법이 필요하다.

```
bind_rows(list(data1=bts, data2=army), .id="flag")
```

##	flag	btsname	btsyear	btsposition	soloSong	singularity	tear
## 1	data1	RM	1994	rap	her	<NA>	rap
## 2	data1	Jin	1992	vocal	epiphany	vocal	<NA>
## 3	data1	Suga	1993	rap	seesaw	<NA>	rap
## 4	data1	Jhope	1994	rap	justDance	<NA>	rap
## 5	data1	Jimin	1995	vocal	serendipity	vocal	<NA>
## 6	data1	V	1995	vocal	singularity	vocal	<NA>
## 7	data1	JK	1997	vocal	euphoria	vocal	<NA>
## 8	data2	army	NA	<NA>	<NA>	<NA>	<NA>

3.4.2 join으로 데이터 결합하기

join 명령어를 사용하면 bind_cols와 bind_rows보다 복잡한 데이터 결합이 가능하다. join 명령어를 사용하기 위해서는 key 변수를 이해해야 한다. join 명령어는 열(column)간의 결합이다. 예를들어 첫번째 데이터에는 A,B,C라는 3개의 케이스에 name, X1, X2라는 세개의 변수가 붙어있다고 생각해보자. 두번째 데이터에는 A, B, D라는 3개의 케이스에 name, X2, X3라는 세 개의 변수가 붙어있다. 두 데이터를 결합한다는 것은 열(column)간의 결합이다. 이때 결합의 기준은 name이라는 변수일 것이다. 즉, 연구자는 A라는 사람의 관련변수가 횡의 방향으로 잘 붙길 바랄것이다. key 변수의 특징과 조건은 다음과 같다.

- join 명령어는 key변수를 기준으로 두 데이터를 결합하는 것이다.
- 두 데이터에는 결합의 기준이 되는 key 변수가 있어야 한다. 두 데이터에서 key 변수의 이름이 서로 달라도 by 옵션에서 대응관계를 지정할 수 있다.
- key 변수는 두 데이터의 관측치를 올바르게 대응시킬 수 있어야 한다. one-to-one 결합에서는 각 데이터에서 key가 고유해야 하지만, one-to-many 또는 many-to-one 결합에서는 한쪽 데이터의 key가 반복될 수 있다. 필요한 경우 두 개 이상의 변수를 조합하여 key로 활용할 수도 있다.

key 변수를 결정하게 되면 두개의 데이터를 어떠한 방식으로 결합할지 결정해야 한다. join의 결합방식은 크게 4가지가 있다.

3.4.2.1 left_join : 첫번째 데이터를 기준으로 결합

join에서 가장 기본적인 방식은 left_join이다. left_join은 첫번째 데이터(왼쪽 데이터)의 모든 관측값을 보존하고, 두번째 데이터는 첫번째 데이터와 결합될 수 있는 데이터만 살리는 방식이다.

좀더 명확한 이해를 위해 가상의 데이터 두개를 만들어 보자.

```
#data1 만들기
id <- c(1, 2, 3)
name <- c("RM", "jin", "suga")
solo <- c("her", "ephipany", "seesaw")
data1 <- data.frame(id, name, solo)
data1
```

	id	name	solo
## 1	1	RM	her
## 2	2	jin	ephipany
## 3	3	suga	seesaw

```
#data2 만들기
id <- c(1,2,3,4,5,6,7)
name <- c("RM", "jin", "suga", "jhope", "jimin", "v", "jk")
solo <- c("her", "epiphany", "seesaw", "justDance", "serendipity", "singularity", "euphoria")
position <-c("rap", "vocal", "rap", "rap", "vocal", "vocal", "vocal")
data2 <-data.frame(id, name, solo, position)
data2
```

	id	name	solo	position
## 1	1	RM	her	rap
## 2	2	jin	epiphany	vocal
## 3	3	suga	seesaw	rap
## 4	4	jhope	justDance	rap
## 5	5	jimin	serendipity	vocal
## 6	6	v	singularity	vocal

```
## 7 7 jk euphoria vocal

#left_join
data1 %>%
  left_join(data2, by= "id") -> left2
data1 %>%
  left_join(data2, by="id", suffix=c("_data1", "_data2")) -> left3
```

left_join 결과를 살펴보면 key 변수(id)를 기준으로, data1의 행(rows)만 남고 나머지 행들은 누락된 것을 볼 수 있다. 다시 말해 data1의 RM, jin, suga의 세 사람에게 해당되는 값만 살아있다. 특이한 것은 name, solo라는 두개의 변수가 data1과 data2에 중복되어 있기 때문에 이 변수들이 두번씩 포함되어 있다는 점이다. 데이터 소스를 확인하기 위해 dplyr에서는 자동으로 .x와 .y로 변수명을 변경하여 결합해준다. 만일 연구자가 원하는대로 중복 변수의 이름을 바꿔주고 싶다면 suffix=c(“_”, “”) 옵션을 사용한다.

- by=“key변수 이름”을 반드시 지정해준다
- 만일 key 변수의 이름이 data1과 data2에서 다르다면 by=c(“왼쪽데이터의 key변수 이름”=“오른쪽데이터의 key변수 이름”)의 옵션을 사용한다.
- 중복변수의 이름을 _data1과 _data2로 바꾸고 싶다면 suffix=c(“_data1”, “_data2”)의 옵션을 추가한다.
- 중복변수를 삭제하고 싶다면 select 함수를 사용하면 된다.

3.4.2.2 right_join :두번째 데이터를 기준으로 결합

left_join을 이해했다면 나머지 join 방식도 쉽게 이해할 수 있다. right_join은 left_join과 정 반대로 오른쪽 데이터의 행(rows)를 기준으로 데이터를 합친다.

```
data1 %>%
  right_join(data2, by="id")
```

##	id	name.x	solo.x	name.y	solo.y	position
## 1	1	RM	her	RM	her	rap
## 2	2	jin	ephipany	jin	epiphany	vocal
## 3	3	suga	seesaw	suga	seesaw	rap
## 4	4	<NA>	<NA>	jhope	justDance	rap
## 5	5	<NA>	<NA>	jimin	serendipity	vocal

```
## 6 6 <NA> <NA> v singularity vocal
## 7 7 <NA> <NA> jk euphoria vocal
```

right_join 결과를 살펴보면 data2의 행은 모두 살아있다. data1은 세명의 데이터만 있기 때문에 매칭되지 않는 행에서는 data1에서 가져오는 변수의 값이 모두 na로 표시되어 있는 걸 확인할 수 있다.

3.4.2.3 inner_join : 첫번째 데이터와 두번째 데이터의 교집합 행만 결합

inner_join은 첫번째 데이터와 두 번째 데이터에 공통으로 존재하는 key 값에 해당하는 행만 호출한다. inner_join을 보여주기 위해 data1에 하나의 열을 추가해보도록 하겠다.

```
army <- data.frame(id=8, name="army", solo=NA)
data1 <- bind_rows(data1, army)
data1
##   id name      solo
## 1  1  RM        her
## 2  2  jin ephipany
## 3  3  suga  seesaw
## 4  8  army      <NA>
data1 %>%
  inner_join(data2, by="id")
##   id name.x solo.x name.y solo.y position
## 1  1     RM     her     RM     her      rap
## 2  2    jin ephipany  jin ephipany  vocal
## 3  3    suga  seesaw    suga  seesaw    rap
```

data1에는 id 1,2,3,8이 포함되어 있고, data2에는 id 1,2,3,4,5,6,7이 포함되어 있다. 따라서 inner_join의 결과는 두 데이터의 교집합인 1,2,3만 포함되는 것을 확인할 수 있다.

3.4.2.4 full_join : 두 데이터의 모든 행을 결합

full_join은 두 데이터의 모든 행을 결합하는 형태이다. 데이터의 손실을 가장 최소화하나, 새롭게 추가되는 변수들에 값을 가지지 않기 때문에 na도 가장 많이 발생한다. 어떤 연구자들은 full_join으로 데이터를 결합한 후에 필요없는 변수나

케이스들을 filter와 select를 통해 drop하는 방식을 쓰기도 한다.

```
data1 %>%
  full_join(data2, by="id")
```

##	id	name.x	solo.x	name.y	solo.y	position
## 1	1	RM	her	RM	her	rap
## 2	2	jin	ephipany	jin	epiphany	vocal
## 3	3	suga	seesaw	suga	seesaw	rap
## 4	8	army	<NA>	<NA>	<NA>	<NA>
## 5	4	<NA>	<NA>	jhope	justDance	rap
## 6	5	<NA>	<NA>	jimin	serendipity	vocal
## 7	6	<NA>	<NA>	v	singularity	vocal
## 8	7	<NA>	<NA>	jk	euphoria	vocal

full_join 결과를 살펴보면 data1의 id 1,2,3,8과 data2의 id 1,2,3,4,5,6,7이 결합되어 전체 1~8의 id에 해당되는 행이 모두 호출된 것을 확인할 수 있다.

3.5 데이터를 타이디하게 만들기 : pivot_longer와 pivot_wider

지금까지 살펴본 데이터들은 이미 정렬이 되어 있는 tidy data이다. tidy data란 무엇인가? tidyverse를 만든 해들리 위컴¹의 정의에 따르면 tidy data는 다음과 같은 세개의 조건을 만족해야 한다.

- 변수마다 해당되는 열이 있어야 한다.
- 관측치마다 해당되는 행이 있어야 한다.
- 값마다 해당하는 하나의 셀이 있어야 한다.

엮어보면 간단한 규칙같지만, 이 세개의 조건은 서로 연관되어 있다. 이 셋 중 두 가지만 충족시키는 것은 불가능하기 때문이다. 좀 더 이해하기 쉬운 조건으로 요약해보면 다음과 같다.

- 변수는 열에 위치해야한다(행x)
- 관측치는 행에 위치해야 한다. (열x)

¹Wickham, H. & Grolemond, G. (2017). R for Data Science

- 하나의 셀에는 하나의 값만이 존재해야 한다(두개 이상의 정보가 결합되면 안된다)

개인적으로는 해들리위컴이 이야기하는 untidy data의 설명을 매우 좋아한다.

깔끔한 데이터셋은 모두 비슷하지만 엉망인 데이터셋은 자기 멋대로 엉망이다

이처럼 untidy data는 무궁무진한 방법으로 연구자를 괴롭힌다. 이를 해결하기 위해서는 tidyverse에 포함되어 있는 tidyr 패키지를 활용한다. tidyr에서 가장 중요한 함수는 pivot_longer와 pivot_wider이다. 함수명에서 확인할 수 있듯이 long data를 wide로, 또는 wide data를 long으로 바꾸는 함수이다. 엑셀을 사용해본 사람이라면 피벗(pivot)이라는 용어를 자주 들어봤을 것이다. 본래 피벗이란 “축을 중심으로 회전시키다”는 뜻을 갖고 있다. 데이터 피벗이란 어떠한 축을 중심으로 long format과 wide format으로 변환시킨다는 뜻이다.

- long format은 말그대로 세로 방향으로 길게 늘어진 형태의 데이터를 의미한다. 가장 대표적인 long format은 시계열 데이터이다. 10명의 사람의 3개년도 키를 long format으로 작성한다면 30개의 행(10명*3)과 3개의 변수(이름, 연도, 키)로 30 x 3의 데이터프레임으로 만들 수 있다.
- wide format은 연도 등과 같은 변수를 행이 아닌 열로 표기하는 방식이다. 10명의 사람의 3개년도 키를 wide format으로 작성한다면 10개의 행(10명)과 4개의 변수(이름, 1차년도키, 2차년도키, 3차년도 키)로 10 x 4의 데이터프레임으로 만들 수 있다.

long format과 wide format중 어떤 것이 더 좋을까? 이는 분석방식에 따라 다르다. 통상적으로 데이터 분석에는 long format을, 직관적으로 이해하기 쉬운 형태는 wide format을 사용하곤 한다.

보다 구체적인 이해를 위해 실제 데이터 셋을 하나 만들어보자. bts의 2016년부터 2019년까지의 앨범 판매량을 연도별로 기입한 자료를 두개의 데이터 셋으로 구성하였다. btsAlbumSales_wide는 wide format으로 작성되어 있다. 총 6개의 앨범의 4년간의 앨범 판매량이 횡의 방향으로 구성되어 있다. 흔히 볼수 있는 표의 모습이다. btsAlbumSales_long은 데이터 분석에 더 적합한 형태이다. 연도가 하나의 변수로 병합되고, 각 앨범의 연도별 판매량이 하나의 변수로 병합되어 있다.

```
btsAlbumSales_wide
```

```
##           album2 year2016 year2017 year2018 year2019
```

3.5. 데이터를 타이디하게 만들기 : PIVOT_LONGER와 PIVOT_WIDER 47

```
## 1      youngForever 368369    89761    129838    66344
## 2              wings 751301    93132    129790    66770
## 3  youNeverWalkAlone      NA    768492    111838    63580
## 4    loveYourself_Her      NA   1493443    333445    133534
## 5    loveYourself_Tear      NA        NA   1849537    122742
## 6 loveYourself_Answer      NA        NA   2197808    154676
```

btsAlbumSales_long

```
##           album year  sales
## 1      youngForever 2016 368369
## 2      youngForever 2017   89761
## 3      youngForever 2018 129838
## 4      youngForever 2019   66344
## 5              wings 2016 751301
## 6              wings 2017   93132
## 7              wings 2018 129790
## 8              wings 2019   66770
## 9  youNeverWalkAlone 2017  768402
## 10 youNeverWalkAlone 2018  111838
## 11 youNeverWalkAlone 2019   63580
## 12    loveYourself_Her 2017 1493443
## 13    loveYourself_Her 2018   333445
## 14    loveYourself_Her 2019   133534
## 15    loveYourself_Tear 2018 1849537
## 16    loveYourself_Tear 2019   122742
## 17 loveYourself_Answer 2018 2197808
## 18 loveYourself_Answer 2019   154676
```

3.5.1 길게 만들기 : pivot_longer 활용하기

long format과 wide format의 차이를 이해했다면, pivot_longer 함수를 활용해 데이터를 길게 만들어보자. btsAlbumSales_wide를 long format으로 만들기 위해서는 다음의 파라미터를 이해해야 한다.

- cols : 현재는 변수로 지정되어 있지만 값(value)으로 변환할 column 이름 (지정방식은 select() 함수와 동일). 이 데이터에서는 year2016~year2019이다.

- `names_to` : 값으로 변환될 자료들의 변수 이름. 이 데이터에서는 `year`이다.
- `values_to` : wide하게 분산되어 있는 값들의 변수 이름. 이 데이터에서는 `sales`이다.

```
btsAlbumSales_wide %>%
  tidyr::pivot_longer(cols=year2016:year2019, names_to="year", values_to="sales") ->long
long
## # A tibble: 24 x 3
##   album2          year    sales
##   <chr>         <chr>   <dbl>
## 1 youngForever  year2016 368369
## 2 youngForever  year2017  89761
## 3 youngForever  year2018 129838
## 4 youngForever  year2019  66344
## 5 wings        year2016 751301
## 6 wings        year2017  93132
## 7 wings        year2018 129790
## 8 wings        year2019  66770
## 9 youNeverWalkAlone year2016    NA
## 10 youNeverWalkAlone year2017 768492
## # i 14 more rows
```

long format으로 바꾼 결과를 살펴보면 `year` 변수에 연도가, `sales` 변수에 각연도 별 앨범판매량이 잘 결합된것을 확인할 수 있다. 하지만 `year` 변수의 값이 wide format의 변수명으로 들어가 있기 때문에 `year2016`로 표기되어 있어 수정이 필요하다. 여러가지 방식으로 수정이 가능하지만 여기서는 `str_replace()` 함수를 한번 활용해보도록 하겠다. `str_replace`는 `stringr` 패키지 안에 있는 함수이다. 패키지명에서 짐작할 수 있듯이 `stringr`은 문자열 변수를 수정하는데 활용되는 패키지이다. `str_replace`는 종종 사용되는 함수인데 특정 문자열을 없애거나 다른 문자로 대체하는데 쓰인다. 특정 변수의 값들의 문자열을 다른 문자로 대체하거나 없애고 싶으면 `mutate()`와 `str_replace()`를 결합하면된다. 복잡해보이지만 찬찬히 분해해보면 그리 어렵지 않다.

- `mutate(새로운변수=바뀌는 내용)` : 여기서는 `year` 변수를 `str_replace` 함수를 활용해서 바꾸라고 제시되어 있다.
- `str_replace(변수명, “바뀌기전 문자”, “바뀐후 문자”)` : 여기서는 `year` 문자를

3.5. 데이터를 타이디하게 만들기 : PIVOT_LONGER와 PIVOT_WIDER 49

없애는 것이다. 큰따옴표 안에 아무것도 없는 것을 확인하라

```
btsAlbumSales_wide %>%
  pivot_longer(cols=year2016:year2019, names_to="year", values_to="sales") %>%
  mutate(year=str_replace(year, "year", ""))>long_replace
long_replace
## # A tibble: 24 x 3
##   album2          year  sales
##   <chr>         <chr> <dbl>
## 1 youngForever  2016  368369
## 2 youngForever  2017   89761
## 3 youngForever  2018  129838
## 4 youngForever  2019   66344
## 5 wings        2016  751301
## 6 wings        2017   93132
## 7 wings        2018  129790
## 8 wings        2019   66770
## 9 youNeverWalkAlone 2016      NA
## 10 youNeverWalkAlone 2017  768492
## # i 14 more rows
```

3.5.2 넓게 만들기 : pivot_wider 활용하기

pivot_wider는 pivot_longer의 반대이다. 관측값이 여러 행에 걸쳐있을때 이를 열로 변환하는 방식이다. pivot_wider는 여기서는 두개의 주요 파라미터를 이해하면 된다.

- names_from: 변수 이름을 포함하는 열, 여기서는 year 이다.
- values_from: 새로 생겨나는 변수별 값이 포함되는 열, 여기서는 sales이다.

```
btsAlbumSales_long %>%
  pivot_wider(names_from=year, values_from = sales)>wide
wide
## # A tibble: 6 x 5
##   album          `2016` `2017` `2018` `2019`
##   <chr>         <dbl> <dbl> <dbl> <dbl>
## 1 youngForever  368369  89761 129838  66344
```

## 2 wings	751301	93132	129790	66770
## 3 youNeverWalkAlone	NA	768402	111838	63580
## 4 loveYourself_Her	NA	1493443	333445	133534
## 5 loveYourself_Tear	NA	NA	1849537	122742
## 6 loveYourself_Answer	NA	NA	2197808	154676

3.6 패널데이터를 활용한 데이터 전처리 실습

지금까지는 dplyr 함수의 이해를 돕기 위해 small dataset을 활용해보았다. 실제 연구 장면에서는 이보다 사이즈가 큰, 즉 1000개이상의 관측치와 100개이상의 variable을 갖고 있는 데이터셋을 만지게 될것이다. 여기서는 한국직업능력연구원 에서 수행하고있는 패널데이터인 인적자본기업패널(Human Capital Corporate Panel)을 활용해 데이터의 결합과 전처리 과정을 수행해보도록 하겠다. 처음 데이터를 만지다보면 데이터 다운로드후 불러오기 부터 난항을 겪는 경우가 많다. 최대한 스텝바이스텝으로 독자들의 눈높이에 맞춰 전처리 과정을 수행해보도록 하겠다. 이장은 반드시 함께 실습을 해보는 것을 권한다.

3.6.1 데이터의 이해

데이터 전처리 전에 수행해야 할 첫번째 단계는 데이터의 이해이다. 보통 발행기관의 홈페이지에서 상세한 내용을 제공한다. 한국직업능력연구원의 인적자본기업패널(HCCP) 소개 페이지를 보면 다음의 내용이 적혀있다.

1. HCCP I 차 WAVE는 2005년부터 1차년도 조사를 시작하여 격년마다 추적 조사를 실시하였으며 2017년 7차년도를 끝으로 조사를 종료하였습니다.

1번의 내용을 읽으면 여러분은 다음의 생각을 할것이다. “격년으로 조사한 7개의 데이터 셋 존재하겠군”, “7개의 데이터 셋에는 기업별 ID 변수가 있어서, 동일한 기업의 연도별 데이터를 횡으로 결합할 수 있다”, “7번 조사에 모두 참여한 기업도 있지만, 중간중간 빠진 기업도 있겠군”, “14년의 기간동안 없어진 기업도 있을텐데 표본 대체가 이루어졌을 까?”

2. HCCP는기업단위 패널조사입니다. HCCP 조사의 가장 큰 특징은 조사 기본 단위가 '기업'이라는 점과 해당 기업 및 근로자를 함께 조사한다는 것입니다.

2번의 내용을 읽으면 이 데이터의 단위가 “기업”이라는 점을 확인할 수 있다. 꼬리를 무는 생각은 다음과 같을 것이다. “기본적으로 기업단위로 데이터가 있겠군”, “기업과 근로자를 함께 조사하였다고 하니, 기업데이터와 근로자 데이터가 분리되어 있겠군”, “근로자데이터와 기업데이터를 붙이기 위해 기업과 해당 기업재직자 데이터는 기업 ID 등으로 결합할 수 있겠군”. 또 다음의 질문도 생길 것이다. “1개의 기업당 몇명의 근로자를 조사했을 까?”

추가적인 질문에 대한 답을 찾기 위해서는 해당데이터의 “조사설계” 자료를 살펴 보도록 하자.

3. HCCP의 모집단은 우리나라에서 사업 활동을 하고 있는 모든 기업을 대상으로 합니다. HCCP의 조사 모집단은 NICE평가정보(주)의『KIS 기업 Data(2005)』 개요 정보에 속한 기업 중 근로자 수 100인 이상이면서 일반 기업 이상입니다. 이에 따라 조사모집단 수는 1,899개이며, 조사에서 제외된 산업은 인적자본의 축적이 크게 의미가 없는 산업(1차산업과 제조업 일부 산업 등)입니다.

3번의 내용은 조사설계를 소개하는 웹사이트의 일부이다. HCCP조사 목적에 따라 100인 미만의 소기업들은 제외되고, 인적자본 축적과 관련이 없는 산업들이 빠져 1,899개의 기업이 모집단인 것을 확인 할 수 있다.

4. 기업의 표본추출을 위해 층화표본추출을 하였으며, 층화변수는 산업(대분류 3개 산업, 중분류 16개 산업), 규모(100~299명, 300~999명, 1,000~1,999명, 2,000명 이상), 기업형태(상장, 코스닥, 등록/외감/일반)를 사용하였다. 표본은 450개 기업이며, 흡수합병, 폐업 등으로 조사가 불가능한 경우에는 동일 업종, 동일 규모의 기업으로 표본을 대체하였다.

4번의 내용은 표본이 450개 기업이며, 산업, 규모, 기업형태를 고려해서 층화표집했다는 내용이다. 우리가 예상한것처럼 조사가 불가능한 경우 표본 대체가 이루어진 것을 확인할 수 있다.

5. HCCP의 근로자 조사는 표본추출된 기업의 팀 단위로 팀장 및 팀원을 산업별/기업규모별 선정 기준에 따라 대상자를 선정하여 조사하였습니다. 근로자 조사는 팀 단위로 팀장 및 팀원을 조사하였습니다.
 - 제조업은 관리직(팀장, 팀원)과 생산직(감독자, 근로자) 조사
 - 금융업은 관리직(팀장, 팀원)과 서비스직(팀장, 팀원) 조사

- 비금융서비스업은 관리직(팀장, 팀원)과 핵심 전문직(팀장, 팀원) 조사

5번은 기업조사와 별도로 해당 기업에 재직중인 근로자를 조사하는 방법을 설명하고 있다. 근로자 조사는 팀단위로 조사하였으며 팀장과 팀원 또는 감독자와 근로자와 같이 근로자 조사 안에서도 일종의 hierarchy가 있는 것을 확인할 수 있다.

6. 관리직 팀장은 기업 규모를 고려하여 조사 기업 당 5~10명 조사, 관리직 팀원은 기업 규모를 고려하여 조사 기업 당 12~16명 조사, 생산직/서비스직/핵심전문직 팀장(감독자)은 기업 규모를 고려하여 조사 기업 당 2~5명 조사, 생산직/서비스직/핵심전문직 팀원(근로자)은 기업 규모를 고려하여 조사 기업 당 10~25명 조사

6번의 내용은 팀장(또는 감독자)와 팀원(또는 근로자)의 조사규모를 보여주고 있다. 기업규모와 산업유형에 따라 근로자 조사 규모가 서로 다른것을 알 수 있다.

이와 같이 조사에 대한 간략한 개요를 살펴보는 것은 데이터 구조를 파악하는데 큰 도움을 준다. 다짜고짜 데이터를 다운받거나 설문지부터 확인하는 것은 좋은 방법이 아니다. 조사 개요를 숙지한 이후에는 조사기관에서 제공하는 user guide를 살펴보는 것이 필요하다. 유저 가이드는 조사 개요보다 더 상세한 정보를 제공하고 있는데, 특히 샘플 사이즈, 표본탈락률 등과 같은 기본 정보와 함께 설문지의 구조 및 흐름을 확인하는데도 매우 큰 도움이 된다.

3.6.2 데이터의 불러오기(import)

대략적으로 HCCP 데이터에 대해 이해를 하였으니, 이제 본격적으로 데이터를 다운받아 열어보자. 이 장에서는 3차년도와 4차년도 자료를 횡으로 결합해보도록 하겠다. 현재 작업중인 r project 폴더에 3차년도와 4차년도의 기업자료와 근로자데이터 총 4개를 담아보도록 하겠다. 통상 조사기관에서는 spss, sas, txt의 세 종류의 포맷으로 제공해주는데, txt 파일을 사용하도록 하겠다. 아래의 파일을 다운받아 r project 폴더에 넣어보자.

- HCCP_Head_3th.txt
- HCCP_Head_4th.txt
- HCCP_Work_3th.txt
- HCCP_Work_4th.txt

txt 파일을 불러오는 방법은 read.delim()이다. 현재 프로젝트 안에 파일이 있다면 번거롭게 directory를 설정하지 않아도, 파일명만을 기입하면 된다.

```
company_3 <- read.delim("HCCP_Head_3th.txt", header = TRUE)
company_4 <- read.delim("HCCP_Head_4th.txt", header = TRUE)

worker_3 <- read.delim("HCCP_Work_3th.txt", header = TRUE)
worker_4 <- read.delim("HCCP_Work_4th.txt", header = TRUE)
```

위 코드를 그대로 실행하면 HCCP_Head_4th.txt를 불러오는 과정에서 오류가 발생한다. 이 파일만 UTF-16 little-endian 방식으로 저장되어 있기 때문이다. 인코딩(encoding)은 한글이나 알파벳 같은 문자를 컴퓨터가 처리할 수 있도록 변환하는 규칙이다. 한글이 포함된 외부 자료를 불러올 때 인코딩 차이로 오류가 자주 발생하므로, 파일 형식을 확인한 뒤 fileEncoding을 지정한다. 이 책의 PDF에는 학습에 불필요한 원시 오류 메시지가 나타나지 않도록 위 실패 예제를 실행하지 않는다.

```
company_3 <- read.delim("HCCP_Head_3th.txt", header = TRUE)
company_4 <- read.delim(
  "HCCP_Head_4th.txt",
  header = TRUE,
  fileEncoding = "UTF-16LE"
)
worker_3 <- read.delim("HCCP_Work_3rd.txt", header = TRUE)
worker_4 <- read.delim("HCCP_Work_4th.txt", header = TRUE)
```

성공적으로 파일불러오기(import)를 하였다면, 다음단계는 파일을 탐색하는 것이다. Environment 창에 company_3, 4, worker_3,4가 로딩된 것이 보이는가? 이는 txt파일을 R의 dataframe으로 성공적으로 불러왔음을 의미한다. 우선 근로자 데이터를 살펴보자. 유저가이드 상에는 ID 구조를 다음과 같이 안내하고 있다.

- id1 : 기업 ID, 4자리, 데이터 연결작업시 key 변수로 활용
- id2 : 사업장 ID, 1자리 (변수값 1=첫번째 작업장)
- id3 : 팀 ID, 3자리 (연구개발=100, 영업=200, 관리=300, 생산관리/기술=400, 상품개발=500, 자금운용=600, 생산직=700, 서비스직=800, 핵심전문직=900)
- id4: 개인 ID, 2자리(팀장=0, 팀원은 1부터 일련번호)

```
worker_3 %>%
  count(W3_id1)
worker_3 %>%
```

```
count(W3_id2)
worker_3 %>%
  count(W3_id3)
```

위 코드를 실행하면 W3_id1을 찾을 수 없다는 오류가 발생한다. Environment 창에서 변수명을 다시 살펴보면 첫 번째 변수는 w3_id1, 두 번째 변수는 W3_id2처럼 대문자와 소문자가 일관되지 않다. 이런 사소한 문제가 실제 데이터 전처리를 어렵게 만든다. 변수명을 하나씩 수정할 수도 있지만, 여기서는 네 데이터 프레임의 모든 변수명을 소문자로 통일한다. dplyr의 `rename_with(tolower)`를 사용하면 일괄 변환할 수 있다.

```
worker_3 %>%
  rename_with(tolower)->worker_3
worker_4 %>%
  rename_with(tolower)->worker_4
company_3 %>%
  rename_with(tolower)->company_3
company_4 %>%
  rename_with(tolower)->company_4
```

ID관련 변수 4개의 빈도를 확인해보니, 이제 정상적으로 출력이 된다. id1은 기업ID로 473개의 기업별로 근로자 데이터가 2~수십개 존재한다. id2는 사업장(영업소 등)으로 0,1,2,3의 값이 존재한다. id3은 팀 ID 이다. 세자리 수 첫번째 자리의 수가 팀의 직무를 나타낸다. 예를 들어 101, 102, 103의 사례수가 각각 1103, 45, 14로 1162개이므로 연구개발 팀(id3=100번대)에 속한 근로자수가 1162명인것을 알 수 있다.

기업 ID: 앞의 10개 기업만 확인

```
worker_3 %>%
  count(w3_id1) %>%
  slice_head(n = 10)

##      w3_id1  n
## 1         1 28
## 2         2 25
## 3         5 31
## 4         6 25
```

```
## 5      7 54
## 6      8  3
## 7      9 43
## 8     10 35
## 9     11 17
## 10     12  9
# 사업장 ID
worker_3 %>%
  count(w3_id2)
##   w3_id2    n
## 1      0 8225
## 2      1 1363
## 3      2  376
## 4      3   55
# 팀 ID 중 연구개발 직무(100번대)
worker_3 %>%
  count(w3_id3) %>%
  filter(w3_id3 >= 100 & w3_id3 < 200)
##   w3_id3    n
## 1    101 1103
## 2    102   45
## 3    103   14
# 개인 ID: 앞의 10개 값만 확인
worker_3 %>%
  count(w3_id4) %>%
  slice_head(n = 10)
##   w3_id4    n
## 1      0 3143
## 2      1 1868
## 3      2 1682
## 4      3 1455
## 5      4 1172
## 6      5  560
## 7      6   80
```

```
## 8      7    32
## 9      8    14
## 10     9     5
```

3.6.3 필요한 변수만 선택(select)

좀더 간명하게 데이터를 확인하기 위해 필요한 변수만 선택해서 남겨보도록 하겠다. 편의상 이 장에서는 아래의 변수만을 선택해보자. 3차년도 근로자 기준으로는 아래와 같은 36개의 변수만을 select 해보자. 4차년도도 변수명 w3를 w4로 바꾼후 select 해보자.

- ID변수 : w3_id1(기업id), w3_id3(팀id), w3_id4(팀원id)
- background 변수 : w3_ind1(산업분류), w3_team(팀분류), w3_posit(팀장여부), w301_01, w301_02(현직장입사시기년, 월), w303_02(현재직급), w3_sex(성별), w3_birthy(출생년도), w3_marr(혼인상태), w3_edu
- HR 부서 역할 : w306_01, w306_02, w306_03, w306_04, w306_05, w306_06, w306_07, w306_08
- 교육훈련방법별 참여현황 : w311_01, w311_02(집체사내훈련), w311_05, w311_06(인터넷학습)
- 교육훈련 참여일수 : w312
- 만족도 : w329_01(일), w329_02(임금), w329_03(인간관계), w329_04(전반)
- 근로조건 : w333(정규직여부), w335(노동조합여부), w336_01, w336_02(주당정규/초과근로시간), w337_01, w337_02(연간, 월간 근로소득)

```
worker_3 %>%
  select(
    w3_id1, w3_id3, w3_id4,
    w3_ind1, w3_team, w3_posit,
    w301_01, w301_02, w303_02,
    w3_sex, w3_birthy, w3_marr, w3_edu,
    w306_01, w306_02, w306_03, w306_04,
    w306_05, w306_06, w306_07, w306_08,
    w311_01, w311_02, w311_05, w311_06,
    w312,
    w329_01, w329_02, w329_03, w329_04,
```

```

w333, w335,
w336_01, w336_02,
w337_01, w337_02
) -> worker_3_se

worker_4 %>%
  select(
    w4_id1, w4_id3, w4_id4,
    w4_ind1, w4_team, w4_posit,
    w401_01, w401_02, w403_02,
    w4_sex, w4_birthy, w4_marr, w4_edu,
    w406_01, w406_02, w406_03, w406_04,
    w406_05, w406_06, w406_07, w406_08,
    w411_01, w411_02, w411_05, w411_06,
    w412,
    w429_01, w429_02, w429_03, w429_04,
    w433, w435,
    w436_01, w436_02,
    w437_01, w437_02
  ) -> worker_4_se

```

나중에 근로자 데이터와 기업 데이터를 결합할 예정이므로 기업 데이터도 필요 변수만 select 해보자. 4차년도 기업데이터에는 역량수준 문항(c3c04_02_01, c3c04_02_02, c3c04_02_03)이 존재하지 않으므로 누락시켜야 한다. 또한 3차년도 조사 참여여부 문항(a_3rd)을 추가한다.

- ID변수 : c3_id1(기업 ID)
- background 변수 : c3_ind1, c3_ksic1(산업대분류), c3_scale(기업규모), c3a02_07(최우선경영방침)
- 근로자 관련 : c3b02_01_01(정규직+비정규직인원), c3b02_01_02(남자 정규직인원), c3b02_01_03(여자정규직인원), c3b02_01_04(전체 비정규직 인원), c3b02_02_01(정규직인원), c3b02_02_02(30세 미만정규직), c3b02_02_05(50세 이상 인원), c3b02_03_02(고졸이하), c3b02_03_03(고졸이하 인원)전문대졸), c3b02_03_04(대졸이하), c3b02_05_1(10년이상 사무직근로자), c3b02_05_02(10년이상 생산직 근로자)

- HRD 관련 : c3c01_01(HRD 담당조직여부), c3c01_01_01(전담자 여부), c3c01_02(hrd 계획 수립여부), c3c01_03(자체교육프로그램 개발여부), c3c01_06_01(집체식 교육 실시여부), c3c01_06_02(집체식 교육연인원), c3c02_03_01, c3c02_03_02, c3c02_03_03, c3c02_03_04, c3c02_03_05(HRD 효과)
- 역량수준 : c3c04_02_01, c3c04_02_02, c3c04_02_03

```
company_3 %>%
```

```
select(
  c3_id1, c3_ind1, c3_ksic1, c3_scale,
  c3a02_07,
  c3b02_01_01, c3b02_01_02, c3b02_01_03, c3b02_01_04,
  c3b02_02_01, c3b02_02_02, c3b02_02_05,
  c3b02_03_02, c3b02_03_03, c3b02_03_04,
  c3b02_05_01, c3b02_05_02,
  c3c01_01, c3c01_01_01, c3c01_02, c3c01_03,
  c3c01_06_01, c3c01_06_02,
  c3c02_03_01, c3c02_03_02, c3c02_03_03,
  c3c02_03_04, c3c02_03_05,
  c3c04_02_01, c3c04_02_02, c3c04_02_03
) -> company_3_se
```

```
company_4 %>%
```

```
select(
  c4_id1, c4_ind1, c4_ksic1, c4_scale,
  c4a02_07,
  c4b02_01_01, c4b02_01_02, c4b02_01_03, c4b02_01_04,
  c4b02_02_01, c4b02_02_02, c4b02_02_05,
  c4b02_03_02, c4b02_03_03, c4b02_03_04,
  c4b02_05_01, c4b02_05_02,
  c4c01_01, c4c01_01_01, c4c01_02, c4c01_03,
  c4c01_06_01, c4c01_06_02,
  c4c02_03_01, c4c02_03_02, c4c02_03_03,
  c4c02_03_04, c4c02_03_05,
  a_3rd
```

```
) -> company_4_se
```

3.6.4 기업 데이터 결합(one-to-one match)

이제 기업 데이터간의 결합을 시도해보자. 데이터 결합시 첫째, key변수가 무엇인지, 둘째, left, right, inner, full join 가운데 어떠한 방식으로 결합할지를 고려해야 한다. key 변수란 두 개의 데이터를 연결시킬때 기준이 되는 변수다. 예를들어 3차년도 기업데이터(company_3_se)에서 A회사와 4차년도 기업데이터(company_4_se)에서 A회사를 같은 열(row)로 연결시켜주는 역할을 하는 것이다. 따라서 key 변수는 각 데이터의 관측치마다 고유값을 가져야 한다. 쉽게 설명한다면 기업마다 서로 다른 값을 가져야 한다. HCCP의 기업데이터에서 기업을 식별하는 데 쓰이는 변수는 c3_id1과 c4_id1이다.

```
company_3_se %>%
  count(c3_id1) %>%
  filter(n>1)
## [1] c3_id1 n
## <0 rows> (or 0-length row.names)

company_4_se %>%
  count(c4_id1) %>%
  filter(n>1)
## [1] c4_id1 n
## <0 rows> (or 0-length row.names)
```

table(company_3_se\$c3_id1)의 명령어를 사용하면 기업id의 빈도를 모두 확인할 수 있다.그러나 기업 갯수가 너무 많기 때문에 혹시 하나의 기업 id에 두개 이상의 관측치(row)가 연결되었는지 확인하기는 어렵다. 이 경우 dplyr의 count와 filter의 조합을 활용하여 손쉽게 활용이 가능하다. c4_id1변수의 값별 빈도를 확인하고, 이 중 빈도가 1 초과인 데이터만 불러오라는 뜻이다. 결과를 보면 두 데이터 모두 빈도가 1 초과인 데이터는 없는 것으로 나타났다. c3_id1과 c4_id1이 각각의 데이터의 관측치의 고유값으로 역할하기 때문에 이 변수들을 key 변수로 활용해보자. 데이터를 붙이기 전에 간단히 environment 창에서 두 개의 데이터의 관측치 갯수를 확인해보자. 3차년도 기업자료는 473개의 관측치(기업수), 4차년도 기업자료는 500개의 관측치(기업수)를 갖고 있다. 직관적으로 생각해보면 3가지 종류의 기업이

있을 것 같다. 1) 3차년도와 4차년도에 공통적으로 존재하는 기업, 2) 3차년도에만 존재하는 기업, 3) 4차년도에만 존재하는 기업. 이들 기업중에 어떤것을 택할지는 연구자의 연구관심에 따라 달려 있다. 이에 따라 `left_join`(3차년도 기업 모두 포함), `right_join`(4차년도 기업 모두 포함), `inner_join`(3/4차년도 공통 기업), `full_join`(3차+4차 모두 포함) 중 하나를 선택하도록 한다.

여기서는 `full_join`을 먼저 수행해보도록 하겠다. 위의 과정을 마치면 데이터 결합은 매우 간단하다. 만일 두 데이터의 key변수의 변수명이 서로 다르다면 c(“데이터X의 key변수명”=“데이터Y의 key변수명”)의 옵션을 사용하면된다. `full_join`을 통해 결합된 데이터(`company_full`)을 좀더 살펴보자. 3차년도 데이터는 31개의 변수, 4차년도 데이터는 29개의 변수가 있었다. 결합된 데이터는 31+29=60개의 변수가 아니라, 하나가 빠진 59개의 변수가 존재한다. 그 이유는 데이터 X의 key 변수(`c3_id1`)로 통합되고, 데이터 Y의 key 변수(`c4_id1`)는 삭제되기 때문이다. 관측치는 어떻게 결합되어 있는지 확인해보자. 별도의 flag 변수를 만들지 않았기 때문에 3차년도와 4차년도에서 na값이 없는 `c3_ind1`과 `c4_ind1` 변수를 활용해서 확인해보자. 이때 사용할 수 있는 구문은 `group_by`와 `summarise(count=n())`이다. 결과를 살펴보면 3차년도와 4차년도 모두 존재하는 기업의 수는 410개(288+36+86)이다. 3차년도에만 존재하는 기업의 수는 63개(48+1+14), 4차년도에만 존재하는 기업의 수는 90개(81+1+8)이다.

```
#데이터 결합
# key 변수 이름 통일 및 연도별 flag 생성
company_3_se <- company_3_se %>%
  rename(company_id = c3_id1) %>%
  mutate(in_3rd = TRUE)
company_4_se <- company_4_se %>%
  rename(company_id = c4_id1) %>%
  mutate(in_4th = TRUE)
# flag 확인
company_3_se %>%
  count(in_3rd)
##   in_3rd    n
## 1   TRUE 473
company_4_se %>%
  count(in_4th)
```

```
##   in_4th   n
## 1   TRUE 500
# full join
company_full <- company_3_se %>%
  full_join(company_4_se, by = "company_id") %>%
  mutate(
    in_3rd = replace_na(in_3rd, FALSE),
    in_4th = replace_na(in_4th, FALSE)
  )
# 연도별 기업 현황 확인
company_full %>%
  count(in_3rd, in_4th)
##   in_3rd in_4th   n
## 1  FALSE   TRUE  90
## 2   TRUE  FALSE  63
## 3   TRUE   TRUE 410
```

inner join 작업도 수행해보자. inner_join은 두 데이터에 공통으로 존재하는 key만 남긴다. 따라서 3차년도와 4차년도에 모두 존재하는 기업만 남게 된다. nrow()로 관측치 수를 확인하면 410개의 기업이 남아있는 것을 확인할 수 있다

```
#inner join
company_inner <- company_3_se %>%
  inner_join(company_4_se, by = "company_id")
#공통기업 수 확인
nrow(company_inner)
## [1] 410
```

이밖에도 한쪽에만 존재하는 기업만 데이터에 포함시키는 anti_join()도 있다.

```
# 3차년도 데이터에만 있는 관측치만 포함
company_3_only <- company_3_se %>%
  anti_join(company_4_se, by = "company_id")
nrow(company_3_only)
## [1] 63
# 4차년도 데이터에만 있는 관측치만 포함
```

```
company_4_only <- company_4_se %>%
  anti_join(company_3_se, by = "company_id")
nrow(company_4_only)
## [1] 90
```

3.6.5 근로자-기업 데이터 결합(many-to-one match)

마지막으로 수행할 데이터 결합은 근로자와 기업을 연결하는 것이다. HCCP 데이터의 구조를 떠올려보면 기업 1개당 다수의 근로자 데이터가 존재한다. 두개의 데이터를 결합하려면 어떠한 key변수가 사용될까? 당연히게도 근로자 데이터의 기업 ID인 w3_id1과 기업 데이터의 기업 ID인 c3_id1일 것이다. 이를 데이터 구조로 생각해보면 데이터 X(근로자 데이터)의 여러 행이 데이터 Y(기업데이터)의 한 행과 결합된다는 것을 의미한다. 근로자 데이터를 기준으로 보면 이러한 결합을 many-to-one match라고 한다. 이러한 방식 역시 join 함수를 사용하면 된다. 앞 절에서 기업데이터의 key 변수(c3_id1, c4_id1)를 company_id로 통일하였기 때문에 c3_id1대신 company_id를 key 변수로 설정하여 조인해보자.

다만, one-to-one match 방식에 비해 결합된 결과물을 잘 살펴볼 필요가 있다. group_by()와 summarise(count=n()) 명령어를 활용하여 주요 변수의 빈도를 확인해본 결과 결합이 잘 되어 있는 것을 확인할 수 있다.

```
# 근로자-기업 데이터 결합
worker_company <- worker_3_se %>%
  left_join(company_3_se, by = c("w3_id1" = "company_id"))
# 결합 전후 관측치 수 확인
nrow(worker_3_se)
## [1] 10019
nrow(worker_company)
## [1] 10019
# 결합 결과 일부 확인
worker_company %>%
  select(
    w3_id1, w3_id3, w3_id4,
    w3_ind1, c3_ind1, c3_scale
  ) %>%
  slice_head(n = 10)
```

##	w3_id1	w3_id3	w3_id4	w3_ind1	c3_ind1	c3_scale
## 1	1	101	0	1	1	1
## 2	1	101	1	1	1	1
## 3	1	101	2	1	1	1
## 4	1	101	3	1	1	1
## 5	1	101	4	1	1	1
## 6	1	101	5	1	1	1
## 7	1	101	6	1	1	1
## 8	1	102	0	1	1	1
## 9	1	102	1	1	1	1
## 10	1	102	2	1	1	1

제 4 장

데이터 시각화

4.1 들어가며

그래프는 강력하다. 여러 개의 표보다 잘 그린 그래프 하나가 더 선명한 메시지를 전달하기도 한다. 그래프는 연구 결과를 제시할 때뿐 아니라 데이터 분석을 시작하는 단계에서도 필요하다. 관심 변수의 분포와 이상치(outlier)를 살펴보고, 집단 간 차이나 변수 간 관계를 탐색하면 표만으로는 발견하기 어려운 패턴을 확인할 수 있다. 4장에서는 R의 대표적인 장점 중 하나인 데이터 시각화를 살펴본다.

R의 기본 그래픽 함수로도 간단한 그래프를 그릴 수 있다. 그러나 여러 정보를 체계적으로 조합하고 일관된 형태의 그래프를 만들려면 별도의 패키지가 유용하다. 3장에서 다룬 tidyverse의 핵심 패키지인 ggplot2가 대표적이다. 이 장에서는 변수의 개수와 유형에 맞는 그래프를 선택하고, ggplot2로 분포와 관계를 표현하는 방법을 익힌다.

4.2 ggplot2의 설치 및 소개

4.2.1 ggplot2 설치

ggplot2는 단독으로 설치할 수도 있고 tidyverse와 함께 설치할 수도 있다. 패키지 설치의 컴퓨터마다 한 번만 수행하며, 다음 코드는 R 콘솔에서 실행한다.

```
install.packages(c("tidyverse", "ragg"))
```

설치한 패키지는 R을 새로 시작할 때마다 `library()`로 불러온다. 이 책에서는 데이터 전처리 예제와 연결하기 위해 `tidyverse` 전체를 불러온다. `ragg`는 그래프 파일을 선명하게 만들고 한글 글꼴을 안정적으로 표시하는 데 사용한다. 설치되어 있지 않은 환경에서는 R의 기본 그래픽 장치를 사용한다.

4.2.2 ggplot2의 작동 원리

`ggplot2`는 그래프를 구성하는 요소를 문법처럼 조합한다. 데이터와 변수를 지정 한 뒤 점, 선, 막대와 같은 기하 객체를 층(layer)으로 쌓는 방식이다. 층을 투명한 도화지라고 생각하면 이해하기 쉽다. 첫 번째 층에 점을 그리고, 그 위에 추세선과 주석을 차례로 더할 수 있다.

`ggplot2` 그래프의 기본 구성 요소는 다음과 같다.

- 사용할 데이터(`data`)
- 축이나 색, 모양 등에 연결할 변수(`aes()`)
- 점, 선, 막대처럼 관측값을 표현할 기하 객체(`geom_*()`)

여기에 다음 요소를 선택적으로 추가할 수 있다.

- 통계적 변환(`stat_*()`)
- 축과 범례의 척도(`scale_*()`)
- 좌표계(`coord_*()`)
- 그래프의 배경과 글꼴(`theme_*()`)
- 집단별 패널 분리(`facet_*()`)
- 제목과 축 이름(`labs()`)

4.2.3 변수의 개수, 유형과 그래프 종류

데이터 시각화는 탐색적인 작업이다. 어떤 변수를 선택하고 그 변수의 어떤 특성을 보여줄지에 따라 적합한 그래프가 달라진다. 그래프를 선택하기 전에 다음 두 가지를 확인한다.

- 첫째, 변수의 개수: 한 변수의 빈도나 분포를 볼 것인가, 두 개 이상 변수의 관계를 볼 것인가?

- 둘째, 변수의 유형: 선택한 변수가 범주형(categorical), 순서형(ordinal), 연속형(continuous) 가운데 어디에 해당하는가?

이 두 가지가 결정되면 선택할 수 있는 그래프의 범위가 좁아진다. 예를 들어 산점도(scatter plot)는 두 연속형 변수의 관계를 표현하므로 변수가 하나뿐이거나 두 변수가 모두 범주형인 경우에는 적합하지 않다. 그래프를 그리기 전에 변수의 개수와 유형을 확인하는 습관이 필요하다.

4.3 변인이 1개인 graph

4.3.1 변인이 연속형(continuous)인 경우


앞서 dplyr에서 작업했던 worker_3 데이터를 활용하여 그래프를 그려보자. worker_3 데이터의 w336_01과 w336_02는 각각 주당 정규 근로시간과 초과 근로시간을 의미한다. 근로시간은 0부터 시작되는 연속형 변수이기 때문에 이 변수를 x축으로 두고, y축은 빈도나 비율로 표현하는 히스토그램(histogram)과 밀도그래프(density)를 그릴 수 있다.

4.3.1.1 histogram

w336_02는 주당 초과근로시간을 나타낸다. 이 변수의 분포는 geom_histogram()으로 확인할 수 있다. 앞서 살펴본 ggplot2의 구조를 떠올리며 다음 코드를 해석해보자.


- ggplot()에 사용할 데이터프레임 worker_3_se를 지정한다.
- aes()에서 초과근로시간 변수 w336_02를 x축에 연결한다. aes는 aesthetic mapping을 뜻한다.
- geom_histogram()으로 그래프의 형태를 지정한다.
- 층은 +로 연결한다. 완성된 그래프를 객체에 저장하면 같은 그래프를 다시 출력하거나 수정하기 쉽다.

```
ggplot(worker_3_se) +
  geom_histogram(aes(x = w336_02))
## `stat_bin()` using `bins = 30`. Pick better value `binwidth`.
```



이 코드를 실행하면 `stat_bin()` using `bins = 30`이라는 안내 메시지가 나타난다. 오류가 아니라, `ggplot2`가 전체 범위를 30개 구간(bin)으로 나누었다는 뜻이다. 구간의 개수는 `bins`, 구간의 너비는 `binwidth`로 지정한다. 분석 목적에 따라 여러 값을 비교해 보고 분포가 과도하게 뭉개지거나 불필요하게 들쭉날쭉하지 않은 값을 선택해야 한다. 여기서는 한 시간 단위로 살펴보기 위해 `binwidth = 1`을 사용한다.


```
ggplot(worker_3_se) +  
  geom_histogram(aes(x = w336_02), binwidth = 1)
```



몇 가지 시각적 속성을 더 지정해보자. `ggplot2`에서는 면 색(fill), 투명도(alpha), 선 색(color), 선 종류(linetype) 등을 조정할 수 있다.


- 색 이름이나 16진수 색상 코드(예: "#56B4E9")를 따옴표 안에 입력할 수 있다.
- alpha에는 0과 1 사이의 값을 지정한다. 0에 가까울수록 투명해진다.

```
ggplot(worker_3_se) +
  geom_histogram(
    aes(x = w336_02),
    binwidth = 1, color = "black", fill = "blue", alpha = 0.2
  )
```



만일 x축과 y축의 명칭을 수정하거나, 그래프의 제목을 달고 싶다면 어떻게 해야 할까? 마찬가지로 layer를 추가해주면 된다. 이때 쓰이는 명령어는 `labs(title="", x="", y="")`이다.


```
ggplot(worker_3_se) +
  geom_histogram(
    aes(x = w336_02),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.2
  ) +
  labs(
    title = "근로자의 주당 초과근로시간",
    x = "주당 초과근로시간", y = "빈도(명)"
  )
```



그래프의 배경은 `theme_*()` 함수로 변경할 수 있다. 다음은 자주 사용하는 테마이다.

- `theme_grey()`: 회색 배경의 기본 테마
- `theme_bw()`: 흰 배경과 격자를 사용하는 테마
- `theme_classic()`: 흰 배경에 격자가 없는 테마
- `theme_minimal()`: 배경 요소를 최소화한 테마

```
ggplot(worker_3_se) +
  geom_histogram(
    aes(x = w336_02),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.2
  ) +
  labs(
    title = "근로자의 주당 초과근로시간",
    x = "주당 초과근로시간", y = "빈도(명)"
  ) +
  theme_minimal()
```




이제 ggplot2의 기본 구조를 확인했다. 다른 그래프도 같은 구조를 사용하므로 데이터, aesthetic mapping, geom을 차례로 확인하면 코드를 쉽게 해석할 수 있다. 다음으로 ggplot2와 dplyr을 연결해보자.

히스토그램에는 음수로 코딩된 값이 포함되어 있다. 이 자료에서 음수는 무응답처럼 유효한 근로시간이 아닌 값을 나타낸다. 정확한 의미는 반드시 원자료의 코드북에서 확인해야 한다. 여기서는 filter()로 0 이상인 관측치만 선택한 뒤 그래프를 그린다.

```
worker_3_se %>%
  filter(w336_02 >= 0) %>%
  ggplot() +
  geom_histogram(
    aes(x = w336_02),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.2
  ) +
  labs(
    title = "근로자의 주당 초과근로시간",
    x = "주당 초과근로시간", y = "빈도(명)"
  ) +
```

```
theme_minimal()
```



파이프 연산자 `%>%`는 앞 단계의 결과를 다음 함수로 전달한다. 따라서 위 코드는 유효한 초과근로시간을 선택한 뒤 그 결과를 `ggplot()`에 전달한다. 데이터 처리 단계는 `%>%`로 연결하고, 그래프의 층은 `+`로 연결한다는 차이에 주의하자. 이 방법은 원본 데이터프레임을 바꾸지 않고 그래프에 필요한 관측치만 임시로 선택할 수 있다는 장점이 있다.


다른 형태의 데이터 변환도 시도해보자. 주당 정규근로시간(`w336_01`)과 초과근로시간(`w336_02`)을 더해 총근로시간 `whour`를 만든다. 다음 코드는 두 변수가 모두 0 이상인 관측치만 선택하고 총근로시간을 계산한 뒤 히스토그램을 그린다.

```
worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0) %>%
  mutate(whour = w336_01 + w336_02) %>%
  ggplot() +
  geom_histogram(
    aes(x = whour),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.2
  ) +
  labs(
```

```

title = "근로자의 주당 근로시간",
x = "주당 근로시간", y = "빈도(명)"
) +
theme_minimal()

```




히스토그램의 y축은 기본적으로 각 구간의 빈도를 나타낸다. 빈도 대신 확률밀도를 표현하려면 `aes(y = after_stat(density))`를 사용한다. 확률밀도의 높이는 단순한 사례 비율과 같지 않으며, 각 막대의 높이 × 너비를 모두 더한 면적이 1이 되도록 조정된 값이다. 이 변환은 뒤에서 밀도곡선을 히스토그램에 겹칠 때 유용하다.

```

worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0) %>%
  mutate(whour = w336_01 + w336_02) %>%
  ggplot() +
  geom_histogram(
    aes(x = whour, y = after_stat(density)),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.2
  ) +
  labs(

```

```
title = "근로자의 주당 근로시간",
x = "주당 근로시간", y = "확률밀도"
) +
theme_minimal()
```




4.3.1.2 density curve

연속형 변수 하나의 분포는 밀도곡선(density curve)으로도 표현할 수 있다. 밀도곡선은 관측된 자료의 분포를 부드럽게 추정한 곡선이다. 특정 x 값에서의 곡선 높이는 확률 그 자체가 아니라 확률밀도이며, 어떤 구간의 확률은 그 구간 아래의 면적으로 해석한다.

- 밀도곡선의 y 축은 확률밀도이다.
- 곡선 아래 전체 면적은 1이다.
- 왼쪽 꼬리가 길면 왼쪽으로 치우친 분포(left-skewed distribution), 오른쪽 꼬리가 길면 오른쪽으로 치우친 분포(right-skewed distribution)라고 한다.
- 왼쪽으로 치우친 분포에서는 평균이 중앙값보다 작은 경우가 많고, 오른쪽으로 치우친 분포에서는 평균이 중앙값보다 큰 경우가 많다. 다만 이는 일반적인 경향이므로 평균과 중앙값을 직접 확인해야 한다.
- 대칭 분포에서도 평균과 중앙값이 반드시 같다고 단정할 수는 없으며, 표본

에서는 차이가 생길 수 있다.


```
worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0) %>%
  mutate(whour = w336_01 + w336_02) %>%
  ggplot() +
  geom_density(aes(x = whour), color = "black", fill = "skyblue", alpha = 0.2) +
  labs(
    title = "근로자의 주당 근로시간",
    x = "주당 근로시간", y = "확률밀도"
  ) +
  theme_minimal()
```



총근로시간은 40~54시간 구간에 집중되어 있고, 그보다 긴 근로시간 쪽으로 꼬리가 이어진다. 평균은 약 49.57시간, 중앙값은 50시간이다. 분포의 방향은 그래프의 꼬리와 요약통계량을 함께 보고 판단해야 한다. 다음 코드에서는 평균 위치를 `geom_vline()`으로 표시한다.

```
worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0) %>%
  mutate(whour = w336_01 + w336_02) %>%
```

```
ggplot() +
  geom_density(aes(x = whour), color = "black", fill = "skyblue", alpha = 0.2) +
  geom_vline(
    aes(xintercept = mean(whour)),
    color = "blue", linetype = "dashed", linewidth = 1
  ) +
  labs(
    title = "근로자의 주당 근로시간",
    x = "주당 근로시간", y = "확률밀도"
  ) +
  theme_minimal()
```




4.3.1.3 histogram + density curve

ggplot2에서는 여러 층을 쌓아 히스토그램과 밀도곡선을 함께 표현할 수 있다. 두 그래프를 겹치려면 x축뿐 아니라 y축의 단위도 같아야 한다. 히스토그램의 기본 y축은 빈도이므로 `after_stat(density)`를 사용해 밀도곡선과 같은 확률밀도 단위로 바꾼다.

```

worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0) %>%
  mutate(whour = w336_01 + w336_02) %>%
  ggplot() +
  geom_histogram(
    aes(x = whour, y = after_stat(density)),
    binwidth = 1, color = "black", fill = "skyblue", alpha = 0.3
  ) +
  geom_density(aes(x = whour), color = "blue", linewidth = 1) +
  labs(
    title = "근로자의 주당 근로시간 분포",
    x = "주당 근로시간", y = "확률밀도"
  ) +
  theme_minimal()

```



4.3.1.4 집단별 그래프 비교

전체 분포를 확인한 다음에는 집단별 분포가 어떻게 다른지 살펴볼 수 있다. 예를 들어 성별에 따라 총근로시간의 중심, 퍼짐, 꼬리 모양이 다른지 탐색해보자. 평균

만 비교하면 분포의 겹침이나 이상치를 놓칠 수 있으므로 그래프와 요약통계량을 함께 확인하는 것이 좋다.

ggplot2에서는 집단에 따라 색이나 선 종류를 다르게 지정할 수 있다. 먼저 성별과 같은 집단변수를 범주형 변수인 factor로 변환한다. tidyverse에 포함된 forcats는 factor의 수준(level)을 변경하거나 순서를 조정할 때 유용하다.

먼저 worker_3_se의 성별 변수 w3_sex를 확인한다. str()로 저장 형태를 확인하고 count()로 값별 빈도를 계산한다. 숫자로 저장된 변수라도 숫자의 크기보다 집단 구분이 중요한 경우에는 factor로 변환해야 한다.

```
str(worker_3_se$w3_sex)
## int [1:10019] 1 1 1 2 1 1 2 1 1 1 ...
worker_3_se %>%
  count(w3_sex)
##   w3_sex    n
## 1     -9   10
## 2      1 8124
## 3      2 1885
```

결과를 살펴보면 w3_sex는 정수형이며 1과 2 외에 -9가 10건 포함되어 있다. 코드 북에서 -9가 성별 불상을 뜻한다는 것을 확인한 뒤 다음 세 단계를 수행한다.

- filter()로 유효하지 않은 성별 코드를 제외한다.
- mutate()와 as_factor()로 w3_sex를 factor형 변수 gender로 변환한다.
- fct_recode()로 1과 2라는 수준에 이해하기 쉬운 이름을 부여한다.

```
worker_3_se %>%
  filter(w336_02 >= 0, w336_01 >= 0, w3_sex > 0) %>%
  mutate(
    whour = w336_01 + w336_02,
    gender = as_factor(w3_sex),
    gender = fct_recode(gender, "남성" = "1", "여성" = "2")
  ) -> worker_3_fa


str(worker_3_fa$gender)
## Factor w/ 2 levels "남성","여성": 1 1 1 2 1 1 2 1 1 1 ...
```

성별 변수를 factor로 변환했으니 성별에 따른 총근로시간 분포를 비교해보자. 집단을 구분하는 대표적인 방법은 다음 두 가지이다.

- 한 패널에서 색이나 선 종류로 집단을 구분하는 방법: `aes(fill = gender)`처럼 지정한다.
- 집단별 그래프를 서로 다른 패널에 그리는 방법: `facet_wrap(~gender)`처럼 지정한다.


먼저 한 패널에서 성별을 면 색으로 구분한다. `fill`을 `aes()` 안에서 변수에 연결하면 자동으로 범례가 생성된다. 두 집단의 사례수가 다르면 빈도만으로 분포를 비교하기 어려우므로 첫 그래프에서는 원자료의 빈도를 확인하고, 다음 그래프에서는 집단별 확률밀도를 비교한다.

```
worker_3_fa %>%
  ggplot() +
  geom_histogram(aes(x = whour, fill = gender), binwidth = 1) +
  labs(x = "주당 근로시간", y = "빈도(명)", fill = "성별")
```




이 자료에는 남성이 여성보다 많으므로 빈도 히스토그램에서는 남성 막대가 전반적으로 크게 나타난다. 집단의 크기가 다른 상황에서 분포의 모양을 비교하려면 y 축을 집단별 확률밀도로 바꾸고 막대를 반투명하게 겹쳐 그릴 수 있다.

```
worker_3_fa %>%
  ggplot() +
  geom_histogram(
    aes(x = whour, y = after_stat(density), fill = gender),
    position = "identity", binwidth = 1, alpha = 0.4
  ) +
  labs(x = "주당 근로시간", y = "확률밀도", fill = "성별")
```



두 번째 방법은 집단별 그래프를 서로 다른 패널에 그리는 것이다. `facet_wrap()`은 지정한 factor의 수준마다 패널을 만든다. 패널의 y축을 확률밀도로 맞추면 사례수가 다른 집단의 분포 모양을 비교하기 쉽다.

```
worker_3_fa %>%
  ggplot() +
  geom_histogram(
    aes(x = whour, y = after_stat(density)),
    binwidth = 1, fill = "skyblue", color = "black"
  ) +
  labs(x = "주당 근로시간", y = "확률밀도") +
  facet_wrap(~gender)
```



4.4 변인이 2개인 graph

4.4.1 Continuous X, Continuous Y

4.4.1.1 산점도 geom_point


두 연속형 변수의 관계를 탐색할 때는 산점도(scatter plot)를 사용한다. 각 관측치를 x값과 y값이 만나는 지점에 점으로 표시하므로 관계의 방향, 형태, 강도와 이상치를 함께 살펴볼 수 있다. ggplot2에서는 `geom_point()`를 사용하고 `aes(x = ..., y = ...)`로 두 변수를 지정한다.

다음 코드는 총근로시간(whour)과 월근로소득(w337_02)의 산점도를 그린다.¹ 이 자료에서는 총근로시간이 길수록 월근로소득이 증가하는 약한 양의 관계가 보이지만, 점들이 넓게 퍼져 있어 근로시간만으로 소득을 설명하기는 어렵다.

```
worker_3_fa %>%
  filter(w337_02 > 0) %>%
```

¹filter()를 생략하면 결측을 의미하는 음수 코드가 그래프에 포함된다. 분석 전에 코드북을 확인하고 유효한 관측치의 범위를 정해야 한다.

```
ggplot(aes(x = whour, y = w337_02)) +
  geom_point(alpha = 0.4) +
  labs(x = "주당 근로시간", y = "월근로소득")
```




4.4.1.2 추세선 geom_smooth

geom_smooth()를 추가하면 두 변수의 전반적인 관계를 추세선으로 표현할 수 있다. 여기서는 선형모형(linear model)을 뜻하는 method = "lm"을 사용한다.² 여러 geom이 같은 변수를 사용한다면 aes()를 ggplot() 안에 지정해 중복을 줄일 수 있다.

```
worker_3_fa %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = whour, y = w337_02)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", formula = y ~ x)
```

²geom_smooth()의 자세한 옵션은 https://ggplot2.tidyverse.org/reference/geom_smooth.html을 참고한다.




그래프에는 관측치를 나타내는 점, 추정된 회귀선, 회귀선 주위의 회색 띠가 함께 나타난다. 회색 띠는 기본적으로 각 x값에서 추정한 평균 반응의 95% 신뢰구간이다. 개별 관측값이 위치할 범위를 뜻하는 예측구간과는 다르다. `geom_smooth()`의 주요 옵션은 다음과 같다.

- `method`: 추세선을 추정할 방법이다. `lm`, `glm`, `gam`, `loess` 등을 사용할 수 있다.
- `se`: 신뢰구간의 표시 여부이다. 기본값은 `TRUE`이며 `se = FALSE`로 숨길 수 있다.
- `level`: 신뢰수준이다. 기본값은 0.95이며, 예를 들어 `level = 0.99`로 변경할 수 있다.
- `na.rm`: 결측치 처리 방식을 지정한다. `TRUE`이면 결측치를 제거하면서 관련 경고를 표시하지 않는다.


히스토그램과 마찬가지로 산점도와 추세선도 집단별로 구분할 수 있다. 한 그래프에서 색으로 집단을 표현하는 방법(`colour = group`)과 패널을 분리하는 방법(`facet_wrap(~group)`)을 살펴보자.

근로시간과 소득의 관계가 산업(`w3_ind1`)과 직종·직위(`w3_posit`)에 따라 다른지 탐색해보자. 두 변수를 factor로 변환하고 코드값에 해석 가능한 이름을 붙인 뒤 `worker3_final`에 저장한다.

```
worker_3_fa %>%  
  mutate(  
    industry = as_factor(w3_ind1),  
    industry = fct_recode(  
      industry, "제조업" = "1", "금융업" = "2", "서비스업" = "3"  
    ),  
    position = as_factor(w3_posit),  
    position = fct_recode(  
      position,  
      "사무관리직" = "1", "생산관리직" = "2",  
      "사무직" = "3", "생산직" = "4"  
    )  
  ) -> worker3_final  
  
worker3_final %>%  
  filter(w337_02 > 0) %>%  
  ggplot(aes(x = whour, y = w337_02, colour = industry)) +  
  geom_point(alpha = 0.4) +  
  geom_smooth(method = "lm", formula = y ~ x)
```




```
worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = whour, y = w337_02, colour = position)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", formula = y ~ x)
```




그래프에서는 금융업 집단의 월근로소득 수준이 상대적으로 높고, 산업 및 직종·직위에 따라 점의 분포와 추세선이 달라지는 모습을 확인할 수 있다. 다만 일부 집단은 사례수가 적고 집단 내 산포도 크므로, 그래프만으로 모집단의 차이나 인과관계를 단정해서는 안 된다. 여기서 발견한 패턴은 이후 장에서 적절한 통계모형으로 검토해야 한다.

집단별 그래프를 여러 패널로 나누어보자. `facet_wrap(~group)`을 추가하면 각 수준이 별도의 패널에 나타난다. 모든 패널이 같은 축 범위를 사용하므로 집단 간 기울기와 분포를 직접 비교할 수 있다.

```
worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = whour, y = w337_02)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", formula = y ~ x) +
  facet_wrap(~industry)
```




```
worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = whour, y = w337_02)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", formula = y ~ x) +
  facet_wrap(~position)
```



두 범주형 변수의 조합으로 패널을 나누려면 `facet_grid()`를 사용한다.
`facet_grid(행 변수 ~ 열 변수)`의 순서로 지정한다.

```
worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = whour, y = w337_02)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", formula = y ~ x) +
  facet_grid(position ~ industry)
```



4.4.2 Discrete X, Continuous Y

두 변수를 그래프에 표현할 때 x축이 범주형이고 y축이 연속형인 경우가 있다. 예를 들어 성별에 따른 소득의 분포나 산업에 따른 근로시간의 분포를 비교할 수 있다. 이때 막대그래프는 요약값을, 박스플롯은 분포를 보여주는 데 적합하다.

4.4.2.1 bar chart

`geom_bar()`는 x축 범주별 관측치 수를 세어 막대 높이로 나타낸다. 예를 들어 성별이 1인 관측치가 70건, 2인 관측치가 30건이면 두 막대의 높이는 각각 70과 30이 된다. 따라서 `geom_bar()`의 기본 통계적 변환은 `stat = "count"`이며 y축 변수를 따로 지정하지 않는다.


이미 요약된 y값을 막대 높이로 사용하려면 `geom_col()`을 사용한다. `geom_col()`은 `geom_bar(stat = "identity")`와 같은 역할을 한다. 원자료의 여러 y값을 그대로 넣으면 같은 범주의 값들이 누적되므로, 평균이나 합계처럼 목적에 맞는 요약값을 먼저 계산해야 한다.

```
# x변수만 지정: 범주별 사례 수
worker3_final %>%
```

```

filter(w337_02 > 0) %>%
ggplot(aes(x = position)) +
geom_bar(fill = "skyblue", alpha = 0.8) +
labs(x = "직종·직위", y = "빈도(명)")

```




```

# 범주별 총근로시간을 먼저 계산
worker3_final %>%
  filter(w337_02 > 0) %>%
  group_by(position) %>%
  summarise(total_whatour = sum(whatour), .groups = "drop") -> position_total

position_total %>%
  ggplot(aes(x = position, y = total_whatour)) +
  geom_col(fill = "skyblue", alpha = 0.8) +
  labs(x = "직종·직위", y = "총근로시간")

```



총근로시간의 합은 집단의 사례수가 많을수록 커지므로 집단의 전형적인 근로시간을 비교하는 데는 적합하지 않을 수 있다. 집단별 평균을 비교하려면 다음 절처럼 평균을 계산해 표현해야 한다.

4.4.2.2 stat_과 geom_의 관계

앞의 그래프는 직종·직위별 총근로시간을 보여주지만, 이 값은 집단의 규모에 크게 좌우된다. 직종·직위별로 한 사람의 전형적인 근로시간을 비교하려면 평균과 불확실성을 함께 표현하는 편이 더 적절하다.

동전의 앞면, stat_과 geom_

여기서 geom과 stat의 의미와 관계를 살펴보자.

- **geom**: 관측값이나 요약값을 어떤 모양으로 표현할지 지정한다. 예를 들어 `geom_bar()`는 막대, `geom_line()`은 선을 그린다.
- **stat**: 원자료를 그래프에 표시하기 전에 어떤 방식으로 변환할지 지정한다. 예를 들어 `stat_count()`는 범주별 사례 수를 계산하고 `stat_summary()`는 평균과 같은 요약통계량을 계산한다.

각 geom에는 기본 stat이 연결되어 있으며, 반대로 stat에도 기본 geom이 연결되어 있다. 따라서 다음 두 표현은 같은 결과를 만든다. 이 책에서는 표현하려는

그래프의 모양을 먼저 생각할 수 있도록 geom 중심의 표현을 주로 사용한다.


- `geom_bar(stat = "count")`
- `stat_count(geom = "bar")`

직종·직위별 평균 근로시간을 표현하려면 `stat_summary()` 또는 `stat = "summary"`를 사용한다. `stat_summary()`는 각 집단의 여러 관측값을 평균과 같은 요약값으로 변환한다. 함께 사용하는 `fun`과 `fun.data`의 차이는 다음과 같다.

- `fun`: 평균이나 중앙값처럼 하나의 수를 반환하는 함수를 지정한다. 예: `fun = mean`, `fun = median`.
- `fun.data`: 중심값과 하한·상한처럼 여러 값을 데이터프레임으로 반환하는 함수를 지정한다. 예: `fun.data = mean_se`.

다음 코드는 직종·직위별 평균 근로시간을 막대로 나타내고 평균의 위아래에 1 표준오차를 오차막대로 표시한다. `mean_se()`는 `ggplot2`가 제공하므로 별도의 패키지 필요하지 않다. 오차막대가 표준편차, 표준오차, 신뢰구간 가운데 무엇을 나타내는지 그래프나 본문에 반드시 밝혀야 한다.

```
worker3_final %>%
  ggplot(aes(x = position, y = whour)) +
  geom_bar(
    stat = "summary",
    fun = mean,
    fill = "red",
    alpha = 0.3
  ) +
  geom_errorbar(
    stat = "summary",
    fun.data = mean_se,
    colour = "black",
    width = 0.2
  ) +
  labs(
    x = "직종·직위", y = "평균 주당 근로시간",
    caption = "오차막대는 평균 ± 1 표준오차"
  )
```



```
worker3_final %>%
  ggplot(aes(x = position, y = whour)) +
  stat_summary(
    geom = "bar",
    fun = mean,
    fill = "blue",
    alpha = 0.3
  ) +
  stat_summary(
    geom = "errorbar",
    fun.data = mean_se,
    colour = "black",
    width = 0.2
  )
```

4.4.2.3 boxplot


박스플롯(boxplot), 또는 상자수염그림(box-and-whisker plot)은 자료의 중앙값과 분포를 함께 확인할 수 있는 그래프이다. 상자, 중앙선, 수염, 수염 밖의 점을 통해

다음 정보를 표현한다.

- 중앙값(median): 상자 안의 선으로 표시하며 제2사분위수(Q2)와 같다. 평균과는 다른 통계량이다.
- 제1사분위수(Q1)와 제3사분위수(Q3): 상자의 아래쪽과 위쪽 경계이다. 상자는 가운데 50%의 관측값을 포함한다.
- 사분위범위(IQR): $Q3 - Q1$ 이며 자료의 중간 50%가 퍼진 정도를 나타낸다.
- 수염(whisker): 아래쪽은 $Q1 - 1.5 \times IQR$ 이상인 관측값 가운데 가장 작은 값까지, 위쪽은 $Q3 + 1.5 \times IQR$ 이하인 관측값 가운데 가장 큰 값까지 이어진다. 따라서 항상 실제 최솟값과 최댓값을 나타내는 것은 아니다.
- 수염 밖의 점: 잠재적 이상치로 표시한다. 자료 입력 오류라고 단정할 수 없으므로 원자료와 연구 맥락을 추가로 확인해야 한다.

ggplot2에서 박스플롯을 그리려면 `geom_boxplot()`을 사용한다.

```
worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = position, y = w337_02)) +
  geom_boxplot(
    fill = "skyblue",
    alpha = 0.3
  ) +
  labs(x = "직종·직위", y = "월근로소득")
```



4.5 Miscellaneous items

완성된 그래프는 `ggsave()`로 저장할 수 있다. 마지막으로 출력한 그래프를 저장할 수도 있지만, 그래프를 객체에 담아 `plot` 인수로 명시하면 어떤 그림을 저장하는지 분명해진다. 파일 확장자에 따라 PNG, PDF 등의 형식이 결정된다.

```
income_boxplot <- worker3_final %>%
  filter(w337_02 > 0) %>%
  ggplot(aes(x = position, y = w337_02)) +
  geom_boxplot(fill = "skyblue", alpha = 0.3) +
  labs(x = "직종·직위", y = "월근로소득")

ggsave(
  filename = "images/income_boxplot.png",
  plot = income_boxplot,
  width = 8, height = 5, units = "in", dpi = 300
)
```

그래프를 해석할 때는 축의 단위, 분석에 포함된 관측치, 결측치 처리, 집단별 사례

수, 오차막대의 의미를 함께 확인해야 한다. 보기 좋은 그래프보다 자료의 구조와 불확실성을 정직하게 보여주는 그래프가 더 좋은 그래프이다.

제 5 장

추론통계와 가설검정

- 추론통계와 확률
 - 기술통계와 추론통계
 - 확률과 확률변수
 - 확률변수와 확률분포
 - 확률분포함수와 확률밀도함수
- 대표적인 확률분포
 - 정규분포
 - 표준정규분포
 - 카이스퀘어분포
 - F 분포
- 중심극한정리
 - 표본평균과 표본평균분포
 - 중심극한정리의 활용
- 가설검정
 - 가설과 가설 검정
 - 점추정
 - 구간추정
 - 가설의 채택이란 무엇인가? 신뢰구간의 해석은?
 - 점추정과 구간 추정

5.1 추론통계와 확률

5.1.1 기술통계와 추론통계

우리가 연구 장면에서 마주하는 통계는 크게 두가지, (1) **기술통계**와 (2) **추론통계**로 구분된다. 기술통계는 **descriptive statistics**로 불리며, 말그대로 자료data를 기술(describing) 하는 목적을 갖는다. 추론통계는 **inferential statistics**로 불리우며, 표본sample에서 확인되는 통계량statistics로 모집단population의 모수치parameter를 추정(inferring) 하는것을 목적으로 한다.

예를 들어 서울대학교 재학생 전체 5,000명의 키 데이터를 운 좋게 갖고 있다고 생각해 보자. 이들의 키 평균, 표준편차, 사분위수, 분포 등의 정보는 기술통계이다. 만약 2500명의 남학생과 2500명의 여학생의 키 평균의 차이가 0.1cm로 나타났다면? 우리가 갖고 있는 데이터는 서울대학교 재학생 전체의 데이터이기 때문에 별도의 추가 분석 없이 “성별에 따라 키의 차이가 있다”고 자신있게 이야기할 수 있다. 모집단의 자료를 모두 갖고 있는 데 통계적인 차이 검정을 할 필요가 없는 것이다.

반면에 추론통계는 우리가 5,000명의 모집단에 대한 정보나 자료를 갖지 못할 때 활용한다. 만약 이 가운데 100명의 표본만 갖고 있다면 표본의 통계량을 통해 모집단을 추정해야 하는 추론통계가 필요하다. 표본중 50명의 여성과 50명의 남성의 키 평균 차이가 5cm로 나타났다고 생각해 보자. 5cm는 충분히 큰 격차이지만 우리는 t 검정을 통해 “통계적으로 유의미한 차이”가 있는지 확인해야 한다. 왜냐하면 우리가 뽑은 표본이 모집단의 분포에서 어디에서 왔는지 알 수 없기 때문이다. 예를 들어 여자는 극단적으로 키가 작은 사람들로 표집되고, 남자는 극단으로 키가 큰 사람들로 표집되었을 수 있다. 이 경우 실제 모집단에서는 성별에 따른 키 차이가 그다지 없지만 표본에서만 과다한 격차를 보일 수도 있기 때문이다.

산업인력개발 현업에서도 기술통계와 추론 통계를 구분하지 않고 보고서가 작성되는 경우가 많다. 예를 들어 A 기업에서 리더십 교육을 받은 직원들의 교육 전후 지식의 차이를 확인한다고 생각해 보자. 만약 리더십교육을 받은 사람들을 모집단으로 설정하고, 이들에 대한 데이터를 모두 수집할 수 있다면 추론통계는 그다지 의미가 없을 수 있다. 하지만 우리는 습관적으로 t 검정이나 ANOVA와 같은 추론통계를 사용한다. 언제 추론통계와 기술통계를 사용해야 하는지를 명확히 이해하는 것이 중요하다.

5.1.2 확률probability과 확률변수random variable

추론통계와 기술통계의 가장 큰 차이는 **확률 probability**의 활용 유무이다. 추론 통계는 표본량을 활용해 모수치를 추정하는 과정에서 확률의 개념이 활용된다는 점이 가장 특징적이다.

확률은 **경험 또는 실험 결과로 특정한 사건이나 결과가 발생할 가능성**을 의미한다. 가장 대표적인 확률은 주사위를 던졌을 때(실험) 각각의 눈이 나올 확률(특정 사건이 발생하는 가능성)이다. 이때 연구자가 주사위를 한번던져서 나온 눈의 개수를 변수값(value)로 정의하여 이를 변수 X 로 정의한다면 X 는 **확률변수**가 된다. 여기서 **변수variable**의 정의에 대해 추가로 이해할 필요가 있다. 변수는 상수constant와 달리 “변하는 값”을 가지며 특정한 척도로 측정하여 그 결과를 수치로 기록한 값을 의미한다. 결국 변수에는 (1)다양한 변수값이 부여되고, (2)변수값은 “척도로 측정”한다는 의미를 동시에 갖고 있다.

지금부터는 두개의 동전을 던지는 실험을 통해 확률변수의 개념을 이해해보도록 하겠다. 이 과정에서 정의되는 것은 다음의 4가지 요소이다

- 실험(experiment) : 어떤 행위의 결과를 관찰하고 측정하여 그 결과에 대해 구체적인 값을 부여한다.
 - 예: 두 개의 동전을 던져서, 앞면이 나오면 2, 뒷면이 나오면 0의 값을 부여하여, 이를 더한다.
- 표본점 : 실험결과로 발생할 수 있는 결과
 - 예: 동전이 앞, 앞이 나온다, 동전이 앞, 뒤가 나온다 등
- 표본공간 : 실험결과로 발생할 수 있는 “모든” 가능한 결과(표본점)의 집합
 - + 예: {앞,앞}, {앞, 뒤}, {뒤, 앞}, {뒤, 뒤}
- 확률변수 : 표본공간상에 나타나는 모든 표본점들에 수치를 부여하는 규칙, 표본공간의 각 결과를 실수에 대응시키는 함수
 - 예: 확률변수 X = 앞면은 2, 뒷면은 0을 부여하고, 두 동전의 값을 합한 것, $\{2+2\}$, $\{2+0\}$, $\{0+2\}$, $\{0+0\}$

위의 실험에서 확인할 수 있듯이 확률변수는 연구자에 따라 다양한 규칙에 따라 수치를 부여할 수 있기 때문에(예: 앞면은 1, 뒷면은 2의 값을 부여하고 곱한다), 하나의 표본공간으로부터 수없이 많은 확률변수들이 생성될 수 있다.

이상의 표본공간, 확률변수 X , 확률변수 X 가 나타날 확률을 표로 정리해보면 다음과 같다.

표본공간	{H, H}	{H, T}	{T, H}	{T, T}
확률변수 X	4	2	2	0
확률변수 X가 나타날 확률 (P)	1/4	1/4	1/4	1/4


5.1.3 확률변수 random variable와 확률분포 probability distribution

확률변수 random variable은 분포 distribution의 정보 없이는 어떠한 의미를 갖지 못한다. 예를 들어 김태형의 삶의 만족도가 40점이라면, 만족한다고 할 수 있을까? 판단을 위해서는 우리가 알아야 할 정보가 있다. 첫째, 표본공간을 알아야 한다. 만족도 점수가 0점부터 50점까지 분포한다. 둘째, 단일표본점의 발생확률을 알아야 한다. 각 점수가 발생할 확률은 동일하다. 이 두 정보를 알게 되면 확률분포를 그릴 수 있다.

확률분포 probability distribution는 확률변수가 특정한 값을 가질 확률을 나타내는 함수를 의미한다. 함수란 무엇인가? $y=f(x)$ 를 떠올려보자. x 에 특정한 값을 투입했을 때 특정한 y 값이 산출되는 일종의 규칙이다. 말이 나온김에 어렵게 느껴지는 함수의 의미를 정확히 이해해보자. 함수는 일종의 자판기와 같다. 1을 집어넣으면 2가 나오고, 2를 집어넣으면 4, 3을 집어넣으면 6이 나오는 자판기가 있다고 생각해보자. 이 자판기의 규칙은 무엇일까? 투입하는 값(x)의 2배가 되는 값(y)을 산출해주는 것이 규칙이다. 이러한 규칙을 바로 함수라고 하는데, 위의 예를 수식으로 쓰면 $y=2x$ 이다. 이 설명을 좀더 수학적으로 설명해보면 함수란 **집합의 임의의 한 원소를 다른 집합의 한 원소에 대응시키는 관계**라고 설명할 수 있을 것이다.

다시 확률분포로 돌아오면, 확률분포는 확률변수를 X 로 하고, 확률변수의 발생 확률($P(X)$)를 y 로 하는 규칙이다. 동전을 던지는 실험에서 정의한 확률변수 X 를 생각해보자. 이를 간단히 그래프로 표현하면 아래와 같다. X 축에는 확률변수 X 가 가질 수 있는 값 $\{0, 2, 4\}$ 이 표현되고, Y 축에는 각 값이 나타날 확률인 $1/4, 1/2, 1/4$ 가 표현된다.

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```



이때 확률변수 X 는 비연속적인 값을 갖고 있다. 즉 값의 갯수를 셀 수 있다(0, 2, 4 중 하나의 값만 가진다). 이처럼 변수값의 갯수를 셀 수 있는(countable)한 경우는 **이산확률변수(discrete random variable)**라고 명명한다. 반대로 확률변수 값의 갯수를 셀 수 없는 경우가 **연속확률변수(continuous random variable)**이다. 연속확률변수 X 는 실생활에서 자주 찾아볼 수 있다. 20대 여성의 키(cm), 우리나라 성인의 (IQ), 고등학교 진로교육만족도(5점 Likert 여러문항의 평균 점수) 등이 대표적이다.

5.1.4 확률질량함수와 확률밀도함수

확률변수분포에 대한 이해를 마쳤다면, 좀더 구체적으로 이산확률변수와 연속확률변수의 특정한 값에 대한 확률을 구하는 방법을 알아보자. 예를 들어 주사위를 두번던져서 나온 눈의 값의 합이 3이 나올 확률은 얼마일까?(이산확률변수의 확률), 우리나라 20대 여성의 키가 165cm~168cm의 값을 가질 확률은 얼마일까?(연속확률변수의 확률). 이러한 질문에 대한 답은 확률질량함수와 확률밀도함수에 있다.

5.1.4.1 확률질량함수 (probability mass function, pmf)

확률질량함수와 확률밀도함수는 매우 유사한 개념이다. 다만 확률변수의 특성(이산변수 vs 연속형 변수)에 따라 y 축의 값이 변하는 것에 차이가 있다. 확률질량함수

는 확률변수가 이산형(비연속형)일때 쓰인다. 확률변수가 이산형일때 확률질량함수를 그래프로 표현하는 것은 아주 직관적이다. 위의 그림처럼 x축이 확률변수의 값(0, 2, 4)이고, y축이 확률변수가 나타날 확률($P(x)$)이기 때문이다.

5.1.4.2 확률밀도함수 (probability density function, pdf)

확률밀도함수는 확률변수가 연속형일때 쓰인다. 이산형 변수와 달리 확률밀도함수의 y축은 $P(x)$ 가 아니다. 왜일까? 연속형 변수의 개념을 잘 생각해보면 답이 있다. 확률변수 X 를 우리나라 20대 여성의 평균 키라고 생각해보면, 확률변수 X 가 165일 확률은 0이다. 왜냐하면 165라는 이산적인 값을 가질 수 없기 때문이다(165앞뒤로 0.0000000....1의 간격으로 조밀하게 값이 분포해있는것을 떠올려보자). 따라서 연속형 확률변수가 특정값을 가질 확률은 구할 수 없고, 특정 구간(예: 160~165 사이)에 분포할 확률을 구해야 한다. 이를 위해 확률밀도함수는 **밀도**의 개념을 사용하여 확률을 계산한다. 앞서 이산확률분포일때의 확률 함수를 확률질량함수라고 했던것을 기억해보자. 이때 y 축은 질량(mass)이며, 이것을 확률변수(X)가 나타날 확률(probability)로 정의한 바 있다. 다음의 4개의 식을 통해 확률밀도함수의 구간 면적(확률변수 x 가 구간에 있을 확률)을 밀도로 표현하는 것을 이해할 수 있다.

- 질량 = 확률변수 X 가 나타날 확률
- 부피 = 계급크기, X 축의 구간($a < X < b$)
- 밀도 = 질량/부피
- 밀도 = 확률변수 X 가 나타날 확률/계급크기
- 확률밀도함수의 구간면적 = $a < X < b$ 사각형의 면적 = 해당구간을 정적분한 값 (정확히는 곡선 아래의 면적)
- 밀도 * 부피 (사각형의 넓이 구하는 공식) = 확률변수 x 가 나타날 확률/계급크기 * 계급크기 = 확률변수 X 가 나타날 확률

위의 설명은 아래의 수식(5.1)을 통해 보다 명확히 이해할 수 있다. 중요한 것은 확률변수 X 가 발생할 확률은 구간의 면적과 같다는 점이다. 이 원리는 앞으로 다양한 확률분포를 활용해서 가설을 검정할때 사용되므로 분명히 이해하는 것이 좋다. 많은 학생들이 y축값을 확률로 오해하는 경우가 많은데, 확률밀도함수의 y값 자체는 확률이 아니며, 구간 아래의 면적이 확률이다.

$$P(a < x < b) = \int_a^b f(x)dx \quad (5.1)$$

확률변수 X 는 무한대라고 가정하면, 확률밀도함수의 전체 면적은 1이다. 왜냐하면 모든 표본점의 발생확률을 더한 값과 같기 때문이다(5.2)

$$P(-\infty < x < \infty) = \int_{-\infty}^{\infty} f(x)dx = 1 \quad (5.2)$$

5.2 대표적인 확률분포

지금부터는 실제 연구에서 활용되는 다양한 종류의 확률분포에 대해 알아보자. 무수히 많은 확률분포 중에서 분포의 특성을 파악하여 함수로 나타낼 수 있는 대표적인 확률분포들이다. 확률분포는 확률변수의 연속성 여부에 따라 달라진다. 이산확률분포에는 대표적으로 이항분포, 포아송분포가, 연속확률 분 표준정규분포(Z분포), t분포, 카이제곱검정, F검정 등이 있다. 산업인력개발분야에서 활용되는 대부분의 확률변수는 연속적이기 때문에 이 장에서는 연속확률분포에 대해서만 언급하도록 하겠다. 다만 이항분포의 경우 로짓분석에서 사용되므로 해당 장에서 자세히 설명하도록 하겠다.

5.2.1 정규분포

연속확률분포에서 가장 기초적으로 이해해야 하는 것은 정규분포(normal distribution)이다. 우리가 분포라는 단어를 들으면 떠오르는 종 모양의 대칭형 분포가 정규분포이다. 좀더 구체적으로 정규분포에 대해 살펴보면 다음과 같다. 정규분포의 확률밀도함수는 (5.3)과 같다.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma}\right]^2}, -\infty < x < \infty \quad (5.3)$$

위의 식은 매우 복잡해보이지만, 차근차근 살펴보면 어려울것이없다(물론 외울필요도 없다). 확률밀도함수를 그래프로 이해해보면, x 축은 x 의 값이, y 축은 $f(x)$ 의 값이 부여된다.

- (1) 이때, x 는 음의 무한대에서 양의 무한대의 값을 갖는다.
- (2) π 와 e 는 상수이다. (π 는 3.14, e 는 2.718의 값을 나타낸다는 것을 기억하라)
- (3) x 와 상수값을 제외하면 남는 것은 평균(μ)와 표준편차(σ)의 값이다.

결국 정규분포는 어떠한 확률변수 x 의 평균과 표준편차에 따라 그 모양이 달라질 것이라고 예상할 수 있다. 이러한 의미에서 평균과 표준편차를 각각 위치모수

(location parameter)와 척도 모수(scale parameter)라고 부른다. 아래 그림을 보면 확률변수 x 의 평균값이 분포의 대칭축이기 때문에, 평균값의 변화에 따라 정규분포의 위치가 이동하는 것을 볼 수 있다. 또한 분산의 경우 종모양이 퍼진정도를 결정하는 것을 볼 수 있다.




그림 5.1: 위치모수와 척도 모수

확률변수 X 가 평균(μ)과 분산(σ)의 값을 갖는 정규분포라는 것을 식으로 표현하면 (5.4)과 같다.

$$X \sim N(\mu, \sigma^2) \quad (5.4)$$

정규분포가 갖는 또 하나의 특징은 평균값을 기준으로 대칭적이라는 것이다. 이는 이후에 가설검정을 할때 큰 도움이 된다. 왜냐하면 왼쪽과 오른쪽의 면적을 각각 구할 필요 없이, 한쪽 면적의 2배로 계산하면 되기 때문이다. 관련한 설명은 표준정규분포에서 좀더 자세히 설명하겠다. 종모양의 분포라고 해서 모두 정규분포라고 할 순 없다. 정규분포를 따르는 경우 전체 자료의 68.26%, 95.44%, 99.74%가 각각 평균으로부터 1시그마, 2시그마, 3시그마 범위안에 존재해야한다. 1표준편차 이내에도 상당한 비율로 자료가 분포하기 때문에 종모양의 중앙이 볼록할 수록 정규분포에 더욱 가까워진다고 추측할 수 있다. 여기서 68.26%의 관측치가 1표준편차 이내에 분포한다는 것이 무슨 뜻일까? 아래 그림에서 볼 수 있듯이 평균(μ)를 기준으로 좌우 -1표준편차($\mu - 1\sigma$), +1표준편차($\mu + 1\sigma$)만큼의 구간에 해당되는 면적이 0.6826이라는 뜻이다(확률밀도함수의 전체 면적은 1이라는 점을 기억하자!)

5.2.2 표준정규분포 (standard normal distribution)

표준정규분포는 특수한 형태의 정규분포이다. 즉, 수많은 정규분포 중 하나이다. 표준정규분포는 평균(μ)은 0이고, 분산(σ^2)은 1인 정규분포이다((5.5)).

$$Z \sim N(0, 1) \quad (5.5)$$

표준정규분포는 왜 필요할까? 정규분포상에서 확률분포가 특정 구간내의 값을 가질 확률을 직접 구하기 어려운 문제를 푸는데 사용된다. 수없이 많은 확률변수 X 는 수없이 많은 평균과 표준편차 값을 갖고 있다. 따라서 특정 구간의 확률을 구하기 위해서는 각각의 확률밀도함수를 일일이 적분해야만 한다. 우리가 가설검정을 할때마다 적분을 해야한다고 생각해보자. 얼마나 끔찍하고 지루한가! 다행히 정규분포를 따르는 모든 확률변수는 표준화를 통해 표준정규분포로 변환시킬 수 있다. 따라서 표준정규분포의 구간 적분값을 이용해서 모든 정규분포의 구간 적분값을 구할 수 있다. 모든 확률변수는 (5.6)과 같이 선형적 변형에 의해 표준정규분포로 만들 수 있다.

$$Z = \frac{x - \mu}{\sigma} \quad (5.6)$$

만일 내가 갖고 있는 확률변수 X 의 분포가 평균 100, 분산은 25라고 가정해보자. 확률변수 X 가 90보다 크고 100보다 작을 확률을 구한다면 다음과 같이 확률변수 X 를 Z -score로 표준화한다.

$$X \sim N(100, 5^2), P(90 < X < 100) Z \sim N(0, 1^2), P\left(\frac{90 - 100}{5} < Z < \frac{100 - 100}{5}\right) \quad (5.7)$$

우리는 표준정규분포의 $P(-2 < Z < 0)$ 의 확률을 확인함으로써, 별도의 적분없이 확률변수 X 의 구간의 확률을 구할 수 있다. 왜냐하면 표준정규분포의 구간확률은 이미 계산되어 알려져있기 때문이다. 거의 모든 통계책의 뒷면을 보면 표준정규분포를 포함한 대표분포의 구간확률이 이미 계산되어 있다. (다만 대부분의 통계 소프트웨어에서는 자동으로 확률을 계산해주므로 직접 표를 찾는 경우는 많지 않다)

아래의 Z 분포 표를 이해하는 것은 매우 중요하다. 이후에 가설검정과도 연결되어 있기 때문이다. Z 분포표를 통해 $P(-2 < Z < 0)$ 의 확률을 구해보자. 여기서 약간의 고민이 필요한데 Z 분포표에서는 대부분 양수의 값만을 표시해주기 때문이다. 이때


떠올려야 할 것은 다음의 세가지이다. * (1) 정규분포는 대칭이다. * (2) 정규분포 밀도함수의 면적의 총합은 1이다. * (3) 정규분포밀도함수의 $P(0 < Z < \infty)$ 는 따라서 0.5이다.

이 세 가지 특성을 활용하면 $P(-2 < Z < 0)$ 은 $P(Z < 2)$ 의 0.5와 같음을 알 수 있다. $P(Z < 2)$ 는 Z-score table에서 찾을 수 있다. 아래 표에서는 각 행(row)는 소수점 첫째자리, 각 열(column)은 소수점 둘째자리를 하므로 $P(Z < 2.00)$ 은 0.9772임을 알 수 있다. 우리가 구하고 싶은 값은 $P(-2 < Z < 0)$ 이므로 $0.9772 - 0.5 = 0.4772$ 가 $P(90 < X < 100) = P(-2 < Z < 0) = 0.4772$ 임을 확인할 수 있다. 다시 말해 평균이 100, 분산이 25인 정규분포를 띄는 확률변수 X 가 90보다 크고 100보다 작을 확률이 0.4772이다.

Z-score table을 활용해 정규분포의 특징중 하나를 실제로 확인해보자. 앞서 모든 정규분포는 $\pm 1\sigma$, $\pm 2\sigma$, $\pm 3\sigma$ 이내에 68.26%, 95.44%, 99.74%의 값을 갖는다고 말한바 있다. 표준정규분포 역시 정규분포의 한 종류이기 때문에 이 조건을 만족한다. 표준정규분포의 표준편차는 1이므로 우리가 구해야 구간은 각각 $P(-1 < Z < 1)$, $P(-2 < Z < 2)$, $P(-3 < Z < 3)$ 이다. $P(-1 < Z < 1)$ 의 값만 구해보면, 위의 표에서 $P(Z < 1) = 0.8413$ 이다. 따라서 $P(0 < z < 1)$ 은 $0.8413 - 0.5 = 0.3413$ 의 확률을 갖는다. $P(-1 < Z < 1)$ 은 면적이 두배이므로 $0.3413 \times 2 = 0.6826$ 이 나온다. 전술한 값인 68.26%와 동일한 것을 확인할 수 있다.

5.2.3 카이스퀘어분포 chi-square distribution


다음으로 알아볼 확률분포는 카이제곱분포 chi-square distribution이다. 카이제곱분포는 감마 분포의 일종이다. 카이제곱 분포는 모집단 분산에 대한 가설검정이나 교차분석에서 유용하게 활용된다. 카이제곱분포는 항상 양(positive value)의 값을 가진다는 특징을 갖고 있고, 오른쪽 꼬리가 길게 떨어지는 비대칭 분포이다. 카이제곱분포는 자유도(df)에 따라 모양이 변한다. 자유도의 개념은 이후에 다시 설명하도록 하겠다. 자유도에 따라 카이제곱분포의 모양이 변하는데, 자유도가 커질수록 오른쪽 꼬리가 짧아지면서 분포의 비대칭성이 감소하여 종 모양에 가까워진다.



따라서 카이제곱분포에서 구간 확률을 구할때는 자유도 정보가 반드시 필요하다. 자유도에 따라 확률밀도함수의 모양이 달라지기 때문이다.

5.2.4 F 분포 F distribution

F분포는 ANOVA, 회귀분석 등 우리에게 친숙한 추론통계에서 자주 사용한다. 카이제곱분포를 갖는 2개의 확률변수 값을 각각의 자유도로 나눈 평균 카이제곱값의 비ratio인 F값을 확률변수로 두는 분포를 말한다. 여기서 중요한 개념은 카이제곱분포를 갖는 2개의 확률변수 값인데, ANOVA에서는 집단내 편차와 집단간 편차, 회귀분석에서는 모형설명분산과 residual 분산이 여기에 포함된다. 2개의 확률변수의 카이제곱값의 평균의 비ratio 이기 때문에 자유도 역시 2개가 포함된다 F분포는 카이제곱분포와 유사하게 항상 양의 값만을 가지며, 오른쪽 꼬리 모양을 갖는 비대칭 포이다. 마찬가지로 2개의 자유도 값에 따라 모양이 변하고, 자유도가 커질수록 비대칭성이 줄어들고 1 주변에 집중된다.



5.3 중심극한정리

지금까지 확률변수와 이들의 대표적인 분포에 대해 알아보았다. 지금부터는 추론 통계에서 매우 중요한 개념인 중심극한정리에 대해 이해해보자. 중심극한정리는 강의를 할때마다 설명에 애를 먹는 개념중 하나다. 학생들이 헷갈려하는 포인트가 제각각이다. 중심극한정리를 식으로는 쓸수 있지만 무슨 뜻인지 모르거나, 중심극한정리가 추론통계에서 사용되는 연결고리를 잘 이해하지 못하거나 하는 식이다, 이해를 돕는데 가장 효과적이었던 것은 실제 사례를 중심으로 시뮬레이션 해보는 것이다. 앞으로 몇 페이지에 걸쳐 지루한 이야기를 하겠지만 이 챕터를 읽다가 책을 덮는 일이 발생하지 않았으면 하는 바람이다. 왜냐하면 너무나 중요한 개념이기 때문이다.

5.3.1 표본평균과 표본평균 분포

중심극한정리를 설명하기 전에 알아야 할 내용은 표본평균(sample mean)의 개념과 표본평균의 분포이다. 우선 표본평균은 우리가 어떠한 모집단에서 추출한 n 개의 자료에서 측정한 무선변수 X 의 평균으로 $\bar{X}$ 로 표현한다. 간단하게 서울대학교 재학생을 모집단population으로 정의하고, 이 가운데 5명의 표본sample을 표집sampling했다고 가정해보자. 그리고 이들의 키를 cm로 측정한 결과를 확률변

수 X 로 정의했다.

서울대 population -> 5명표본 -> 키측정

그 결과 5명의 학생의 키를 통해 확률변수 X 의 5개의 값이 확인되었다.

- 1번학생 : 165cm -> X_1
- 2번학생 : 168cm -> X_2
- 3번학생 : 170cm -> X_3
- 4번학생 : 175cm -> X_4
- 5번학생 : 177cm -> X_5

이 5개의 확률변수는 동일한 모집단(서울대학교 재학생)에서 추출되었다. 만일 모집단의 분포가 평균 μ , 분산은 σ^2 인 정규분포라고 가정해보자. 그리고 각각의 확률변수는 모두 독립적이다. 이를 간단히 표현하면 다음과 같다. 이때, i.i.d는 identically and independently distributed의 약자이다. 확률변수가 독립적이며 동일한 분포를 취한다는 뜻이다. 이를 수식으로 쓰면 (5.8)와 같다.

$$X_1, X_2, \dots, X_n \sim i.i.dN(\mu, \sigma^2) \quad (5.8)$$

다음으로 다섯개의 확률변수 값의 평균을 구해보자.((5.9))

$$\bar{X} = \frac{X_1 + X_2 + X_3 + X_4 + X_5}{5} = \frac{\sum_{i=1}^n X_i}{n} \quad (5.9)$$

위의 사례에서는 $(165 + 168 + 170 + 175 + 177)/5 = 171$ 로 우리가 우연히 뽑은 표본의 표본평균 $\bar{X}$ 는 171이다. 이 값은 $\bar{X}$ 가 취할 수 있는 무한대로 다양한 값 중에 하나에 불과하다(서울대 재학생중에 5명을 무작위로 계속 뽑는다고 생각해 보면, $\bar{X}$ 는 다양한 값들이 나온다는 점을 상기해보자). 추가적으로 이해해야 할 부분은 표본평균 $\bar{X}$ 는 확률변수 X 의 일차함수적(선형적) 결합이라는 것이다(평균을 산출하는 식을 생각해보자.). 따라서 확률변수 X 가 정규분포를 따르기 때문에 $\bar{X}$ 도 정규분포를 따른다. 다만 $\bar{X}$ 가 취하는 정규분포의 평균과 분산은 달라진다.

우선 표본평균 $\bar{X}$ 의 평균 $\mu_{\bar{X}}$ 를 구해보자((5.10)). (X 의 평균이 아니라 $\bar{X}$ 의 평균임을 잊지말자!!)

$$\begin{aligned}\mu_X = E(\bar{X}) &= E((X_1 + X_2 + \dots + X_n) \times \frac{1}{n}) = \frac{1}{n} \times [E(X_1) + E(X_2) + \dots + E(X_n)] \\ &= \frac{1}{n} \times (\mu \times n) = \mu\end{aligned}\quad (5.10)$$

다음으로 표본평균 $\bar{X}$ 의 분산 σ_X^2 를 구해보자((5.14)

$$\begin{aligned}\sigma_X^2 &= Var(\bar{X}) = Var((X_1 + X_2 + \dots + X_n) \times \frac{1}{n}) \\ &= \frac{1}{n^2} \times [Var(X_1) + Var(X_2) + \dots + Var(X_n)] \\ &= \frac{1}{n^2} \times (\sigma^2 \times n) = \frac{\sigma^2}{n}\end{aligned}\quad (5.11)$$

(5.10)와 (5.14)를 다시 정리해보면 (5.12)과 같다. 표본평균의 분포는 모집단의 평균과 같은 μ 를 평균으로 하고, 모집단의 분산 σ^2 를 표본수 n 으로 나눈 σ^2/n 을 분산으로 하는 정규분포의 형태를 취하게 된다. (5.12)은 표본평균의 표본분포(sampling distribution of sample mean)

$$\bar{X} \sim n(\mu, \frac{\sigma^2}{n}) \quad (5.12)$$

이처럼 표본평균의 분포는 모집단의 분포의 평균과 분산, 그리고 표본수(sample size)의 정보를 알면 쉽게 예측할 수 있다. 표본평균의 표본분포(sampling distribution of sample mean)의 성질에 대해 이해하였으니 다음으로 중심극한정리에 대해 알아보도록 하자. 중심극한정리를 간단히 정의해보면 다음과 같다.

- (1) 모집단이 어떠한 분포를 하던지간에
- (2) 모집단으로부터 추출한 표본의 크기(n)가 커질수록
- (3) 표본평균이 정규분포에 준하는 분포가 된다는 것이다.
- (4) 이때 표본평균분포의 평균과 분산은 모집단의 평균(μ)과 모집단 분산을 표본수로 나눈 값($\frac{\sigma^2}{n}$)과 같아짐을 알 수 있다.

앞서 설명한 표본평균의 표본분포는 모집단 평균과 분산값을 모두 알고 있는 상황을 가정해보았다. 그러나 일반적인 연구 상황에서는 우리가 갖고있는 자료는 다양한 경우의 수 중 하나에 불과한 수 개의 표본이 전부이다. 서울대학교 재학생이라는 모집단의 평균과 분산값에 대한 정보는 없는 것이다. 다행히 중심극한정리를 통해 모집단의 분포가 어떠한 모양이던 상관없이 표본평균의 분포가 정규분포한다는 사실을 알게 되었기 때문에 표본평균의 분포의 모습을 예측하고, 구간내의 값을 가질 확률을 계산 할 수 있는 것이다.

중심극한정리의 수학적 증명은 복잡하기 때문에 생략하고, 사례 중심으로 이해해보자.

5.3.2 예제를 통해 이해하는 중심극한정리

중심극한정리를 이해할때 가장 헷갈리는 개념은 **표본평균의 평균**과 **표본평균의 분포**이다. 평균이라는 말이 두번 나오다보니, 많은 사람들이 그냥 표본평균으로 오해하기도 한다. 이처럼 헷갈리는 개념들이 있는 경우에는 실제 데이터를 만들어서 일일이 손으로 풀어보는것이 가장 확실하다.

다음과 같은 모집단이 있다고 생각해보자. 모집단은 총 6명의 사람이며, 이때 확률변수(X)는 각각의 사람들의 자녀수라고 정의해보자. 모집단인 6명의 자녀수가 아래와 같다고 생각하자

- 1번 사람 : 자녀 1명
- 2번 사람 : 자녀 2명
- 3번 사람 : 자녀 3명
- 4번 사람 : 자녀 4명
- 5번 사람 : 자녀 5명
- 6번 사람 : 자녀 6명

통상적으로 6명의 사람을 조사해보면 자녀2명인 사람이 많이 나올법도 한데, 이 모집단은 유니폼 분포를 갖고 있다. 즉, 자녀 1명인 사람은 상대도수가 $1/6$, 자녀 2명인 사람도 상대도수가 $1/6, \dots$ 자녀 5명인 사람도 상대도수가 $1/6$ 로 모든 모집단에 속한 개체의 상대도수가 서로 같다. 만약 우리가 이 모집단 6명에게 모두 접근할 수 있어서 표본을 추출해야 한다고 가정해보자. 표본은 1명 추출($n=1$), 2명 추출($n=2$), 3명추출($n=3$)까지 다양히 시도해보자.

표본을 추출하는 것은 모집단에 해당되는 공을 하나의 주머니에 넣고, 손을 집어넣어서 무작위로 추출하는 과정과 같다. 표본을 1명추출하는 것은 주머니속에 손을 넣어 1개의 공만 추출하는 것이다. 우리는 고등학교때 이미 경우의 수를 계산하는 방법을 배웠기 때문에 표본수에 따른 표본의 경우의 수도 계산할 수 있다. 먼저 1명을 추출한다고 생각해보면 $6C1=6$ 개의 경우의 수가 생긴다. 다시 말하면 6명의 모집단에서 추출가능한 표본(sample)은 6가지의 경우이다. 이를 일일이 표현한 것이 아래의 표이다. 가장 왼쪽 칼럼을 보면 표본수가 1일때 가능한 표본의 경우의 수가 제시되어 있다. 그렇다면 표본 평균(sample mean)이란 무엇인가? 간단하다 해당 표본의 확률변수 X 의 값이 평균이다. 1번 사람이 표본으로 뽑혔다면 이때의

표본평균은 당연히 1이다(자녀수(확률변수 X)가 1이므로)

그렇다면 표본평균의 평균(mean of sample mean)은 무엇인가? 말그대로 가능한 모든 표본의 $\rightarrow$ 각각의 평균값의 $\rightarrow$ 평균값이다. 좀더 정확히 이해하기 위해 표본수를 2개로 늘린 3번째, 4번째 칼럼을 통해 설명해보자. 만일 우연히 추출한 표본 2개가 1번째, 2번째 사람이었다면, 이들의 자녀수는 각각 $\{1, 2\}$ 이고, 따라서 표본의 평균은 $(1+2)/2 = 1.50$ 이다. 표본 개수가 2개인 경우 추출 가능한 표본의 경우의 수는 $6C2=15$ 가지이다. 15가지의 추출가능한 표본평균의 평균은 $(1.50+2.00+\dots+5.00+5.50)/15 = 52.5/15 = 3.5$ 이다. 한편 표본평균의 분산 1.166으로 모집단의 분산보다 줄어든 것을 볼 수 있다. 표본을 3개 추출한 경우에는 어떠한가? 이때의 표본평균의 평균은 역시 3.5이고, 표본평균의 분산은 0.583으로 크게 줄어들었다.


이 사례에서 우리는 모집단의 분포를 알고 있다. 1부터 6까지 균등한 상대도수 ($p=1/6$)를 갖고 있는 유니폼분포이며, 평균은 3.5, 분산은 2.916이다. 이 모집단에서 표본을 1개, 2개, 3개로 추출해보니, **표본평균**의 평균은 3.5으로 모집단의 평균과 같고, 분산은 모집단의 분산보다 작으며, 표본수(n)가 증가할 수록 분산은 점점 작아지는 것을 알 수 있다¹. 따라서 (5.12)가 확인됨을 알 수 있다.

n=1	sample mean	n=2	sample mean	n=3	sample mean
{1}	1.00	{1,2}	1.50	{1,2,3}	2.00
{2}	2.00	{1,3}	2.00	{1,2,4}	2.33
{3}	3.00	{1,4}	2.50	{1,2,5}	2.66
{4}	4.00	{1,5}	3.00	{1,2,6}	3.00
{5}	5.00	{1,6}	3.50	{1,3,4}	2.66
{6}	6.00	{2,3}	2.50	{1,3,5}	3.00
		{2,4}	3.00	{1,3,6}	3.33
		{2,5}	3.50	{1,4,5}	3.33
		{2,6}	4.00	{1,4,6}	3.66
		{3,4}	3.50	{1,5,6}	4.00
		{3,5}	4.00	{2,3,4}	3.00
		{3,6}	4.50	{2,3,5}	3.33

¹표본평균의 평균과 달리 분산은 공식과 같은 결과가 나오지 않는다. 그 이유는 아래 예시는 비복원추출이기 때문에 finite population correction을 해야하기 때문이다. 이때 표본평균 분산의 공식은 $Var(\bar{X}) = \frac{\sigma^2}{n} \frac{N-n}{N-1}$ 이다

n=1	sample mean	n=2	sample mean	n=3	sample mean
		{4,5}	4.50	{2,3,6}	3.66
		{4,6}	5.00	{2,4,5}	3.66
		{5,6}	5.50	{2,4,6}	4.00
				{2,5,6}	4.33
				{3,4,5}	4.00
				{3,4,6}	4.33
				{3,5,6}	4.66
				{4,5,6}	5.00
평균	3.5	평균	3.5	평균	3.5
분산	2.916	분산	1.166	분산	0.583

아래의 그래프는 표본평균의 분포를 그래프로 표현한 것이다. 이때 x축은 표본평균($\bar{X}$), y축은 상대도수이다. 모집단의 분포는 유니폼분포이지만, sample size가 증가할 수록 표본평균($\bar{X}$)의 분포는 점차 정규분포에 가까워진다.



NULL

다시 한번 중심극한정리에 대해 요약해보면 다음과 같다.


- 우리는 모집단의 분포(분포의 모양, 평균, 분산)에 대해 알지 못한다.
- 모집단이 어떠한 분포를 하던 상관없이 표본크기(n)가 충분히크면(경험적으로는 30이상), 표본평균($\bar{X}$)의 분포는 정규분포한다.
- 또한 표본평균($\bar{X}$)의 분포의 평균은 모집단 평균과 같고, 분산은 모집단 분산을 표본사이즈로 나눈 값에 근사한다.

중심극한정리를 통해 우리는 모집단 분포에 대한 정보가 없이도, 표본평균의 분포가 정규분포에 준하는 분포가 된다는 점을 알게 되었다. 또한 표본평균의 평균과 분산을 통해 모집단의 분포와 관련한 정보도 확인이 가능하다.

5.3.3 시뮬레이션을 통해 이해하는 중심극한정리

위의 사례에서는 표본수를 무한정 늘릴 수 없으니, 복원추출의 방법으로 표본의 크기를 늘려보도록 하겠다. 복원추출이란 모집단에서 추출했던 것을 원래대로 돌려놓고 다시 추출하는 방법을 말한다. {1,2,3,4,5,6} 으로 이루어진 모집단에서 표본수(n) 1, 2, 3, 5, 30 및 100개를 복원 추출해보도록 하자. 이때 추출은 임의로 10,000번으로 설정해보았다. 예를 들어 표본수가 3이라면, 모집단에서 3개의 표본을 10,000번을 추출하여 표본평균의 분포를 그린것이다.

아래 그림과 같이, 모집단이 유니폼 분포를 하더라도, 표본의 수가 늘어날수록 표본평균($\bar{X}$)의 분포는 점차 정규분포에 근사하게 변하고 있다. 또한 표본평균($\bar{X}$)의 평균도 모집단의 평균인 3.5에 근사하고 있고, 분산은 표본수가 증가할수록 점점 줄어드는 것을 확인할 수 있다.



5.4 추정과 가설검정

우리의 관심은 표본(sample)이 아닌 모집단(population)에 있다. 추론통계는 우리가 갖고 있는 자료, 즉 표본(sample)을 통해 모집단(population)의 정보들을 추론한다. 이를 통계적 추론이라고 하는데, 여기에는 추정과 가설검정이 있다.

5.4.1 추정

5.4.1.1 점추정(point estimation)

먼저 추정에 대해 이해해보자. 추정(estimation)이란 표본의 통계량을 통해 모집단의 파라미터를 찾는 것이다. 먼저 모집단의 평균을 추정한다고 생각해보자. 우리가 갖고 있는 것은 모집단에서 추출될 수 있는 무수히 많은 경우의 수 중에 하나인 표본의 평균($\bar{X}$)이다. 모집단의 평균인 (μ)를 추정하기 위해서 사용할 수 있는 것은 표본의 평균($\bar{X}$)이다. 당연히 $\bar{X}$ 는 모집단 평균(μ)과 일치하지 않을 가능성이 높다. μ 를 추정하기 위해 사용할 수 있는 최선의 추정량이 $\bar{X}$ 일뿐이다.

하지만 앞선 중심극한정리에서 모집단의 평균(μ)은 표본의 평균이 아니라 표본평균의 평균과 근사한다는 것을 밝혀냈다 즉, 수많은 표본을 추출하고 각각의 표본에서 추출한 표본의 평균의 평균이 모집단의 평균과 같다는 것이다. 이 정리를 통해

표본평균은 모평균의 불편추정량(unbiased estimator)라고 말할 수 있다² 우리가 갖고 있는 특정한 표본의 평균은 표본평균의 평균에서 어느정도 떨어져있을 것이다. 표본을 반복적으로 추출하면 표본평균은 모집단 평균 주변에서 조금씩 달라진다. 이러한 표본평균의 변동 정도(표본분포의 표준편차)를 표준오차(Standard Error)라고 한다. 표준오차에 대해서는 가설검정시 다시 설명하도록 하겠다.

추정을 위해 한가지 더 고려해야 하는 것은 모집단의 분산이다. 모집단의 분산(σ^2)을 추정하기 위해서는 표본 분산(S^2)을 사용해야 한다. 표본의 분산을 구하는 식 ((5.13))을 상기해보자.

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} \quad (5.13)$$

앞서 중심극한정리를 설명할때 도출하였던 표본평균($\bar{X}$)의 분산의 식은 다음 ((5.14))과 같다.

$$\begin{aligned} Var(\bar{X}) &= Var\left(\frac{X_1+X_2+\dots+X_n}{n}\right) = \frac{Var(X_1)+Var(X_2)+\dots+Var(X_n)}{n^2} \\ &= \frac{n \times Var(X)}{n^2} = \frac{\sigma^2}{n} \approx \frac{S^2}{n} \end{aligned} \quad (5.14)$$

그러나 표본평균의 분산은 모집단 분산(σ^2)의 불편추정량(unbiased estimator)가 아니다. S^2 의 기대값은 σ^2 를 과소 추정하는 경향이 있기 때문이다. n 이 작을수록 과소 추정하는 경향이 크다. 이를 보정하기 위해 분모가 n 이 아닌 $n-1$ 을 사용하는 s^2 을 사용한다.

5.4.1.2 구간추정(interval estimation)

점 추정은 우리가 갖고 있는 표본의 평균을 통해 모집단의 평균을 하나의 값으로 추정하는 것이다. 하지만 앞서 설명한것 처럼 추정오차에 대한 정보가 포함되어 있지 않기 때문에, 이를 해결하기 위해 구간으로 추정하는 방법을 **구간 추정**이라고 한다. 이때 구간은 점추정 $\pm$ 추정오차로 계산된다.

5.4.1.2.1 신뢰구간(confidence interval) 신뢰구간은 연구자가 정한 신뢰수준(confidence level)에 따라 실제 모수(파라미터)가 있을 것이라 예상하는 구간이다. 신뢰구간을 결정하는데는 다음의 두 가지의 정보가 필요하다.

²표본을 한번 추출했을때 정확한값을 없는 것이 아니라, 표본을 반복해서 추출했을때 평균적으로는 모수를 정확하게 추정하는 추정량이라는 뜻이다

- 신뢰 수준(confidence level)
- 표준 오차(standard error)

신뢰 수준은 연구자가 결정한다. 보통 95%, 99%, 99.9%로 결정하며, (1-신뢰수준)을 허용오차 수준(α)라고 정의한다. 허용오차 수준은 5%, 1%, 0.1% 중에 연구자가 결정하게 된다.

표준오차는 표본평균($\bar{X}$)의 표준편차이다. 즉, 표본평균의 분산에 root를 씌운 값이다.

만일 우리가 모집단 평균의 신뢰구간을 추정하려고 한다고 가정해보자. 우리가 갖고 있는 것은 다음의 3가지 정보이다.

- 추출된 표본의 평균 : $\bar{X}$
- 추출된 표본의 표준편차 = 표준오차 : $\frac{s}{\sqrt{n}}$
- 허용오차 수준(α) = 1-신뢰수준 = 5% (연구자가 결정)

이 세가지 정보를 활용해서 신뢰구간을 계산하는 식은 아래((5.15))와 같다.

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \bar{X} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}} \right] \quad (5.15)$$

수식이 복잡한 것처럼 보이지만 표본평균을 중간에 두고 표준오차와 신뢰수준의 t 값을 곱한 값만큼 좌우(±)로 떨어진 값이 바로 신뢰구간이다. 예를 들어 우리가 서울대학교 학생 중 무작위로 25명을 뽑아 키를 관찰하였더니 평균 170, 표준편차가 10이었다고 생각해보자. 95%의 신뢰구간을 계산하면 다음과 같다.

- 표본평균 : $\bar{X} = 170$
- 표준오차 : $10 / \sqrt{25} = 10/5 = 2$
- 신뢰수준(95%)에 따른 t값 : t분포에서 확률밀도 함수의 면적이 0.95인 지점 = 2.064

따라서 신뢰구간은 다음((5.16))과 같이 결정된다.

$$\begin{aligned} & \left[170 - 2.064 \times \frac{10}{5}, \quad 170 + 2.064 \times \frac{10}{5} \right] \\ & = [165.87, \quad 174.13] \end{aligned} \quad (5.16)$$

5.4.2 신뢰구간의 해석

위의 신뢰구간은 어떻게 해석해야 할까? 많은 논문에서 신뢰구간의 해석에 대한 오류를 범하고 있는데, 김창택(2020)의 저서(사회과학을 위한 고급통계학:R을 이용한 분석)에서 보다 명쾌한 해석 가이드라인을 제시한바 있다. 이 책을 기초로 설명하면 다음과 같다.

- 서울대학교 학생의 평균키는 95%의 확률로 165.87과 174.13 사이에 있다(X)
- 서울대학교 학생이라는 모집단 안에서 무한히 많은 표본을 추출하고, 각 표본에 대하여 신뢰구간을 구하였을때, 그 신뢰구간 중 95%가 서울대학교 학생의 평균키를 포함하고 있다 (O)

서울대학교 학생이라는 전체 모집단에서 무작위로 25명을 1000번 추출하였다고 가정해보자. 1000개의 서로다른 표본은 각각의 서로 다른 표본평균과 표준오차를 가지고 있을 것이다. 따라서 동일한 신뢰수준(95%)로 신뢰구간을 계산하더라도, 1000개의 서로 다른 신뢰구간이 계산될 것이다. 이때 950개의 신뢰구간은 모집단의 평균, 즉 서울대학교 학생 전체의 평균키를 신뢰구간 내에 갖고 있을 것이고, 50개의 신뢰구간은 구간내에 모평균을 갖고 있지 않는다. 이를 그림으로 표현하면 다음과 같다.




그림 5.2: 신뢰구간의 정확한 해석

제 6 장

t검정과 ANOVA

- 모집단 평균에 관한 가설검정 종류
- t검정 (t-test)
 - t검정의 개념 및 가정
 - 단일 모집단평균에 대한 t 검정
 - 동일 모집단 반복측정 평균에 대한 t 검정(paired t-test, 쌍
체비교)
 - 두 모집단 평균에 대한 t 검정
 - t검정 효과 크기
 - R을 활용한 t 검정 실습
- 분산분석 (ANOVA)
 - 분산분석 (ANOVA)의 개념
 - 일원분산분석 (one-way ANOVA) 공식
 - 손으로 푸는 일원분산분석 (one-way ANOVA)
 - R을 활용한 일원분산분석 (one-way ANOVA)

6.1 모집단 평균에 관한 가설검정

모집단에 대한 가설검정은 검정 대상에 따라 크게 두가지 종류가 있다. (1) 모집단의 평균(μ) 검정, (2) 모집단의 분산(σ^2) 검정이다. 검정 대상이란 무엇일까? 앞서

살펴본 중심극한정리에 따라 우리는 소량의 표본(sample)의 통계량(표본평균, 표본분산)을 활용해 모집단의 모수(모집단 평균, 모집단분산)를 추정할 수 있음을 이해했다. 여기서 가설검정이란 표본으로부터 얻은 정보를 이용하여 모집단의 모수(예: 모집단 평균, 모집단 분산)에 대한 가설이 타당한지를 판단하는 절차이다.

아래와 같이 가설검정 대상에 따라 검정 방식은 모두 달라진다. 모집단 평균을 검정하는 경우 모집단의 수에 따라 검정방식이 달라진다.

- 1개 모집단의 평균을 검정 : t 검정 (예: H1: 서울대학교 학생들의 평균키는 165cm이다)
- 2개 집단의 평균 차이 검정 : 단일 모집단 t검정 : (H1: 서울대학교 남학생의 입학당시 IQ와 졸업당시 IQ는 차이가 있다) 두 모집단 t검정 : (H1: 서울대학교 남학생과 여학생의 평균키는 차이가 있다)
- 3개 모집단의 평균 차이 검정 : ANOVA (H1: 서울대학교 학생의 GPA는 학년별(1/2/3/4학년)로 차이가 있다)

한편 모집단 분산을 검정하는 경우에도 모집단의 수에 따라 검정방식은 다르다

- 1개 모집단의 분산을 검정 : 카이제곱 검정
- 2개 모집단의 분산을 검정 : F 검정

이 장에서는 산업인력개발 분야에서 주로 쓰이는 모집단 평균 검정에 국한하여 살펴보도록 하겠다.

6.2 t 검정 (t-test)

6.3 t 검정 (t-test)의 개념 및 가정

t 검정에 대해 알아보기 전에, 먼저 가설검정에 대해 좀더 자세히 알아보자. 가설 검정은 연구자가 세운 가설(alternative hypothesis)이 참인지 확인하는 절차이다. 그러나 연구가설을 직접 검정하는 것이 아니라, 영가설, 또는 귀무가설(null hypothesis)을 기각하는 방식으로 연구가설을 채택한다. 다음의 예시를 통해 이해해보자.

- 서울대학교 학생회관 근처를 지나가는 학생들 100명을 표집하여 키(cm)를 측정했더니 평균 168cm가 나왔다. 이 평균키가 서울대학교 전체 학생들의 키 분포에서 나왔는지, 아니면 다른 분포에서 나왔는지 검증하려고 한다(예: 서울대학교 농구부 학생들처럼 키가 큰 학생들의 분포에서 나왔는지)

- 서울대학교 전체 학생의 평균키는 평균키 165cm, 분산은 4인 정규분포를 따른다는 정보를 알고 있다. 우리가 갖고 있는 표본이 이 분포에서 나왔다고 가정하자($H_0: X \sim N(165, 4)$)
- 평균을 검정하는 것이므로 영가설과 연구가설은 다음과 같이 쓸 수 있다.
 $H_0: \mu_x = 165 \quad H_1: \mu_x \neq 165$
- 표본의 평균키인 168cm가 $N(165, 4)$ 의 분포에서 나올 확률을 구한다.
- 만일 유의확률(p-value)이 유의수준보다 낮으면, 표본의 평균키가 해당분포에서 나올 확률은 극히 드물것이다. 따라서 표본은 서울대학교 전체 학생들의 키 분포에서 나왔다는 영가설을 기각하고, 우리의 표본은 다른 모집단에서 추출되었다는 연구가설(H_1)을 채택할 수 있다.

하지만 대부분의 경우 우리는 모집단의 분포에 대한 정보(μ, σ^2)를 알지못한다. 따라서 표본의 평균($\bar{X}$)과 표본의 분산(S^2)를 사용하여 모집단의 평균과 분산을 추정할 수 밖에 없다는 것을 기억하자.

6.3.1 단일 모집단 평균에 대한 t 검정

단일 모집단 평균에 대한 t 검정은 우리가 수집한 표본의 평균이 모집단 평균과 차이가 있는지를 확인하는 검정방식이다. 좀더 구체적으로 설명한다면 표본의 평균이 모집단의 분포에서 나온것인지를 확인하는 것이다. 다음의 예시를 살펴보자

- A회사는 자사의 노트북 배터리 용량이 길다고 홍보하고 있다. 제품 스펙에는 배터리 용량이 80시간으로 되어 있는데, 소비자들은 80시간보다 짧은 것 같다고 불만을 나타내고 있다. 이를 확인하기 위해 우리는 A회사 노트북 100개를 무작위로 수집하여 배터리 용량을 각각 측정해보았다. 측정결과 표본 100개의 평균 배터리 용량은 평균 79시간이었고, 분산은 4였다. 노트북 배터리가 80시간보다 짧은지 유의수준 0.05에서 검증해보자.

위와 같은 예시에서 연구가설과 영가설은 다음과 같이 쓸 수 있다.

$H_1: \mu < 80$ (노트북의 배터리 용량은 80시간보다 작다) $H_0: \mu \geq 80$
 $\bar{X} = 79, S^2 = 4$
 노트북의 배터리 용량은 80시간과 같거나 크다.

즉, 우리가 수집한 100개의 노트북 배터리의 평균 용량 79시간이 $N(80, \sigma^2)$ 의 분포에서 나온것인지 확인하는 것이다. 안타깝게도 모집단의 평균은 80시간으로 알려져있지만 분산값은 확인할 수가 없다. 이 경우는 표본의 분산값을 사용해 모집단의 분산을 추정해야 한다. 앞서 중심극한정리에서 간단히 설명한 바와 같이 모집단의

분산과 표본의 분산은 완전히 일치하지 않지만 가장 적합한 추정량이기 때문에 이를 사용하게 된다.

만일 우리가 모집단의 평균과 분산을 모두 안다면, 표준정규분포로 변환하여 구간확률을 구할 수 있었던 점을 기억하자. 이때 Z-score는 다음과 같은 공식으로 산출된다.

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$


우리는 모집단의 표준편차(sigma)를 알지 못하므로, 표본의 표준편차를 표본크기 제곱근($\sqrt{n}$)으로 나눈값을 활용해 모집단 표준편차를 대체해보자. 이때의 값을 t-score로 명명한다.

$$t = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}$$

$\bar{X} = 79, \mu = 80, S = 2, n = 100$ 이므로 t값은 다음과 같이 계산된다.

$$t_{\bar{X}} = \frac{79-80}{2/\sqrt{100}} = -5$$

산출된 t값 -5는 검정통계량이라고 하며, 검정통계량을 임계치와 비교함으로써 연구가설의 채택여부를 결정한다. 우리의 유의수준은 .05이며, 자유도 99(100-1)의 t값의 임계치는 -1.66이므로 절대값이 임계치보다 크다. 따라서 영가설을 기각하고 연구가설을 채택할 수 있다.



따라서 유의수준(α) 0.05에서 A 회사의 노트북 배터리의 평균 용량은 우리의 주장대로 80시간보다 작은 것으로 판단된다.

6.3.2 동일 모집단 반복측정 평균에 대한 t 검정

동일 대상을 반복측정한 두 평균에 대한 t 검정은 흔히 쌍체비교 t 검정 (paired t-test)이라고 불린다. 산업인력개발분야에서 가장 대표적인 쌍체비교 t 검정 사례는 교육훈련 프로그램 전/후의 직무 수준의 차이가 통계적으로 유의미한지를 확인하는 주제일 것이다. 예를 들어 A 회사의 25명의 사람들에게 특정한 직무훈련프로그램을 제공하였다고 가정해보자. 우리는 직무훈련 프로그램의 효과성을 검증하기 위해 훈련프로그램 전/후의 직무 수준을 측정할 것이다. 25명의 사람들의 교육전 직무 수준을 측정하였더니 평균 3.00(5점 만점)이었다. 직무훈련프로그램을 이수한 후에 동일한 측정도구로 직무 수준을 측정하였더니 평균 3.30(5점 만점)이 나왔다. 프로그램은 효과적이었는가? 다시 말해 훈련프로그램 전 후의 직무수준은 유의미한 차이가 있는가?

위의 실험에서 우리는 동일한 모집단에게서 반복 측정된 숫자 두 가지를 갖게 된다. 첫번째 사람의 훈련 전/후 직무수준, 두 번째 사람의 훈련 전/후 직무 수준...25 번째 사람의 훈련 전/후 직무수준으로 총 50개의 자료를 얻었다. 이들 자료는 전체 평균으로 비교할 것이 아니라 동일한 개인의 사전/사후 검사를 비교해야만 의미가 있을 것이다. 즉, 쌍별(paired) 평균 비교를 해야 한다.

관련한 쌍체비교 t 검정을 하기 위해 연구가설과 영가설을 다음과 같이 쓸 수 있다.

$H_1 : \mu_{\bar{d}} = \mu_{X_A} - \mu_{X_B} > 0$ (훈련프로그램 사후 직무수준이 사전 직무수준보다 크다) $H_0 : \mu_{\bar{d}} = \mu_{X_A} - \mu_{X_B} = 0$ (훈련프로그램 사전/사후 직무수준의 차이는 없다)

```
##
```

```
## Attaching package: 'kableExtra'
```

```
## The following object is masked from 'package:dplyr':
```

```
##
```

```
## group_rows
```

쌍체 비교는 두개의 통계량(사전 측정값의 평균, 사후 측정값의 평균)이 존재하지만, 가설검정을 위해서는 사전/사후의 차이(differences)의 평균값만을 활용한다. 위의 표와 같이 25명의 사전/사후 직무수준 측정값을 갖고 있다면, 세 번째 열인 사전/사후 차이값을 하나의 새로운 변수로 만든뒤, 그 차이의 평균이 0인지 검정한다.

표 6.1: 대응표본 t 검정을 위한 예제 데이터

ID	Pre-test	Post-test	Difference (d)	$(d - \bar{d})^2$
1	3.0	3.2	0.2	0.003
2	3.5	3.8	0.3	0.002
3	3.2	3.4	0.2	0.003
4	3.0	2.8	-0.2	0.208
5	2.8	3.5	0.7	0.197
6	3.1	3.2	0.1	0.024
7	3.1	3.3	0.2	0.003
8	3.2	3.7	0.5	0.060
9	2.9	3.1	0.2	0.003
10	3.0	3.8	0.8	0.296
11	3.0	3.3	0.3	0.002
12	3.1	2.9	-0.2	0.208
13	3.3	3.1	-0.2	0.208
14	2.0	2.8	0.8	0.296
15	3.5	3.6	0.1	0.024
16	3.2	3.5	0.3	0.002
17	3.3	3.7	0.4	0.021
18	2.8	2.9	0.1	0.024
19	2.9	2.9	0.0	0.066
20	2.9	3.6	0.7	0.197
21	2.7	3.3	0.6	0.118
22	3.2	3.5	0.3	0.002
23	3.0	3.1	0.1	0.024
24	3.1	3.4	0.3	0.002
25	2.8	2.6	-0.2	0.208

따라서 가설을 검정하는 방식이 단일 모집단 평균에 관한 검정과 같다.

위의 가설을 다시 설명해보면 $\mu_{\bar{d}}$ 가 평균이 0인 분포에서 도출된 것인지를 검정하는 것이다. 즉 평균이 0인 분포에서 나왔다면 영가설이 채택되고, 그렇지 않다면 연구가설이 채택될 것이다. 마찬가지로 모집단의 표준편차(σ)는 알 수 없으므로 표본의 표준편차를 사용하는 것이 최선의 대안일 것이다. 표본의 표준분산은 위의 표의 네번째 열을 표본크기-1(n-1)로 나뉜 값이고, 표준편차는 표준분산의 제곱근이다.

$$s_d^2 = \frac{\sum_{i=1}^n (d_i - \bar{d})^2}{n - 1} = \frac{2.2016}{24} = 0.0917 \quad (6.1)$$

$$s_d = \sqrt{0.0917} = 0.303 \quad (6.2)$$

표준오차(standard error)는 다음과 같이 구한다.

$$SE_{\bar{d}} = \frac{s_d}{\sqrt{n}} = \frac{0.303}{\sqrt{25}} = 0.0606 \quad (6.3)$$

t값을 구하는 공식은 다음과 같다.

$$t = \frac{\bar{d} - \mu_d}{SE_{\bar{d}}} \quad (6.4)$$

여기서 $\bar{d} = 0.256$, $\mu_d = 0$, $SE_{\bar{d}} = 0.0606$ 이므로 t값은 다음과 같이 계산된다.

$$t = \frac{0.256 - 0}{0.0606} = 4.23 \quad (6.5)$$

- 왼쪽꼬리 검정
- 오른쪽 꼬리 검정
- 양쪽꼬리 검정

6.3.3 두 모집단 평균에 대한 t 검정

독립적인 두 모집단 평균에 대한 t 검정도 산업인력개발분야에서 많이 활용된다. 예를 들어 직무만족수준이 성별(남/여)에 따라 차이가 있는지? 삶의 만족도가 취업 여부(취업/미취업)에 따라 차이가 있는지를 검증하는 것이 이에 해당된다. 집단간 평균차이 검정은 두집단인 경우에만 t검정을 하고 세 집단 이상인 경우에는 분산 분석(ANOVA)를 실시함을 반드시 기억하자!

이번에도 예시를 들어 가설을 검정해보자. 서울대학교 학생들의 성격요인 중 성실성(conscientiousness) 점수가 성별에 따라 차이가 있는지 검증하고자 한다. 각각 25명의 남학생과 여학생을 표본으로 선정하여 성실성 점수를 측정하였더니 100점 만점에 남학생은 평균 75점, 분산은 9, 여학생은 평균 80점, 분산은 16이 나왔다. 서울대학교 남학생과 여학생의 성실성 점수는 통계적으로 유의한 차이가 있는지 유의수준(α)검증해보자.

두 집단의 평균에 차이가 있는가를 검증하는 것은 두집단 평균의 차이가 0이 아닌 것을 증명하는 것과 같다. 따라서 위의 예시를 기반으로 가설을 작성하면 다음과 같다.

$H_1 : \mu_M - \mu_F \neq 0$ (남학생과 여학생의 성실성 점수의 차이가 있다) $H_0 : \mu_M - \mu_F = 0$ (남학생과 여학생의 성실성 점수의 차이는 없다)

이때 $\bar{X}_M - \bar{X}_F = -5$, $\mu_M - \mu_F = 0$, $n_M = 25$, $n_F = 25$ 임을 우리는 알고 있다. 모 집단이 두개이기 때문에 차근차근 생각해보자. 먼저 두집단의 평균차이($\bar{X}_M - \bar{X}_F$)는 무선변수의 선형적인 결합이기 때문에, 각 집단의 평균이 정규분포를 따른다면 이들의 선형함수인 평균차이 역시 정규분포를 따른다. 문제는 분산과 표준편차인데, 역시나 모집단(서울대학교 전체 학생)의 분산을 알수 없으므로 통계량을 통해 추정해야 한다.

두 모집단이 독립적이라고 가정한다면 모분산은 다음과 같이 계산할 수 있다.

$$\sigma_{\bar{X}_M - \bar{X}_F}^2 = \text{var}(\bar{X}_M - \bar{X}_F) = \text{var}(\bar{X}_M) + \text{var}(\bar{X}_F) = \frac{\sigma_M^2}{N_M} + \frac{\sigma_F^2}{N_F}$$

$$\sigma_{\bar{X}_M - \bar{X}_F} = \sqrt{\frac{\sigma_M^2}{N_M} + \frac{\sigma_F^2}{N_F}}$$

만일 두 모집단의 분산이 서로 같다는 가정을 할 수 있다면 두개의 표본을 합쳐서 하나의 표본으로 생각하고, 통합된 분산을 구하여 표준 오차를 구한다. (6.6)

$$S_{\bar{X}_M - \bar{X}_F} = \sqrt{S_p^2 \left(\frac{1}{n_M} + \frac{1}{n_F} \right)} \text{ when } S_p^2 = \frac{(n_M - 1)S_M^2 + (n_F - 1)S_F^2}{n_M + n_F - 2} \quad (6.6)$$

이때의 자유도는 다음과 같이 계산된다. (6.7)

$$df = \left(\frac{(S_m^2/n_m + S_f^2/n_f)^2}{\frac{(S_m^2/n_m)^2}{(n_m-1)} + \frac{(S_f^2/n_f)^2}{(n_f-1)}} \right) \quad (6.7)$$

반대로 두 모집단의 분산이 서로 다르다면, 두 집단별 표본분산을 각각의 표본개수로 나누어 더한 다음 루트를 씌워서 표준오차를 구한다.(6.8)

$$S_{\bar{X}_M - \bar{X}_F} = \sqrt{\frac{S_M^2}{N_M} + \frac{S_F^2}{N_F}} \quad (6.8)$$

다시 예시로 돌아와서, 남학생과 여학생의 성실성 수준에 차이가 있는가를 검증해보자. 모집단 분산이 서로 다르다고 가정하면 다음과 같다. 먼저 자유도를 계산해보면 다음과 같다.

$$df = \left(\frac{(9/25 + 16/25)^2}{\frac{(9/25)^2}{24} + \frac{(16/25)^2}{24}} \right) = 44.51 \quad (6.9)$$

또한 이때의 검정통계량 t 값은 다음과 같다.

$$t_{\bar{x}_m - \bar{x}_f} = \frac{(\bar{x}_m - \bar{x}_f) - (\mu_m - \mu_f)}{\sqrt{\frac{S_m^2}{n_m} + \frac{S_f^2}{n_f}}} = \frac{(-5) - (0)}{\sqrt{9/25 + 16/25}} = -5 \quad (6.10)$$

$t_{(0.25, 44.51)}$ 는 ± 1.96 으로 검정통계량 t 인 -5 보다 절대값이 작으므로, 영가설을 기각하고 연구가설을 채택할 수 있다. 즉, 유의수준(α)에서 서울대학교 남학생과 여학생의 성실성 평균수준은 모집단에서도 차이가 있는 것으로 판단할 수 있다.

6.3.4 t 검정에서의 효과크기와 검증력

6.3.4.1 가설검증의 오류(errors)

검증력에 대한 설명을 위해서는 가설검증시 발생가능한 두 가지 종류의 오류(error)에 대해 설명할 필요가 있다. 흔히 1종 오류, 2종 오류라 불리우는데, 직관적인 이해를 위해 양치기 소년 일화를 통해 이해해보자.

양치기 소년이 늑대가 오지 않았는데 늑대가 나타났다고 소리를 질렀다. 마을 사람들은 늑대가 나타났다고 믿고 달려갔지만 거짓말임을 알게 되었다(type 1 error : H_1 이 거짓이지만 H_1 을 채택하는 확률). 며칠이 지나고 진짜 늑대가 나타났고(H_1 은 참), 양치기 소년이 소리를 질렀지만, 마을 사람들은 믿지 않았다(H_1 : reject). 결국 늑대는 양을 모두 잡아먹었다(type 2 error : H_1 이 참이지만, H_1 을 기각하는 확률)

위의 일화를 통해 1종오류와 2종오류를 정의해 보면 아래 표와 그림과 같다. 앞선 예시에서는 H_1 (연구가설)을 기준으로 설명하였지만, 엄밀히 말해서 가설검정은 H_0 (영가설)을 검증하는 것이기 때문에 1종/2종 오류를 정의할때도 H_0 (영가설)을 중심으로 설명한다.

구분	영가설 참	영가설 거짓
영가설 채택	옳은 결정	2종 오류(beta)
영가설 기각	1종 오류(alpha)	옳은 결정

그림을 보면 1종 오류와 2종오류의 정의를 좀더 쉽게 이해할 수 있다. 영가설이 참이지만 영가설이 기각될 확률은 유의수준(alpha) 와 같다. 반면 영가설이 거짓이지만 영가설을 채택하는 확률은 beta로 표기한다. 그림에서 이해를 할 수 있듯이 1종오류 확률과 2종 오류 확률은 서로 trade-off관계이다. 즉, 1종오류가 커지면 2종오류는 줄어든다. 따라서 검정할 가설의 종류에 따라 어떤 오류가 더 치명적인지 결정하고 연구에 반영할 필요가 있다. 일반적으로 사회과학에서는 1종 오류에 대해 더욱 중요하게 다루므로 유의수준의 기준(예: alpha=0.05, 0.01 등)을 엄격하게 살피는 경향이 있다.

2종오류는 beta로 표기하는데, 그 자체를 활용하기 보다 1-beta에 해당되는 검정력(power)로 치환하여 살펴보게 된다. 검정력은 2종오류의 반대 개념이기 때문에 클수록 바람직하다. 이를 위해서 보통 통용되는 검정력을 만들기 위해 적절한 표본 크기를 계산하는데 사용된다. 검정력에 대해서 좀더 알아보자.

6.3.4.2 효과크기 (effect size)

검정력(1-β)은 크게 세 가지 요소에 의해 결정된다. 유의수준, 표본 크기, 그리고 효과크기이다. 효과크기라는 새로운 개념이 등장했다.


효과크기(effect size)는 가설 검정 유형에 따라 다양한 지표를 사용할 수 있다. 예를 들어 두 모집단 평균차이에 관한 검정을 할때는 코헨의 d (Cohen's d)를 사용한다. 코헨의 d를 구하는 공식은 다음과 같다.

$$d = \frac{\mu_a - \mu_b}{S_{pool}}$$

이때 pooled standard deviation은 두 모집단 분산 동일성 여부에 따라 공식이 달라짐을 이미 설명한바 있으므로 참고하길 바란다(reference) 공식을 잘 살펴보면 결국 두 집단의 평균거리를 표준편차로 척도 차이를 조절한 것이다. 다시 말해 두집단의 평균 거리가 크 수록 코헨의 d, 즉 효과크기가 커진다.

6.3.4.3 검정력 (power)

[그림 1]에서 확인할 수 있듯이 검정력은 영가설이 기각되고, 연구가설이 채택되는



α = Type I error (H_1 이 FALSE
 H_0 이 TRUE 인데 -
 H_0 이 reject 하는
 β = Type II error
 (H_0 이 FALSE
 H_1 이 TRUE 인데
 H_0 이 accept 하는
 1- β
 검정력
 1- β

그림 6.1: 가설검정 오류

확률이다. 앞서 언급했듯이 검정력은 효과크기, 신뢰수준, 그리고 표본크기에 따라 달라진다.

6.3.4.3.1 효과크기와 검정력 두모집단 평균차이에서의 효과크기는 영가설과 연구가설의 평균의 차이와 비례한다. 아래 그림과 같이 효과크기가 커질수록, 즉 영가설과 연구가설의 평균차이가 커질수록 연구가설이 채택되는 확률(검정력)이 커지는 것을 알 수 있다.

그림

6.3.4.3.2 표본크기와 검정력 효과크기와 신뢰수준은 동일하되 표본크기가 커지면 검정력은 어떻게 변화할까? 영가설과 연구가설의 평균이 같을때 표본 크기가 커지만 자동으로 분산이 작아지므로 그림과 같이 분포가 뾰족해진다. 따라서 검정력은 커지게 된다.

6.3.4.3.3 허용오차수준(alpha)과 검정력 효과크기와 표본수가 동일한 경우에 허용오차수준(α)가 커지면 검정력도 증가한다. 그림과 같이 검정력이 cut-off가 허용오차수준에 의해 결정되기 때문이다.

6.3.4.4 검정력의 활용 : 적정 표본수의 결정

검정력은 연구가설이 참일때, 영가설을 기각하고 연구가설을 채택하는 확률이기 때문에 중요하다. 흔히 가설을 검증할때 허용오차 수준만을 고려하기 때문에 간과되기 쉽다. 표본크기가 작은 실험연구에서는 검정력이 중요하게 고려되는데, 일부 연구분야에서는 일정 수준 이상의 검정력을 요구하는 경우가 있다. 검정력을 확보하기 위해서는 허용오차수준을 늘리거나, 샘플사이즈를 늘리거나, 효과크기를 늘려야 한다. 그러나 허용오차 수준을 늘리면 1종 오류가 늘어나고, 효과크기는 연구자가 조절하기가 어려운 영역이다. 따라서 보통 표본 크기를 늘리는 방식으로 검정력을 늘리곤 한다. R에서는 pwr 패키지 등을 활용하면 일정 수준의 검정력을 확보하기 위한 최소 표본크기를 계산해준다. 만일 산업인력개발 분야에서 실험 연구 등과 같은 작은 표본을 대상으로 연구를 진행한다면, 반드시 검정력을 고려해 표본크기를 결정해야 한다.

6.3.5 R을 활용한 t 검정

앞서 3종류의 t 검정방법에 대해 알아보았다.

1. 단일모집단 평균에 대한 t검정
2. 동일모집단 반복측정 평균에 대한 t 검정
3. 두 모집단 평균에 대한 t검정

종합해보면 1번은 모집단이 한개, 2번은 모집단이 한개이지만 반복측정한 두개의 값의 평균차이를 검증, 3번은 서로다른 두개의 모집단의 평균의 차이가 있는지를 확인하는 방식이다. 가상의 데이터를 활용해서 t 검정을 해보자.

6.3.5.1 단일 모집단 평균 t 검정

C사에서 판매하는 립밤 제품의 중량은 3g으로 표기되어 있다. 하지만 많은 소비자들이 립밤이 너무 빨리 닳는다며, 표기 중량보다 적게 들어 있다고 생각했다. 어떤 유튜버가 총 15개의 립밤을 무작위로 구매하여 각각의 중량을 측정하였다.

유튜버의 목적은 C사의 립밤의 평균중량이 3g에 미치지 않는 다는 것을 증명하는 것이다. 갖고 있는 관측데이터는 15개에 불과하지만, 이 데이터를 통해 모집단(C사에서 판매하는 모든 립밤)의 평균중량을 예측하는 것이다.

이때 연구가설과 영가설은 다음과 같다. H1: C사 립밤의 평균중량은 3g보다 작다 (less than 3g) H0: C사 립밤의 평균중량은 3g과 같거나 크다.

r 코드는 간단하다. t.test를 사용하면 되고, 괄호안에는 총 4개의 인수를 지정해준다. 첫째, 데이터셋\$변수명, 둘째, 가설검정할 평균값, 셋째, 단측검정과 양측검정, 넷째, 신뢰수준을 추가해야한다. 이 사례에서는 가설검정을 할 평균값이 3g이므로 $\mu=3$, 연구가설이 평균($\mu=3$)보다 작다이므로 단측검정, 신뢰수준은 연구자가 설정한 95 프로 이다.

```
ID<-c(1,2,3,4,5,6,7,8,9,10,11,12,13,14,15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25)
X<-c(3.00, 2.75, 2.81, 3.0, 2.93, 3.01, 3.10, 3.20, 2.90, 3.00, 3.00, 2.95, 2.75, 2.88, 3.12, 3.05, 3.00, 2.98, 3.02, 2.99, 3.01, 3.03, 2.97, 3.04, 3.06, 3.08, 3.09, 3.07, 3.05, 3.03, 3.01, 3.00, 2.99, 2.98, 2.97, 2.96, 2.95, 2.94, 2.93, 2.92, 2.91, 2.90, 2.89, 2.88, 2.87, 2.86, 2.85, 2.84, 2.83, 2.82, 2.81, 2.80, 2.79, 2.78, 2.77, 2.76, 2.75, 2.74, 2.73, 2.72, 2.71, 2.70, 2.69, 2.68, 2.67, 2.66, 2.65, 2.64, 2.63, 2.62, 2.61, 2.60, 2.59, 2.58, 2.57, 2.56, 2.55, 2.54, 2.53, 2.52, 2.51, 2.50, 2.49, 2.48, 2.47, 2.46, 2.45, 2.44, 2.43, 2.42, 2.41, 2.40, 2.39, 2.38, 2.37, 2.36, 2.35, 2.34, 2.33, 2.32, 2.31, 2.30, 2.29, 2.28, 2.27, 2.26, 2.25, 2.24, 2.23, 2.22, 2.21, 2.20, 2.19, 2.18, 2.17, 2.16, 2.15, 2.14, 2.13, 2.12, 2.11, 2.10, 2.09, 2.08, 2.07, 2.06, 2.05, 2.04, 2.03, 2.02, 2.01, 2.00, 1.99, 1.98, 1.97, 1.96, 1.95, 1.94, 1.93, 1.92, 1.91, 1.90, 1.89, 1.88, 1.87, 1.86, 1.85, 1.84, 1.83, 1.82, 1.81, 1.80, 1.79, 1.78, 1.77, 1.76, 1.75, 1.74, 1.73, 1.72, 1.71, 1.70, 1.69, 1.68, 1.67, 1.66, 1.65, 1.64, 1.63, 1.62, 1.61, 1.60, 1.59, 1.58, 1.57, 1.56, 1.55, 1.54, 1.53, 1.52, 1.51, 1.50, 1.49, 1.48, 1.47, 1.46, 1.45, 1.44, 1.43, 1.42, 1.41, 1.40, 1.39, 1.38, 1.37, 1.36, 1.35, 1.34, 1.33, 1.32, 1.31, 1.30, 1.29, 1.28, 1.27, 1.26, 1.25, 1.24, 1.23, 1.22, 1.21, 1.20, 1.19, 1.18, 1.17, 1.16, 1.15, 1.14, 1.13, 1.12, 1.11, 1.10, 1.09, 1.08, 1.07, 1.06, 1.05, 1.04, 1.03, 1.02, 1.01, 1.00, 0.99, 0.98, 0.97, 0.96, 0.95, 0.94, 0.93, 0.92, 0.91, 0.90, 0.89, 0.88, 0.87, 0.86, 0.85, 0.84, 0.83, 0.82, 0.81, 0.80, 0.79, 0.78, 0.77, 0.76, 0.75, 0.74, 0.73, 0.72, 0.71, 0.70, 0.69, 0.68, 0.67, 0.66, 0.65, 0.64, 0.63, 0.62, 0.61, 0.60, 0.59, 0.58, 0.57, 0.56, 0.55, 0.54, 0.53, 0.52, 0.51, 0.50, 0.49, 0.48, 0.47, 0.46, 0.45, 0.44, 0.43, 0.42, 0.41, 0.40, 0.39, 0.38, 0.37, 0.36, 0.35, 0.34, 0.33, 0.32, 0.31, 0.30, 0.29, 0.28, 0.27, 0.26, 0.25, 0.24, 0.23, 0.22, 0.21, 0.20, 0.19, 0.18, 0.17, 0.16, 0.15, 0.14, 0.13, 0.12, 0.11, 0.10, 0.09, 0.08, 0.07, 0.06, 0.05, 0.04, 0.03, 0.02, 0.01, 0.00, -0.01, -0.02, -0.03, -0.04, -0.05, -0.06, -0.07, -0.08, -0.09, -0.10, -0.11, -0.12, -0.13, -0.14, -0.15, -0.16, -0.17, -0.18, -0.19, -0.20, -0.21, -0.22, -0.23, -0.24, -0.25, -0.26, -0.27, -0.28, -0.29, -0.30, -0.31, -0.32, -0.33, -0.34, -0.35, -0.36, -0.37, -0.38, -0.39, -0.40, -0.41, -0.42, -0.43, -0.44, -0.45, -0.46, -0.47, -0.48, -0.49, -0.50, -0.51, -0.52, -0.53, -0.54, -0.55, -0.56, -0.57, -0.58, -0.59, -0.60, -0.61, -0.62, -0.63, -0.64, -0.65, -0.66, -0.67, -0.68, -0.69, -0.70, -0.71, -0.72, -0.73, -0.74, -0.75, -0.76, -0.77, -0.78, -0.79, -0.80, -0.81, -0.82, -0.83, -0.84, -0.85, -0.86, -0.87, -0.88, -0.89, -0.90, -0.91, -0.92, -0.93, -0.94, -0.95, -0.96, -0.97, -0.98, -0.99, -1.00, -1.01, -1.02, -1.03, -1.04, -1.05, -1.06, -1.07, -1.08, -1.09, -1.10, -1.11, -1.12, -1.13, -1.14, -1.15, -1.16, -1.17, -1.18, -1.19, -1.20, -1.21, -1.22, -1.23, -1.24, -1.25, -1.26, -1.27, -1.28, -1.29, -1.30, -1.31, -1.32, -1.33, -1.34, -1.35, -1.36, -1.37, -1.38, -1.39, -1.40, -1.41, -1.42, -1.43, -1.44, -1.45, -1.46, -1.47, -1.48, -1.49, -1.50, -1.51, -1.52, -1.53, -1.54, -1.55, -1.56, -1.57, -1.58, -1.59, -1.60, -1.61, -1.62, -1.63, -1.64, -1.65, -1.66, -1.67, -1.68, -1.69, -1.70, -1.71, -1.72, -1.73, -1.74, -1.75, -1.76, -1.77, -1.78, -1.79, -1.80, -1.81, -1.82, -1.83, -1.84, -1.85, -1.86, -1.87, -1.88, -1.89, -1.90, -1.91, -1.92, -1.93, -1.94, -1.95, -1.96, -1.97, -1.98, -1.99, -2.00, -2.01, -2.02, -2.03, -2.04, -2.05, -2.06, -2.07, -2.08, -2.09, -2.10, -2.11, -2.12, -2.13, -2.14, -2.15, -2.16, -2.17, -2.18, -2.19, -2.20, -2.21, -2.22, -2.23, -2.24, -2.25, -2.26, -2.27, -2.28, -2.29, -2.30, -2.31, -2.32, -2.33, -2.34, -2.35, -2.36, -2.37, -2.38, -2.39, -2.40, -2.41, -2.42, -2.43, -2.44, -2.45, -2.46, -2.47, -2.48, -2.49, -2.50, -2.51, -2.52, -2.53, -2.54, -2.55, -2.56, -2.57, -2.58, -2.59, -2.60, -2.61, -2.62, -2.63, -2.64, -2.65, -2.66, -2.67, -2.68, -2.69, -2.70, -2.71, -2.72, -2.73, -2.74, -2.75, -2.76, -2.77, -2.78, -2.79, -2.80, -2.81, -2.82, -2.83, -2.84, -2.85, -2.86, -2.87, -2.88, -2.89, -2.90, -2.91, -2.92, -2.93, -2.94, -2.95, -2.96, -2.97, -2.98, -2.99, -3.00, -3.01, -3.02, -3.03, -3.04, -3.05, -3.06, -3.07, -3.08, -3.09, -3.10, -3.11, -3.12, -3.13, -3.14, -3.15, -3.16, -3.17, -3.18, -3.19, -3.20, -3.21, -3.22, -3.23, -3.24, -3.25, -3.26, -3.27, -3.28, -3.29, -3.30, -3.31, -3.32, -3.33, -3.34, -3.35, -3.36, -3.37, -3.38, -3.39, -3.40, -3.41, -3.42, -3.43, -3.44, -3.45, -3.46, -3.47, -3.48, -3.49, -3.50, -3.51, -3.52, -3.53, -3.54, -3.55, -3.56, -3.57, -3.58, -3.59, -3.60, -3.61, -3.62, -3.63, -3.64, -3.65, -3.66, -3.67, -3.68, -3.69, -3.70, -3.71, -3.72, -3.73, -3.74, -3.75, -3.76, -3.77, -3.78, -3.79, -3.80, -3.81, -3.82, -3.83, -3.84, -3.85, -3.86, -3.87, -3.88, -3.89, -3.90, -3.91, -3.92, -3.93, -3.94, -3.95, -3.96, -3.97, -3.98, -3.99, -4.00, -4.01, -4.02, -4.03, -4.04, -4.05, -4.06, -4.07, -4.08, -4.09, -4.10, -4.11, -4.12, -4.13, -4.14, -4.15, -4.16, -4.17, -4.18, -4.19, -4.20, -4.21, -4.22, -4.23, -4.24, -4.25, -4.26, -4.27, -4.28, -4.29, -4.30, -4.31, -4.32, -4.33, -4.34, -4.35, -4.36, -4.37, -4.38, -4.39, -4.40, -4.41, -4.42, -4.43, -4.44, -4.45, -4.46, -4.47, -4.48, -4.49, -4.50, -4.51, -4.52, -4.53, -4.54, -4.55, -4.56, -4.57, -4.58, -4.59, -4.60, -4.61, -4.62, -4.63, -4.64, -4.65, -4.66, -4.67, -4.68, -4.69, -4.70, -4.71, -4.72, -4.73, -4.74, -4.75, -4.76, -4.77, -4.78, -4.79, -4.80, -4.81, -4.82, -4.83, -4.84, -4.85, -4.86, -4.87, -4.88, -4.89, -4.90, -4.91, -4.92, -4.93, -4.94, -4.95, -4.96, -4.97, -4.98, -4.99, -5.00, -5.01, -5.02, -5.03, -5.04, -5.05, -5.06, -5.07, -5.08, -5.09, -5.10, -5.11, -5.12, -5.13, -5.14, -5.15, -5.16, -5.17, -5.18, -5.19, -5.20, -5.21, -5.22, -5.23, -5.24, -5.25, -5.26, -5.27, -5.28, -5.29, -5.30, -5.31, -5.32, -5.33, -5.34, -5.35, -5.36, -5.37, -5.38, -5.39, -5.40, -5.41, -5.42, -5.43, -5.44, -5.45, -5.46, -5.47, -5.48, -5.49, -5.50, -5.51, -5.52, -5.53, -5.54, -5.55, -5.56, -5.57, -5.58, -5.59, -5.60, -5.61, -5.62, -5.63, -5.64, -5.65, -5.66, -5.67, -5.68, -5.69, -5.70, -5.71, -5.72, -5.73, -5.74, -5.75, -5.76, -5.77, -5.78, -5.79, -5.80, -5.81, -5.82, -5.83, -5.84, -5.85, -5.86, -5.87, -5.88, -5.89, -5.90, -5.91, -5.92, -5.93, -5.94, -5.95, -5.96, -5.97, -5.98, -5.99, -6.00, -6.01, -6.02, -6.03, -6.04, -6.05, -6.06, -6.07, -6.08, -6.09, -6.10, -6.11, -6.12, -6.13, -6.14, -6.15, -6.16, -6.17, -6.18, -6.19, -6.20, -6.21, -6.22, -6.23, -6.24, -6.25, -6.26, -6.27, -6.28, -6.29, -6.30, -6.31, -6.32, -6.33, -6.34, -6.35, -6.36, -6.37, -6.38, -6.39, -6.40, -6.41, -6.42, -6.43, -6.44, -6.45, -6.46, -6.47, -6.48, -6.49, -6.50, -6.51, -6.52, -6.53, -6.54, -6.55, -6.56, -6.57, -6.58, -6.59, -6.60, -6.61, -6.62, -6.63, -6.64, -6.65, -6.66, -6.67, -6.68, -6.69, -6.70, -6.71, -6.72, -6.73, -6.74, -6.75, -6.76, -6.77, -6.78, -6.79, -6.80, -6.81, -6.82, -6.83, -6.84, -6.85, -6.86, -6.87, -6.88, -6.89, -6.90, -6.91, -6.92, -6.93, -6.94, -6.95, -6.96, -6.97, -6.98, -6.99, -7.00, -7.01, -7.02, -7.03, -7.04, -7.05, -7.06, -7.07, -7.08, -7.09, -7.10, -7.11, -7.12, -7.13, -7.14, -7.15, -7.16, -7.17, -7.18, -7.19, -7.20, -7.21, -7.22, -7.23, -7.24, -7.25, -7.26, -7.27, -7.28, -7.29, -7.30, -7.31, -7.32, -7.33, -7.34, -7.35, -7.36, -7.37, -7.38, -7.39, -7.40, -7.41, -7.42, -7.43, -7.44, -7.45, -7.46, -7.47, -7.48, -7.49, -7.50, -7.51, -7.52, -7.53, -7.54, -7.55, -7.56, -7.57, -7.58, -7.59, -7.60, -7.61, -7.62, -7.63, -7.64, -7.65, -7.66, -7.67, -7.68, -7.69, -7.70, -7.71, -7.72, -7.73, -7.74, -7.75, -7.76, -7.77, -7.78, -7.79, -7.80, -7.81, -7.82, -7.83, -7.84, -7.85, -7.86, -7.87, -7.88, -7.89, -7.90, -7.91, -7.92, -7.93, -7.94, -7.95, -7.96, -7.97, -7.98, -7.99, -8.00, -8.01, -8.02, -8.03, -8.04, -8.05, -8.06, -8.07, -8.08, -8.09, -8.10, -8.11, -8.12, -8.13, -8.14, -8.15, -8.16, -8.17, -8.18, -8.19, -8.20, -8.21, -8.22, -8.23, -8.24, -8.25, -8.26, -8.27, -8.28, -8.29, -8.30, -8.31, -8.32, -8.33, -8.34, -8.35, -8.36, -8.37, -8.38, -8.39, -8.40, -8.41, -8.42, -8.43, -8.44, -8.45, -8.46, -8.47, -8.48, -8.49, -8.50, -8.51, -8.52, -8.53, -8.54, -8.55, -8.56, -8.57, -8.58, -8.59, -8.60, -8.61, -8.62, -8.63, -8.64, -8.65, -8.66, -8.67, -8.68, -8.69, -8.70, -8.71, -8.72, -8.73, -8.74, -8.75, -8.76, -8.77, -8.78, -8.79, -8.80, -8.81, -8.82, -8.83, -8.84, -8.85, -8.86, -8.87, -8.88, -8.89, -8.90, -8.91, -8.92, -8.93, -8.94, -8.95, -8.96, -8.97, -8.98, -8.99, -9.00, -9.01, -9.02, -9.03, -9.04, -9.05, -9.06, -9.07, -9.08, -9.09, -9.10, -9.11, -9.12, -9.13, -9.14, -9.15, -9.16, -9.17, -9.18, -9.19, -9.20, -9.21, -9.22, -9.23, -9.24, -9.25, -9.26, -9.27, -9.28, -9.29, -9.30, -9.31, -9.32, -9.33, -9.34, -9.35, -9.36, -9.37, -9.38, -9.39, -9.40, -9.41, -9.42, -9.43, -9.44, -9.45, -9.46, -9.47, -9.48, -9.49, -9.50, -9.51, -9.52, -9.53, -9.54, -9.55, -9.56, -9.57, -9.58, -9.59, -9.60, -9.61, -9.62, -9.63, -9.64, -9.65, -9.66, -9.67, -9.68, -9.69, -9.70, -9.71, -9.72, -9.73, -9.74, -9.75, -9.76, -9.77, -9.78, -9.79, -9.80, -9.81, -9.82, -9.83, -9.84, -9.85, -9.86, -9.87, -9.88, -9.89, -9.90, -9.91, -9.92, -9.93, -9.94, -9.95, -9.96, -9.97, -9.98, -9.99, -10.00, -10.01, -10.02, -10.03, -10.04, -10.05, -10.06, -10.07, -10.08, -10.09, -10.10, -10.11, -10.12, -10.13, -10.14, -10.15, -10.16, -10.17, -10.18, -10.19, -10.20, -10.21, -10.22, -10.23, -10.24, -10.25, -10.26, -10.27, -10.28, -10.29, -10.30, -10.31, -10.32, -10.33, -10.34, -10.35, -10.36, -10.37, -10.38, -10.39, -10.40, -10.41, -10.42, -10.43, -10.44, -10.45, -10.46, -10.47, -10.48, -10.49, -10.50, -10.51, -10.52, -10.53, -10.54, -10.55, -10.56, -10.57, -10.58, -10.59, -10.60, -10.61, -10.62, -10.63, -10.64, -10.65, -10.66, -10.67, -10.68, -10.69, -10.70, -10.71, -10.72, -10.73, -10.74, -10.75, -10.76, -10.77, -10.78, -10.79, -10.80, -10.81, -10.82, -10.83, -10.84, -10.85, -10.86, -10.87, -10.88, -10.89, -10.90, -10.91, -10.92, -10.93, -10.94, -10.95, -10.96, -10.97, -10.98, -10.99, -11.00, -11.01, -11.02, -11.03, -11.04, -11.05, -11.06, -11.07, -11.08, -11.09, -11.10, -11.11, -11.12, -11.13, -11.14, -11.15, -11.16, -11.17, -11.18, -11.19, -11.20, -11.21, -11.22, -11.23, -11.24, -11.25, -11.26, -11.27, -11.28, -11.29, -11.30, -11.31, -11.32, -11.33, -11.34, -11.35, -11.36, -11.37, -11.38, -11.39, -11.40, -11.41, -11.42, -11.43, -11.44, -11.45, -11.46, -11.47, -11.48, -11.49, -11.50, -11.51, -11.52, -11.53, -11.54, -11.55, -11.56, -11.57, -11.58, -11.59, -11.60, -11.61, -11.62, -11.63, -11.64, -11.65, -11.66, -11.67, -11.68, -11.69, -11.70, -11.71, -11.72, -11.73, -11.74, -11.75, -11.76, -11.77, -11.78, -11.79, -11.80, -11.81, -11.82, -11.83, -11.84, -11.85, -11.86, -11.87, -11.88, -11.89, -11.90, -11.91, -11.92, -11.93, -11.94, -11.95, -11.96, -11.97, -11.98, -11.99, -12.00, -12.01, -12.02, -12.03, -12.04, -12.05, -12.06, -12.07, -12.08, -12.09, -12.10, -12.11, -12.12, -12.13, -12.14, -12.15, -12.16, -12.17, -12.18, -12.19, -12.20, -12.21, -12.22, -12.23, -12.24, -12.25, -12.26, -12.27, -12.28, -12.29, -12.30, -12.31, -12.32, -12.33, -12.34, -12.35, -12.36, -12.37, -12.38, -12.39, -12.40, -12.41, -12.42, -12.43, -12.44, -12.45, -12.46, -12.47, -12.48, -12.49, -12.50, -12.51, -12.52, -12.53, -12.54, -12.55, -12.56, -12.57, -12.58, -12.59, -12.60, -12.61, -12.62, -12.63, -12.64, -12.65, -12.66, -12.67, -12.68, -12.69, -12.70, -12.71, -12.72, -12.73, -12.74, -12.75, -12.76, -12.77, -12.78, -12.79, -12.80, -12.81, -12.82, -12.83, -12.84, -12.85, -12.86, -12.87, -12.88, -12.89, -12.90, -12.91, -12.92, -12.93, -12.94, -12.95, -12.96, -12.97, -12.98, -12.99, -13.00, -13.01, -13.02, -13.03, -13.04, -13.05, -13.06, -13.07, -13.08, -13.09, -13.10, -13.11, -13.12, -13.13, -13.14, -13.15, -13.16, -13.17, -13.18, -13.19, -13.20, -13.21, -13.22, -13.23, -13.24, -13.25, -13.26, -13.27, -13.28, -13.29, -13.30, -13.31, -13.32, -13.33, -13.34, -13.35, -13.36, -13.37, -13.38, -13.39, -13.40, -13.41, -13.42, -13.43, -13.44, -13.45, -13.46, -13.47, -13.48, -13.49, -13.50, -13.51, -13.52, -13.53, -13.54, -13.55, -13.56, -13.57, -13.58, -13.59, -13.60, -13.61, -13.62, -13.63, -13.64, -13.65, -13.66, -13.67, -13.68, -13.69, -13.70, -13.71, -13.72, -13.73, -13.74, -13.75, -13.76, -13.77, -13.78, -13.79, -13.80, -13.81, -13.82, -13.83, -13.84, -13.85, -13.86, -13.87, -13.88, -13.89, -13.90, -13.91, -13.92, -13.93, -13.94, -13.95, -13.96, -13.97, -13.98, -13.99, -14.00, -14.01, -14.02, -14.03, -14.04, -14.05, -14.06, -14.07, -14.08, -14.09, -14.10, -14.11, -14.12, -14.13, -14.14, -14.15, -14.16, -14.17, -14.18, -14.19, -14.20, -14.21, -14.22, -14.23, -14.24, -14.25, -14.26, -14.27, -14.28, -14.29, -14.30, -14.31, -14.32, -14.33, -14.34, -14.35, -14.36, -14.37, -14.38, -14.39, -14.40, -14.41, -14.42, -14.43, -14.44, -14.45, -14.46, -14.47, -14.48, -14.49, -14.50, -14.51, -14.52, -14.53, -14.54, -14.55, -14.56, -14.57, -14.58, -14.59, -14.60, -14.61, -14.62, -14.63, -14.64, -14.65, -14.66, -14.67, -14.68, -14.69, -14.70, -14.71, -14.72, -14.73, -14.74, -14.75, -14.76, -14.77, -14.78, -14.79, -14.80, -14.81, -14.82, -14.83, -14.84, -14.85, -14.86, -14.87, -14.88, -14.89, -14.90, -14.91, -14.92, -14.93, -14.94, -14.95,
```

```
## alternative hypothesis: true mean is less than 3
## 95 percent confidence interval:
##      -Inf 3.007219
## sample estimates:
## mean of x
##      2.9644
```

검정 결과, 표본평균은 2.9644이지만 t검정통계량이 -14.225, p-value가 0.08388로 연구가설이 기각되고, 영가설이 채택되었다. 다시 말해 C사의 립밤의 평균중량은 3g과 같거나 크다고 볼 수 있다.




그림 6.2: t분포를 활용한 가설검정

6.3.5.2 단일 모집단 반복측정 평균 t 검정 (paired t-test)

모든 t 검정의 명령어는 `t.test()`로 동일하다. 다만 괄호안의 인수들을 변경하여 지정함으로써 3개 유형의 t검정을 실시할 수 있다. 이것은 인수들을 자칫 잘못 지정하면 엉뚱한 검정을 할 수 있다는 것을 의미한다. `t.test()`에서 지정할 인수는 다음과 같다.

- 분석에 사용될 데이터명과 변수명 : 데이터명 $\tilde{A}_{pt0}$ 변수명2의 형태로 지정
 - 영가설은 변수1-변수2=0
- 가설검정방식 : 양측검정, 단측(왼쪽/오른쪽)검정
 - 양측검정 : two.sided, less, greater
- 집단간 동분산 : default : FALSE
- 쌍체비교 여부(대응표본여부) : true/false
- conf.level= 연구자 지정 (0.90, 0.95, 0.99....)

데이터를 입력한 후에는 일단 각 집단별 평균을 구해보자. 사전점수는 3.024, 사후검사는 3.28로 사후검사가 더 높은 것을 알 수 있다. 다음으로는 집단간 동분산을 확인하여야 한다. 동분산 가정이 충족되지 않는 경우 t값의 계산 공식이 달라지기 때문이다. 집단간 동분산을 검증하는 방법이 여러가지가 있다. 여기서는 `var.test` 명령어를 사용해보자. 분석결과 p값이 상당히 커서 연구가설(두 집단의 분산의 차이가 0이 아니다)이 기각된다. 따라서 두 집단은 분산이 같다고 가정할 수 있다. 이를 기초로 `t.test` 명령어를 사용하여 분석해보면 t 값은 -4.2262 이고, p-value 는 0.05 미만으로 연구가설을 채택한다. 연구가설은 “Xpre-Xpost가 0이 아니다” 이므로 두 집단간의 차이가 있다고 결론내릴 수 있다.

데이터 입력

```
ID<-c(1,2,3,4,5,6,7,8,9,10,11,12,13,14,15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25)
Xpre<-c(3.0, 3.5, 3.2, 3.0, 2.8, 3.1, 3.1, 3.2, 2.9, 3.0, 3.0, 3.1, 3.3, 2.0, 3.5, 3.2, 3.3, 2.8, 2.9, 3.0, 3.1, 3.2, 3.4, 3.5, 3.6, 3.7, 2.9, 2.8)
Xpost<-c(3.2, 3.8, 3.4, 2.8, 3.5, 3.2, 3.3, 3.7, 3.1, 3.8, 3.3, 2.9, 3.1, 2.8, 3.6, 3.5, 3.7, 2.9, 2.8, 3.0, 3.1, 3.2, 3.4, 3.5, 3.6, 3.7, 2.9, 2.8)
prepostT<-data.frame(ID, Xpre, Xpost)
```

사전/사후 집단의 평균비교

```
mean(prepostT$Xpre)
```

```
## [1] 3.024
```

```
mean(prepostT$Xpost)
```

```
## [1] 3.28
```

집단간 동분산성 확인

```
var.test(prepostT$Xpre, prepostT$Xpost)
```

```
##
## F test to compare two variances
##
## data:  prepostT$Xpre and prepostT$Xpost
## F = 0.76847, num df = 24, denom df = 24, p-value = 0.5238
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.3386396 1.7438650
## sample estimates:
## ratio of variances
##          0.7684672

## 쌍체비교 t-test
t.test(prepostT$Xpre, prepostT$Xpost, var.equal=TRUE, alternative="two.sided", conf.level=0.95)
##
## Paired t-test
##
## data:  prepostT$Xpre and prepostT$Xpost
## t = -4.2262, df = 24, p-value = 0.0002971
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##  -0.3810207 -0.1309793
## sample estimates:
## mean difference
##          -0.256
```

6.3.5.3 두 모집단 평균 t 검정 (two sample t-test)

두 모집단 평균 t검정은 paired t-test와 매우 유사한 데이터 구조를 갖고 있지만 쌍별 비교가 아니라 두 집단의 전체 평균을 비교한다는 점에서 차이가 있다. r 명령어도 매우 유사한데, 다만 “paired=FALSE”로 반드시 지정해주어야 잘못된 분석결과를 피할 수 있다.

앞서 paired t-test에서 사용한 데이터셋을 그대로 사용해보자. 다만 이번에는 A직무 25명과, B직무 25명의 시험점수를 측정해서 학년간 격차가 있는지 확인한다고


```
## t = 0, df = 48, p-value = 1
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.1684459  0.1684459
## sample estimates:
## mean of x mean of y
##      3.024      3.024
```

6.4 분산분석 (ANOVA)

앞서 살펴본 t-test는 평균을 비교하는 집단의 수가 2개일때 가능한 분석 방법이다. 만일 세개 이상의 집단간 평균의 차이가 유의미하게 있는지 검증하고 싶다면 분산분석(ANOVA, Analysis of Variance)을 수행해야 한다. 예를 들어 학년별 평균 GPA의 차이가 있는지?, 출퇴근 수단(자차,도보,버스,지하철)에 따라 평균 출근소요시간에 차이가 있는지?, 교육방법(강의식, 토론식, 자기학습식)에 따라 교육성과에 따라 차이가 있는지? 등이 분산분석을 통해 검증할 수 있는 연구질문들이다.

6.4.1 분산분석 (ANOVA)의 개념

세개 이상의 집단간 평균차이를 비교하는데 왜 분산을 분석해야 할까? 강의를 하다 보면 많은 학생들이 이와 같은 질문을 한다. 만일 세 집단의 평균차이를 검증하고 싶다면 두집단씩 쌍별로 t검증을 세번하면 되지 않을까(예: A-B 평균차이, B-C 평균 차이, A-C의 평균차이)? 그러나 이 경우 다수의 가설검증으로 인해 1종 오류의 크기가 증가하기 때문에 문제가 발생한다.

t검증을 다시 떠올려보면 A그룹과 B그룹의 평균차이를 하나의 값(A-B)으로 계산해서 t값을 계산한다. 그러나 세 집단 이상의 경우 평균의 차이는 하나의 수치로 계산이 되지 않는다. 분산분석(ANOVA)은 집단간 평균의 차이(differences)를 사용하지 않고, 집단간 평균의 분산(variance)을 활용하는 방법이다.

6.4.1.1 분산분석의 종류

분산분석은 평균의 차이를 확인하고 싶은 종속변수(Y)을 구분하는 집단이 3개 이상일때 쓰인다. 분산분석은 종속변수와 독립변수의 수에 따라 다음과 같이 구분된다.

- 종속변수 2개 : 다변량 분산분석

- 종속변수 1개 : 단변량 분산분석
 - 독립변수 1개: 일원 분산분석 (one-way ANOVA)
 - 독립변수 2개: 이원 분산분석 (two-way ANOVA)

6.4.1.2 그래프로 이해하는 일원분산분석(ANOVA)

3집단 이상의 평균간의 차이가 있는지를 확인하고 싶다면, 집단별 평균과 함께 집단내분산을 함께 고려해야한다. 아래 그림은 세 집단의 각각의 평균이 μ_A, μ_B, μ_C 로 같지만, 집단간 분산이 서로 다른 경우를 보여주고 있다.

상단의 그래프는 집단간 분산이 크다. 예를 들어 A집단의 경우 μ_A 라는 평균에서 멀리 떨어져있다. 하단의 그래프는 보다 촘촘히 집단평균에 모여있다. 집단간 분산이 작다는 뜻이다. 상단과 하단 그래프는 μ_A, μ_B, μ_C 가 모두 같다. 만일 평균만 고려한다면 상단과 하단 모두 집단간 평균차이가 유의미한것처럼 보이겠지만, 분산을 고려하면 하단 그래프만이 집단간 평균차이가 유의할 것이다. 왜냐하면 하단의 그래프는 집단간 분산이 매우 작아 집단간 평균의 차이가 분명하기 때문이다. 반대로 상단의 그래프는 평균차이는 있지만 A집단, B집단, C집단이 겹치는 경우가 많다. 따라서 집단간 평균의 차이가 유의미하지 않을 가능성이 높다.

예제의 데이터를 활용해서 그래프를 그려보자. A그룹, B그룹, C그룹에 각각 5명의 사람이 있다. 변수 Y는 각 개인의 반차 사용 횟수라고 생각해보자. 우리의 연구가설과 영가설은 다음과 같다.

- H1: A, B, C 그룹간의 반차 사용횟수의 평균의 차이가 존재한다.
- H0: A, B, C 그룹간의 반차 사용횟수의 평균의 차이가 없다.

간단하게 집단별로 사용횟수의 평균 차이를 `group_by`와 `summarize`를 활용해서 분석하였다. A 집단의 평균 반차 사용횟수는 12회, B집단은 10.4회, C 집단은 15.2회이다.

박스플롯과 density plot을 그려보니 평균에는 차이가 있지만 overlapped되는 케이스가 존재하는 것을 알 수 있다. 따라서 평균 차이만으로는 위의 연구가설을 채택할 수 없다.

```
##      ID X   Y G
## 1    1 1    7 A
## 2    2 1  11 A
## 3    3 1  13 A
## 4    4 1  14 A
```






그림 6.3: 3집단 이상의 평균비교: 분산분석

```
## 5    5 1 15 A
## 6    6 2  8 B
## 7    7 2  9 B
## 8    8 2 14 B
## 9    9 2 11 B
## 10   10 2 10 B
## 11   11 3 14 C
## 12   12 3 15 C
## 13   13 3 16 C
## 14   14 3 14 C
## 15   15 3 17 C
## # A tibble: 3 x 2
##       X mean
##   <dbl> <dbl>
## 1     1  12
## 2     2 10.4
## 3     3 15.2
```






6.4.2 일원분산분석 공식

6.4.2.1 총편차, 집단간편차, 집단내편차

분산분석의 공식은 총편차, 집단간편차 그리고 집단내 편차를 이해하는것에서 시작



한다.

먼저 ANOVA와 같이 집단별로 케이스가 있는 경우(subsample)에는 다음과 같이 아래첨자를 쓴다는 것을 이해하자.

- Y_{ij} : j번째 집단의 i번째 사람의 Y값
 - 예: Y_{32} : 2번째 집단의 3번째 사람의 Y 값
 - 예: $Y_{.3}$: 3번째 집단의 모든 사람의 Y 값

3개의 집단에서 측정한 종속변수(Y)값이 있다고 생각해보면, 평균은 총 4개이다.

- 총평균(grand mean) : $\bar{Y}$

- 집단에 관계없이 모든 Y_{ij} 의 평균
- pooled mean, total mean 등으로 불리움
- 집단평균(group mean) : $\bar{Y}_1, \bar{Y}_2, \bar{Y}_3$
- 각 집단별 Y_i 의 평균

그리고 이 평균들에서 떨어진 정도가 총편차와 집단내 편차이다.

- 총편차(total differences) : $\bar{Y} - Y_{ij}$ + 총평균에서 개별데이터가 떨어진 정도
- 집단내편차(within-group differences) : $\bar{Y}_j - Y_{ij}$ + 집단평균에서 해당집단의 데이터가 떨어진 정도
- 집단간편차(between-group differences) : $\bar{Y} - \bar{Y}_j$ + 총평균에서 집단평균이 떨어진 정도

위의 그림에서 알 수 있듯이 총편차=집단간편차+집단내편차이다. 따라서 이를 수식으로 정리하면 다음과 같다.

$$(\bar{Y} - Y_{ij}) = (\bar{Y} - \bar{Y}_j) + (\bar{Y}_j - Y_{ij})$$

6.4.2.2 편차제곱합

편차를 합했을때는 모두 상쇄되는 성질이 있기때문에 제곱합의 개념을 도입한다. 총편차, 집단간편차, 집단내편차의 제곱합 공식은 다음과 같다.

- 총편차 제곱합(SST) = 집단간편차 제곱합(SSB) + 집단내편차 제곱합(SSW)

$$\sum (\bar{Y} - Y_{ij})^2 = \sum (\bar{Y} - \bar{Y}_j)^2 + \sum (\bar{Y}_j - Y_{ij})^2$$

다만 두개의 식에서 $a = b + c$ 가 어째서 $a^2 = b^2 + c^2$ 가 되는지 궁금한 사람이 있을 것이다. 이것이 성립하려면 $b * c = 0$ 이 성립되어야 하는데, $\sum (\bar{Y} - \bar{Y}_j) * (\bar{Y}_j - Y_{ij})$ 은 항상 0이기 때문에 성립된다.

6.4.2.3 평균제곱합

이제 편차제곱합의 평균을 구해보자. 평균을 구하기 위해서는 각각의 자유도를 분모로 나눠주면 된다.

- 총편차 제곱합의 자유도 : $n-1$ (전체 사례수-1)

- 집단간편차 제곱합의 자유도 : $g-1$ (전체 집단수-1)
- 집단내편차 제곱합의 자유도 : $n-g$ ($=n-1-(g-1)$)

종합하면 다음과 같다.

- 총평균제곱(MST) = 집단간평균제곱(MSB) + 집단내평균제곱(MSW)

$$\frac{\sum(\bar{Y} - Y_{ij})^2}{n-1} = \frac{\sum(\bar{Y} - \bar{Y}_j)^2}{g-1} + \frac{\sum(\bar{Y}_j - Y_{ij})^2}{n-g}$$

편차의 제곱합을 사례수 또는 자유도로 나눠준 것이 분산이므로 다시 쓰면 다음과 같다.

- 총분산 = 집단간분산 + 집단내분산

6.4.2.4 일원분산분석 종합

이상의 내용을 하나의 표로 정리하면 아래와 같다. 보통 어떤 통계패키지를 쓰더라도 다음의 표의 내용이 산출된다. 일원분산분석의 핵심은 집단간 분산과 집단내 분산의 비율을 계산하는 것이다. 앞서 살펴본 것처럼 집단간분산이 집단내 분산보다 유의미하게 커야 집단간의 평균차이가 있다고 결론내릴 수 있기 때문이다.

- 총분산에서 집단간분산의 비율이 큰 경우 -> 집단간 평균의 차이가 크다.
집단내 분산은 상대적으로 작기 때문에 겹치는 부분이 적다
- 총분산에서 집단간분산의 비율이 작은 경우 -> 집단간 평균의 차이가 없다.
집단내 분산이 상대적으로 크기 때문에 겹치는 부분이 많다.

원천	제곱합(SS)	자유도	평균제곱	F
집단 간	$SSB = \sum_j \sum_i (\bar{y}_j - \bar{y})^2$	$(g-1)$	$MSB = \frac{SSB}{g-1}$	$\frac{MSB}{MSW}$
집단 내	$SSW = \sum_j \sum_i (y_{ij} - \bar{y}_j)^2$	$(n-g)$	$MSW = \frac{SSW}{n-g}$	
총(합계)	$SST = \sum_j \sum_i (y_{ij} - \bar{y})^2$	$(n-1)$		

그림 6.4: 일원분산분석표

집단간 평균차이의 유의성을 검증하기 위해서 F value를 산출해야하는데 이는 집단간평균제곱과 집단내평균제곱합의 비와 같다.




그림 6.5: 일원분산분석검정을 위한 F 분포

6.4.3 손으로 풀어보는 일원분산분석(ANOVA)

이상의 이해를 바탕으로 일원분산분석을 손으로 계산해보자. 요즘같은 디지털세상에 손으로 계산하는 것이 우습고 느껴보일 수는 있지만, 정확한 이해를 돕는데 이만한 방법이 없다. 앞서 살펴본 집단별 연차횟수의 평균 차이를 확인하려던 데이터를 가져와보자.

```
##      G  Y
## 1    A  7
## 2    A 11
## 3    A 13
## 4    A 14
## 5    A 15
## 6    B  8
## 7    B  9
## 8    B 14
## 9    B 11
## 10   B 10
## 11   C 14
## 12   C 15
## 13   C 16
```

```
## 14 C 14
```

```
## 15 C 17
```

좀 더 쉽게 계산하기 위해서는 위의 long data format을 wide data format으로 바꾸도록하자.

```
A_group<-c(7, 11, 13, 14, 15)
B_group<-c(8, 9, 14, 11, 10)
C_group<-c(14, 15, 16, 14, 17)
longAnova<-data.frame(A_group, B_group, C_group)
longAnova
##   A_group B_group C_group
## 1      7      8      14
## 2     11      9      15
## 3     13     14      16
## 4     14     11      14
## 5     15     10      17
```

이를 바탕으로 분산분석표를 계산해보면 다음과 같아.

가설검증의 유의수준이 0.05인경우 F table 을 통해 임계치를 찾아보면 $F=3.8853$ 인것을 확인할 수 있다.

우리의 검정통계량은 5.271, 임계치는 3.8853이므로 연구가설은 채택된다.

6.4.4 R을 활용한 일원분산분석(ANOVA)

6.4.4.1 R code

R을 통해 일원분산분석을 하는 것은 매우 쉽다. oneway.test라는 명령어와 종속 변수, 독립변수를 지정해주기만 하면된다.

```
##
## One-way analysis of means
##
## data: Y and X
## F = 5.2706, num df = 2, denom df = 12, p-value = 0.02276
```


	A group	B group	C group
	7	8	14
	11	9	15
	13	14	16
	14	11	14
	15	10	17
집단평균(group mean)	12	10.4	15.2
총평균(grand mean)	12.533		

구분	A group	B group	C group
집단간편차제곱	1.422	22.755	35.555
	$=5*(12-12.533)^2$	$=5*(10.4-12.533)^2$	$=5*(15.2-12.533)^2$
	59.733		
집단내 편차제곱합	40	21.2	166.8
	$= (7-12)^2 + (11-12)^2 + (12-13)^2 + (12-14)^2 + (15-12)^2$	$= (8-10.4)^2 + (9-10.4)^2 + (14-10.4)^2 + (11-10.4)^2 + (10-10.4)^2$	$= (14-15.2)^2 + (15-15.2)^2 + (16-15.2)^2 + (14-15.2)^2 + (17-15.2)^2$
	68		
총편차제곱합	127.7333		
	$= (7-12.533)^2 + (11-12.533)^2 + \dots + (16-12.533)^2 + (14-12.533)^2 + (17-12.533)^2$		

구분	편차제곱합(SS)	자유도(df)	평균제곱(MS)	F-value
집단간(BETWEEN)	59.733	2	29.866	5.271
집단내(WITHIN)	68	12	5.666	
총(TOTAL)	127.733	14	9.123	

그림 6.6: 일원분산분석검정을 위한 F 분포

F Table for $\alpha = 0.05$



/	df ₁ =1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
df ₂ =1	161.4476	199.5000	215.7073	224.5832	230.1619	233.9860	236.7684	238.8827	240.5433	241.8817	243.9060	245.9499	248.0131	249.0518	250.0917
2	18.5128	19.0000	19.1643	19.2468	19.2964	19.3295	19.3532	19.3710	19.3848	19.3959	19.4125	19.4291	19.4458	19.4541	19.4621
3	10.1280	9.5521	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123	8.7855	8.7446	8.7029	8.6602	8.6385	8.6161
4	7.7086	6.9443	6.5914	6.3882	6.2561	6.1631	6.0942	6.0410	5.9988	5.9644	5.9117	5.8578	5.8025	5.7744	5.7451
5	6.6079	5.7861	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725	4.7351	4.6777	4.6188	4.5581	4.5272	4.4951
6	5.9874	5.1433	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.0990	4.0600	3.9999	3.9381	3.8742	3.8415	3.8081
7	5.5914	4.7374	4.3468	4.1203	3.9715	3.8660	3.7870	3.7257	3.6767	3.6365	3.5747	3.5107	3.4445	3.4105	3.3751
8	5.3177	4.4590	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881	3.3472	3.2839	3.2184	3.1503	3.1152	3.0791
9	5.1174	4.2565	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789	3.1373	3.0729	3.0061	2.9365	2.9005	2.8631
10	4.9646	4.1028	3.7083	3.4780	3.3258	3.2172	3.1355	3.0717	3.0204	2.9782	2.9130	2.8450	2.7740	2.7372	2.6991
11	4.8443	3.9823	3.5874	3.3567	3.2039	3.0946	3.0123	2.9480	2.8962	2.8536	2.7876	2.7186	2.6464	2.6090	2.5701
12	4.7472	3.8853	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964	2.7534	2.6866	2.6169	2.5436	2.5055	2.4661
13	4.6672	3.8056	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144	2.6710	2.6037	2.5331	2.4589	2.4202	2.3801

그림 6.7: 일원분산분석검정을 위한 F table




그림 6.8: 일원분산분석검정에서의 임계치와 검정통계량

6.4.4.2 주의: 등분산성 가정

추가로 고려해야할 것인 일원분산분석의 기본 가정이다. 이중 가장 대표적인 것이 세집단의 등분산 가정이다. 만일 등분산 가정이 충족되지 않는다면 F-value를 계산하는 공식이 달라진다.

등분산성을 확인하는 방식은 여러가지다. 바틀렛테스트(bartlett.test)나 레벤테스트(leveneTest)가 대표적이다. 둘다 영가설(H_0)은 집단간 분산이 모두 같다. 연구가설(H_1)은 적어도 두개의 집단의 분산이 서로 다르다. 따라서 두개의 테스트에서 연구가설이 기각된다면 집단간의 등분산성이 확인된다고 볼 수 있다.

```
##
## Bartlett test of homogeneity of variances
##
## data: dataAnova$Y by dataAnova$G
## Bartlett's K-squared = 2.5304, df = 2, p-value = 0.2822
## Loading required package: carData
##
## Attaching package: 'car'
## The following object is masked from 'package:dplyr':
##
##      recode
## The following object is masked from 'package:purrr':
##
##      some
## Warning in leveneTest.default(y = y, group = group, ...): group coerced to
## factor.
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group 2    0.675 0.5275
##      12
```

그 결과 바틀렛테스트와 레벤테스트 모두 연구가설(집단간 분산이 다르다)를 기각하고, 영가설(집단간 분산이 서로 같다)를 채택하였다. 따라서 앞서 일원분산분석 시 `var.equal=TRUE`의 옵션을 지정해주면 된다. 만일 집단간 분산이 서로 다르다면 `var.equal=FALSE`를 넣어주면 그에 맞는 계산이 이루어진다.

제 7 장

분산, 공분산 그리고 상관

두 변수의 관계 + 관련 가설들 + 변수의 척도에 따른 두 변수의 관계

- 분산과 공분산
 - 분산의 의미
 - 두 변수의 분산, 공분산
- 상관계수
 - 공분산의 한계
 - 공분산의 표준화
 - 상관계수의 해석

7.1 두 변수의 관계

7.1.1 관련 가설들

사회과학분야의 상당한 연구들은 두 변수들의 관계를 구명하는데 관심이 있다. 지능이 높으면 행복할까?, 돈이 많으면 결혼생활 만족도가 높을까?, 공부하는 시간이 많으면 시험성적이 높을까? 산업인력개발분야에서도 비슷한 연구질문들이 많다. 상사의 리더십에 긍정적으로 반응하는 사람일수록 직무수행이 우수할까? 임금에 만족하는 사람일수록 주관적 경력성공의 수준이 높을까?

통상 이러한 가설에 포함된 변수들은 일종의 방향이 있다. 다시 말해 낮은 점수에서 높은 점수로의 방향성이 있다. 또한 대부분 리커트 척도(1점~5점 또는 1점 ~ 7점)

로 측정되었기 때문에 등간척도(interval scale)이다. 1점과 2점, 2점과 3점 사이의 간격이 동일하므로 덧셈, 뺄셈이 가능하다.

이러한 척도로 측정된 두개의 변수의 관계는 보통 산점도(scatter plot)을 그려보면 직관적으로 확인이 가능하다.

[원: 증가하는 그래프], [오: 감소하는 그래프]

왼쪽의 그래프는 상사의 리더십과 직무수행 점수를 나타낸다. 상사의 리더십에 긍정적으로 반응하는 사람일수록 직무수행 점수가 높다. 오른쪽의 그래프는 부적인 관계를 나타낸다. 직무만족도가 높을수록 이직 의도가 낮아진다.

7.1.2 변수의 척도에 따른 두 변수의 관계

이러한 두 변수의 관계는 변수를 측정하는 척도(scale)에 따라 제한적이다. 다시 말해 두 변수가 모두 등간척도(interval scale) 이상이어야 한다. 한 변수의 증가폭과 다른 변수의 증가폭이 계산 가능해야 하기 때문이다.

만일 한쪽이 이분변수(성별), 나머지는 연속변수(직무수행점수)라고 생각해보자. X축에 성별을 두고 Y축에 직무수행 점수를 두었을때 산점도를 그릴수 없다.

두 변수 모두 범주변수일때도 마찬가지이다. X축에 성별, Y축에 리더십 유형(합리적 리더십, 성과지향 리더십, 친화적 리더십)을 두고 산점도를 그려보자. 산점도에 의미가 있는가? 산점도는 두 변수 모두 연속형이면서 등간척도일때만 그릴 수 있다.

따라서 변수의 척도에 따라 두 변수의 관계를 구명하는 방식은 다음과 같이 정리할 수 있다.

- 두 변수가 모두 등간척도 일때 : 피어슨 상관분석
- 한 변수가 범주변수, 나머지 변수가 등간척도일때 :
 - 이분변수-등간척도 일때 : t-test
 - 3집단 이상의 범주변수-등간척도 일때 : ANOVA(분산분석)
- 두 변수 모두 범주변수 일때 : 교차분석(cross tabulation)

7.2 분산과 공분산

상관분석을 이해하기 위해서는 먼저 분산(variance)과 공분산(covariance)를 이해해야한다.

7.2.1 분산의 의미

7.2.1.1 분산의 공식

분산은 평균에서 떨어진 정도로 정의할 수 있다. 분산의 공식은 (7.1)과 같다.

$$\begin{aligned} \text{var}(X) = \sigma^2 = \sigma_{xx} &= \frac{1}{N} \sum_{i=1}^N (X_i - \mu)(X_i - \mu) \\ &= \frac{\sum_{i=1}^N (X_i - \mu)^2}{N} \end{aligned} \quad (7.1)$$

가상의 데이터를 활용하여 분산(σ^2)의 공식을 이해해보자. $n=6$ 인 data set = {1, 2, 3, 4, 5, 6}이 있다고 가정하자. 분산은 평균에서 떨어진 정도이기 때문에 평균을 먼저 구해야한다.


$$\bar{X} = (1 + 2 + 3 + 4 + 5 + 6)/6 = 3.5$$

6개의 데이터가 평균에서 떨어진 정도를 확인하기 위해서, 각각의 데이터와 평균의 차이(difference)를 계산한다. 이때 이 차이를 편차라고 부른다 6개의 편차가 확인 되면, 제곱하여 모두 합한다. 제곱을 하지 않는다면 이 차이들의 합은 모두 0이기 때문에 부호를 없애주는 작업이다. 편차제곱합을 분자로 두고, 분모를 데이터의 갯수(n)으로 두면 이것이 바로 분산이다.

$$\sigma^2 = \frac{(1 - 3.5)^2 + (2 - 3.5)^2 + (3 - 3.5)^2 + (4 - 3.5)^2 + (5 - 3.5)^2 + (6 - 3.5)^2}{6} = 2.917$$

7.2.1.2 시각적으로 이해하는 분산

공분산을 이해하기 위해 분산을 시각적으로 이해해보자. 앞서 살펴본 6개의 데이터를 갖고 있는 X를 자격증 수로 가정해보자. 이와 함께 또 하나의 변수 Y(직무수행점수)를 가정해보자. Y는 {15, 30, 45, 55, 70, 100}이라고 가정하자. 예를 들어 첫번째 사례(사람)은 자격증 수(X)는 1개이고, 직무수행점수는 15점이다.



위의 두 그래프에서 볼 수 있듯이 분산의 기본은 편차의 제곱, 다시 말해 편차*편차이므로 총 6개의 사각형의 넓이가 만들어진다. 사각형의 넓이의 합이 클수록 분산이 커진다. 또한 분산에서는 1사분면과 3사분면에만 편차제곱, 즉 사각형이 만들어진다는 점을 염두해 두자. Y의 분산은 907.5로 X보다 분산이 크다. 이것은




그림 7.1: X 의 분산




그림 7.2: Y의 분산



두 가지에서 기인하는데 1)실제로 Y의 자료들이 평균에서 떨어진 정도가 크고, 2)Y의 척도(scale)이 0~100이므로 X의 척도보다 크기 때문이다. 따라서 분산값은 서로 다른 척도를 가진 자료들을 비교하는데는 적절하지 않다.



7.2.2 두 변수의 분산, 공분산

공분산은 이름에서 추측할 수 있듯이 서로다른 두개의 변수의 공통된 분포를 나타내는 분산이다. 공분산의 공식은 (7.2)과 같다. (7.1)와 비교해보면 $(X_i - \mu) * (X_i - \mu)$ 대신에 $(X_i - \mu_x) * (Y_i - \mu_y)$ 로 바뀐것을 볼 수 있다. 다시 말해 X의 편차 제곱이 X 편차*Y편차로 바뀐 것이다

$$\begin{aligned} Cov(X, Y) &= \sigma_{xy} \\ &= \frac{1}{N} \sum_{i=1}^N (X_i - \mu_x)(Y_i - \mu_y) \end{aligned} \quad (7.2)$$

```
##   X  Y1  Y2  Y3
## 1 1   15 100  30
## 2 2   30  70  15
## 3 3   45  55 100
## 4 4   55  45  70
## 5 5   70  30  55
## 6 6  100  15  45
```





$$\begin{array}{c}
 \text{3사분면} \\
 \underbrace{(-)*(-) + (-)*(-) + (-)*(-)}_{\text{양의 값}} + \underbrace{(+)*(+) + (+)*(+) + (+)*(+)}_{\text{양의 값}} = \text{공분산 양의 값} \\
 \text{1사분면}
 \end{array}$$




그림 7.3: 음의 공분산




그림 7.4: 0에 가까운 공분산

7.3 상관계수

7.3.1 공분산의 한계

앞서 살펴본 바와 같이 공분산의 부호는 두 변수의 관계를 알려준다. 양의 부호인 경우에는 정적인 관계를, 음의 부호인 경우에는 부적인 관계를 갖는다. 공분산의 절대값 역시 정보를 갖고 있다. 0에 가까울수록 두 변수의 관계가 거의 없는 것을 알 수 있다. 그러나 공분산의 절대값 만으로 두 변수간의 관계가 강하다, 약하다 등의 결론을 내릴 수는 없다. 그 이유는 분산의 특징에서 기인한다. 분산과 공분산 모두 변수의 척도에 민감하게 영향을 받기 때문이다. 만일 0~5로 측정된 두 변수의 공분산과, 0~100으로 측정된 두 변수의 공분산을 비교한다고 가정하자. 아마도 높은 확률로 0~100으로 측정된 두 변수의 공분산이 크다. 척도의 범주가 더 크기 때문에 편차가 더 크기 때문이다.


따라서 공분산은 척도가 다른 변수들의 관계들을 비교하기가 어렵다.

7.3.2 공분산의 표준화=상관계수

공분산이 척도에 민감하게 반응하는 문제를 해결하기 위해서는 표준화(standardization)가 필요하다. 표준화는 두 변수의 공분산을 각각의 변수의 표준편차로 나누는 방식을 취한다. 상관계수의 공식은 (7.3)과 같다.

$$\begin{aligned}
 \text{corr}(X, Y) = \rho &= \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}} \\
 &= \frac{\sigma_{XY}}{\sqrt{\sigma_{xx}}\sqrt{\sigma_{yy}}} \\
 &= \frac{\sigma_{xy}}{\sigma_x \sigma_y}
 \end{aligned} \tag{7.3}$$

지금까지의 분산, 공분산, 상관계수의 공식은 모집단에 대한 공식이다. 이를 표본에서 추정하기 위해서는 분모가 N 이 아닌 $n-1$ 로 바뀌고, 분산, 공분산, 상관계수의 기호도 S^2 , S_{xy} , r 로 바뀌는 것에 유의하자.



이훈영(2008). 이훈영교수의 연구조사 방법론.

그림 7.5: 모집단과 표본에서의 분산, 공분산, 상관계수 공식

7.3.3 상관계수의 해석

두 변수의 공분산을 표준화한 상관계수(r)는 공분산의 크기와 두 변수의 표준편차에 의해 결정된다. 부호는 공분산의 부호와 같다. 또한 -1에서 1 사이의 값을 갖게 된다. 상관계수의 특징은 다음과 같다.

- 상관계수의 범위 : $-1 \leq r \leq 1$
- 변수에 일정하게 0이 아닌 상수를 더하거나, 양의 상수를 곱하더라도 상관계수의 값은 변하지 않음
- 음의 상수를 한 변수에 곱하면 상관계수의 부호만 바뀜
- 음의 상수를 두 변수에 곱하면 상관계수는 변하지 않음

상관계수의 장점은 두 변수의 관계를 수량화하여 비교하고, 관계의 정도를 일정하게 판단할 수 있다는 데 있다. 주로 사회과학분야에서 상관계수를 해석하는 기준은 다음과 같다.

- $|r| \leq 0.2$: 관계가 거의 없음
- $0.2 \leq |r| \leq 0.4$: 낮은 상관관계
- $0.4 \leq |r| \leq 0.6$: 비교적 높은 상관관계
- $0.6 \leq |r| \leq 0.8$: 높은 상관관계
- $0.8 \leq |r| \leq 1.0$: 매우 높은 상관관계

7.3.4 상관계수 추정 및 유의성 검정

실제 데이터를 활용하여 상관계수를 계산해보고 유의성을 검정해보도록 하자. X는 자격증 갯수, Y는 직무수행 점수라고 가정한다. 개인이 갖고 있는 자격증 갯수와 직무수행점수와 유의미한 관계가 있는지 알고 싶다. 이때 연구가설과 영가설은 다음과 같다.

영가설(H_0) : 자격증갯수(X)와 직무수행점수(Y)는 선형관계가 없다. (또는 상관계수가 0이다) 연구가설(H_1) : 자격증갯수(X)와 직무수행점수(Y)는 선형관계가 있다. (또는 상관계수가 0이 아니다)

연구가설이 유의수준(α) 0.05에서 유의한지를 확인하려고 한다.

7.3.4.1 손으로 풀어보는 상관계수 검정

다음의 10개 데이터를 활용하여 상관계수 r 을 추정하려면, X의 편차($X - \mu_x$)와 편차 제곱($(X - \mu_x)^2$), Y의 편차($Y - \mu_y$)와 편차제곱($(Y - \mu_y)^2$), 그리고 X편차와 y편차의 곱($(X - \mu_x)(Y - \mu_y)$)을 각 사례별로 모두 계산한다.


ID	X	Y	X 편차		Y 편차		X 편차*Y 편차
			X 편차	제곱	Y 편차	제곱	편차
1	1	15	-2.3	5.29	-39.5	1560.25	90.85
2	1	30	-2.3	5.29	-24.5	600.25	56.35
3	2	45	-1.3	1.69	-9.5	90.25	12.35
4	3	40	-0.3	0.09	-14.5	210.25	4.35
5	3	50	-0.3	0.09	-4.5	20.25	1.35
6	2	55	-1.3	1.69	0.5	0.25	-0.65
7	4	60	0.7	0.49	5.5	30.25	3.85
8	5	70	1.7	2.89	15.5	240.25	26.35
9	5	80	1.7	2.89	25.5	650.25	43.35
10	7	100	3.7	13.69	45.5	2070.25	168.35
mean	3.3	54.5	sum	34.1	sum	5472.5	406.5

상관계수 r 의 공식에 따라 아래의 식처럼 계산이 가능하다. 분자와 분모의 $(n-1)$ 은 소거됨을 확인하다. 그 결과 자격증 갯수(X)와 직무수행점수(Y)의 상관계수(r)은 0.94로 매우 높은 정적인 상관이 있는 것으로 나타났다.

$$r = \frac{S_{xy}}{S_x S_y} = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1)}}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}} = \frac{406.5}{\sqrt{34.1 * 5472.5}} = \frac{406.5}{\sqrt{186612.25}} = 0.94$$

연구가설이 채택되기 위해서는 r 의 유의성이 검증되어야 한다. 상관계수 r 의 검정 통계량 t 의 공식은 다음과 같다. t 분포의 자유도(df)는 $n-2$ 로, 이 사례에서는 $10-2=8$ 이다.

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.94 * \left(\sqrt{\frac{8}{1-(0.94)^2}} \right) = 0.94 * 8.290 = 7.7926$$



위의 그림은 자유도(df) 8의 t분포표이다. 유의확률 0.05는 양측검정시 0.025이므로, 이때 임계치는 +2.306, -2.306이다(t-table 참조). 검정통계량은 임계치의 절대값을 한참 상회하는 7.7926이므로 상관계수 r 은 유의하다. 따라서 연구가설 (H_1 : 개인의 자격증 갯수와 직무수행점수의 상관계수는 0이 아니다)를 채택하게 된다.

7.3.4.2 R을 활용한 상관계수 검정

데이터 셋이 있는 경우에 R을 활용하여 상관계수를 검정하는것은 매우 쉽다.
`cor.test(데이터프레임[,1], pt0EΦD변수2)`

```
X<-c(1, 1, 2, 3, 3, 2, 4, 5, 5, 7)
Y<-c(15, 30, 45, 40, 50, 55, 60, 70, 80, 100)
correlation <-data.frame(X, Y)
cor.test(correlation$X, correlation$Y)
##
## Pearson's product-moment correlation
##
## data: correlation$X and correlation$Y
## t = 7.8651, df = 8, p-value = 4.935e-05
```

```
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.7640734 0.9862784
## sample estimates:
##          cor
## 0.9410018
```

7.4 편상관계수

tbd

제 8 장

직관으로 이해하는 회귀분석

- 산업인력개발에서의 회귀분석
 - 변수간의 관계를 구명하는 연구가설들
 - 연구가설을 검정하기 위해 필요한 데이터의 구조
- 회귀분석과 1차함수
 - 절편의 의미
 - 기울기의 의미
 - $\hat{Y}$ 와 Y
 - 변수가 여러개일때 계수의 해석(다중회귀분석과 통제변수)
- 회귀분석과 2차함수
 - 연구문제(임금방정식)
 - 절편의 의미
 - 기울기의 의미
- 회귀식으로 이해하는 조절효과
 - 조절효과의 개념
 - 회귀식 만들기과 해석하기
 - 분석결과 해석하기
- 회귀식으로 이해하는 매개효과
 - 매개효과의 개념
 - 회귀식 만들기과 해석하기
 - 분석결과 해석하기

8.1 산업인력개발에서의 회귀분석

산업인력개발분야에서 이루어지는 상당수의 연구들은 회귀분석을 기초로 하고 있다. 회귀분석은 중급이상의 연구방법의 밑바탕이 되며, 최근 연구들에서 많이 쓰이고 있는 조절효과, 매개효과분석, 구조방정식분석, 다층모형 분석 등의 기초이다. 회귀분석에서 가장 중요한 것은 회귀식을 이해하는 것인데, 상술한 연구방법들이 모두 간단한 회귀식의 조합으로 풀어나갈 수 있기 때문이다. 이 책의 9장은 다른 장과 다르게 좀더 직관적으로 회귀분석을 설명하려고 한다.

8.1.1 변수간의 관계를 구명하는 연구가설들


회귀분석이란 무엇인가? 간단히 회귀분석의 특징과 목적을 설명하면 다음과 같다.
* 두 변수간의 “관계”를 분석하는 목적이 있다. * 두 변수간의 “관계”는 수치화하여 비교할 수 있다.

8.2 회귀분석과 1차 함수

8.2.1 절편과 기울기의 의미

예를 들어 근로자의 '학습시간'과 '직무성과'가 관계가 있다고 가정해보자. 근로자 10명으로부터 작년 1년간의 학습시간과 그 해의 직무성과 자료를 다음의 표와 같이 수집하였다.

ID	X(학습시간)	Y(직무성과)
1	1	12
2	0.5	11
3	2	18
4	3	19
5	3	21
6	3.5	18.5
7	4	21.5
8	4	23.5
9	4.5	22.5
10	5	25



이 10개의 자료를 X축을 학습시간, Y는 직무성과점으로 두고 산점도를 그려보자. 10개의 점이 찍혀 있는 그래프를 보면 학습시간이 많은 사람일수록 직무성과점이 대체로 높다는 것을 알 수 있다. 오른쪽 그래프에는 10개의 점을 가장 잘 설명하는 직선을 하나 그려보았다. 이 직선은 1차 함수($Y = 10 + 3X$)로 간단히 표현할 수 있다.

1차 함수는 X 가 Y 에 대응되는 규칙이다. X 에 특정값을 투입하면 함수라는 규칙에 따라 특정한 Y 가 산출된다. 중학교 수학시간에 배웠던 간단한 1차 함수의 특징을 생각해보자

- 절편(intercept) : X 가 0일때 Y 의 값
- 기울기(slope) : X 가 한 단위 변화할때 Y 가 변화하는 양이다.


이 함수에서 절편은 10이다. 그래프에서도 X 가 0일때 Y 값은 10인것을 확인할 수 있다. 이 절편은 회귀분석시에도 자주 해석이 되므로 기억할 필요가 있다. 이 데이터에서는 X (학습시간)이 0인 사람의 예측되는 Y (직무성과점)가 10점이라고 해석할 수 있다. 기울기는 X 로 미분한 값으로도 해석할수 있는데, 1차 함수이기 때문에 기울기는 “3”인 상수이다. 다시 말하면 어떠한 X 값이든 한 단위 변화할때 Y 의 변화량이 동일하다는 것이다. 파란선의 기울기가 어떠한 구간에서도 동일한 직선임을 확인하자. 이러한 1차 함수의 특징을 고려하여 X 와 Y 가 선형적인 관계 (Linear relationship)라고 부른다.

8.2.2 기울기의 의미

여기서 기울기는 보통 “회귀계수(regression coefficient)”라고 불린다. 독립변수(X)와 종속변수(Y)의 관계를 나타내는 계수이다. 회귀계수를 해석하는 방식은 1차 함수에서 기울기 값을 이해하면 매우 쉽게 기억할 수 있다.

- 기울기(회귀계수)의 부호

- 양의 값(+)을 가지면 : X와 Y의 관계가 정적(positive)이다. X가 증가할 때 Y가 증가한다.
- 음의 값(-)을 가지면 : X와 Y의 관계가 부정(negative)이다. X가 증가할 때 Y가 감소한다.



8.2.3 $\hat{Y}$, Y와 잔차(residual)

'학습시간(X)과 '직무성과(Y)'의 그래프를 다시 살펴보자. $Y = 10 + 3X$ 라는 1차 함수는 X를 투입했을 때 산출되는 Y의 값이다. 우리가 갖고 있는 10개의 데이터는 이 함수에 의해 대체로 잘 예측되고 있지만, 그렇지 않은 데이터도 있다.

- ID=1인 사람의 학습시간(X)은 1이고, 직무성과(Y)는 12이다. 함수에 의해 예측되는 Y값은 $10 + (3 * 1) = 13$ 으로 “1만큼의 격차가 있다. 이때 함수에 의해 예측되는”13”을 우리는 $\hat{Y}$ 라고 부른다.
- 이와 동일하게 나머지 데이터에서도 $\hat{Y}$ 를 다음의 표와 같이 계산할 수 있다.
- 실제 관측된 Y와 계산된 $\hat{Y}$ 의 차이(difference)도 옆에 계산해보자. $Y - \hat{Y}$ = 잔차(residual)로 정의한다.

ID	X(학습시간)	Y(직무성과)	예측된 Y($\hat{Y}$)	$Y - \hat{Y}$
1	1	12	13	-1.0

ID	X (학습시간)	Y (직무성과)	예측된 $Y(\hat{Y})$	$Y - \hat{Y}$
2	0.5	11	11.5	-0.5
3	2	18	16	2
4	3	19	19	0.0
5	3	21	19	2.0
6	3.5	18.5	20.5	-2.0
7	4	21.5	22	-0.5
8	4	23.5	22	1.5
9	4.5	22.5	23.5	-1.0
10	5	25	25	0.0

여기에 아랫첨자(i)를 넣어서 종합해보면 다음과 같다.

- X_i : i 번째 사람의 관측된 X 값이다. 예: $X_3 = 2$
- Y_i : i 번째 사람의 관측된(observed) Y 값이다. 예: $Y_3 = 18$ 이때 “관측되었다”는 뜻은 우리가 관찰한, 또는 측정한 값이라는 뜻이다. (가상의 값이 아님)
- $\hat{Y}_i$: i 번째 사람의 예측된(predicted) Y 값이다. 예: $\hat{Y}_3 = 16$. 예측된 값 16은 $\hat{Y} = 10 + 3X$ 라는 추정된 회귀식에 $X_3 = 2$ 의 값을 넣어서 생성된 값이다 ($10 + (3 \times 2) = 16$)
- $residual_i = Y_i - \hat{Y}_i$: i 번째 사람의 관측값과 예측된 값의 차이이다. 예: $residual_3 = 2$

회귀식은 우리의 관측치를 완벽히 설명할수가 없기 때문에, 잔차는 필연적으로 발생한다. 예를 들어 ID 4번과 5번은 X 의 값이 3으로 같다. 10개의 데이터를 통해 추정된 회귀식 $\hat{Y} = 10 + 3X$ 에 $X = 3$ 을 투입하면 $\hat{Y}$ 는 19이다. ID 4번의 사람은 Y 가 19로 $\hat{Y}$ 19와 같아잔차가 0인데 반해, ID 5번의 사람은 $Y_4 = 21$ 로 잔차가 2만큼 발생한다.

잔차는 작을수록 좋다. 우리가 추정한 회귀식이 관측된 값들을 잘 예측한다는 뜻이기 때문이다. 따라서 회귀분석을 할때 추정되는 회귀계수(절편과 회귀)는 잔차를 최소화하는 방식으로 계산된다. 이와 관련한 자세한 내용은 Chapter 9에서 다루도록 하겠다.

위의 데이터를 활용해서 실제로 회귀분석을 실시해보자. Chapter 9에서 다루겠지만 R에서 회귀분석은 매우 간단한 코드로 이루어져있다. 여기서 산출되는 값을 활용해 다시 한번 회귀식을 제대로 이해해보자.

```

ID<-c(1,2,3,4,5,6,7,8,9,10)
X<-c(1, 0.5, 2, 3, 3, 3.5, 4, 4, 4.5, 5)
Y<-c(12, 11, 18, 19, 21, 18.5, 21.5, 23.5, 22.5, 25)
Learning <-data.frame(ID, X, Y)
learningReg <-lm(Y ~ X, data=Learning)
summary(learningReg)
##
## Call:
## lm(formula = Y ~ X, data = Learning)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.0437 -0.9187 -0.2937  1.0917  1.9493
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.0925     1.0930   9.233 1.53e-05 ***
## X              2.9861     0.3255   9.173 1.61e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.446 on 8 degrees of freedom
## Multiple R-squared:  0.9132, Adjusted R-squared:  0.9023
## F-statistic: 84.15 on 1 and 8 DF, p-value: 1.611e-05
resid(learningReg)
##           1           2           3           4           5           6
## -1.07858048 -0.58555133  1.93536122 -0.05069708  1.94930292 -2.04372624
##           7           8           9          10
## -0.53675539  1.46324461 -1.02978454 -0.02281369

```

R의 내장함수인 lm을 사용하면 간단히 회귀분석을 실시할 수 있다. 명령어의 사용법은 다음과 같다. * 회귀분석결과 <- lm(종속변수 ~ 독립변수, data=사용할 data.frame) 또한 회귀분석결과와 잔차를 확인하는 명령어는 다음과 같다. * summary(회귀분석결과) * resid (회귀분석결과)

산출된 회귀분석결과를 살펴보면 크게 두 가지의 coefficient가 추정되어 있다. 절편(Intercept)과 기울기(X)이다. 절편의 추정치는 10.0925, 기울기의 추정치는 2.9861이다. 추정치 옆에는 3개의 값이 붙는다 표준오차(standard error)와 t-value, 그리고 p-value이다. 이 3개의 값의 의미는 chapter 9에서 다시 다룰테니 일단 넘어가자. 절편과 기울기의 추정치를 활용하여 회귀식을 구성해보면 다음과 같다.

(8.1)

$$\hat{Y} = 10.0925 + (2.9861 * X) \quad (8.1)$$

(8.1)를 잔차가 포함된 회귀식으로 다시 쓰면 (8.2)과 같다.

$$Y = 10.0925 + (2.9861 * X) + e \quad (8.2)$$

resid()를 활용해서 호출한 10개의 잔차값을 확인하면 -2.0437부터 1.9493 까지 분포를 보인다. 이 중 첫번째 사람(ID=1)의 데이터를 활용해서 회귀식을 재확인해보자.

- $X_1 = 1$, $residual_1 = -1.0785048$ 이고,
- $Y = 10.0925 + (2.9861 * X) + e$ 에 위의 값을 넣어보면,
- $10.0925 + (2.9861 * 1) - 1.0785048 = 12.0001$ 로 $Y_1 = 12$ 과 같은 것을 확인할 수 있다.

많은 사람들이 회귀분석결과를 해석할때 다음과 같은 오류를 범한다.

- 절편을 해석하지 않거나,
- 회귀계수의 유의성에만 의미를 부여하거나, ($p < 0.001$ 수준에서 유의했다)
- 회귀계수의 부호만 해석한다 (정적인 효과가 있다, 부적인 효과가 있다)

이를 방지하기 위해서는 반드시 회귀식을 만들어서, 좀 더 선명한 해석을 할 필요가 있다. 회귀식을 만들어 절편과 기울기의 의미를 정확히 이해하고 해석한다면 보다 풍부한 설명이 가능하다. 또한 이러한 단순회귀식을 정확히 이해해야만, 조절효과, 매개효과, 구조방정식, 다층모형 등 다양한 고급 다변량 분석을 손쉽게 이해할 수 있다.


8.2.4 독립변수가 두 개 이상일때의 회귀식

지금까지 살펴본 회귀식은 독립변수가 1개인 단순회귀분석이다. 따라서 X와 Y의 관계를 간단한 1차함수로 설명할 수 있다. 산업인력개발 연구장면에서는 대부분

독립변수 X 가 2개 이상인 다중회귀분석(multi-variate regression)을 수행한다. 회귀분석의 목적은 종속변수(Y)를 예측하는 것이라는 점을 생각해보면, 종속변수를 설명하는 독립변수는 많은 것이 자연스럽다. 앞서 다뤘던 재직자의 직무성과 점수를 예측하는 첫번째 독립변수($X1$, 학습시간)을 생각해보자. 개인의 직무성과에 미치는 영향을 미치는 다른 변수($X2$, 근무기간)이 있다고 가정할 수 있다. 이 데이터를 다음과 같이 확보했다고 생각해보자.

ID	X1(학습시간)	X2(근무기간)	Y(직무성과)
1	1	16	12
2	0.5	20	11
3	2	28	18
4	3	29	19
5	3	32	21
6	3.5	30	18.5
7	4	50	21.5
8	4	41	23.5
9	4.5	40	22.5
10	5	60	25

종속변수 1개와 독립변수 1개의 관계는 2차원으로 표현할 수 있었다. 당연하게도 종속변수 2개와 독립변수 1개의 관계는 3차원으로 표현해야 한다. 아래 그림은 종속변수 Y 를 Z 축으로 두고 10개의 데이터를 좌표에 표시한 것이다. 데이터는 3개의 좌표를 갖기 때문에 데이터의 집합은 더이상 선이 아니라 면의 형태를 갖게 된다. 두 번째 그림은 데이터를 가장 잘 설명하는, 다시 말해 잔차를 최소화하는 평평한 면을 표시한 것이다.



이처럼 독립변수가 2개 이상이 되면 더이상 1차 함수로 설명하기 곤란해진다. 독립변수가 2개이면 3차원으로 표시가 가능하지만, 독립변수가 3개라면 4차원, 4개라면 5차원 등 시각화가 어려워지기 때문에 더욱 어렵다. 따라서 다중회귀분석부터는 회귀식으로 이해하는 것이 편리하다. 위의 그래프에서 활용한 두 개의

독립변수(X_1 , X_2)를 Y 에 대해 회귀분석을 해보자. 아래 결과표를 활용해서 회귀식을 구성해보면 아래와 같다.

```
##
## Call:
## lm(formula = Y ~ X1 + X2, data = multiLearning)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.6684 -0.8821 -0.6049  1.1867  2.0497
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   9.63316     1.41213   6.822 0.000248 ***
## X1             2.61870     0.74485   3.516 0.009784 **
## X2             0.04566     0.08233   0.555 0.596458
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.513 on 7 degrees of freedom
## Multiple R-squared:  0.9168, Adjusted R-squared:  0.8931
## F-statistic: 38.59 on 2 and 7 DF,  p-value: 0.0001659
##           1           2           3           4           5           6           7
## -0.9824018 -0.8556850  1.8509879  0.1866247  2.0496482 -1.6683863 -0.8909152
##           8           9          10
##  1.5200143 -0.7436790 -0.4662078
```

$$Y = 9.63316 + 2.61870 * (X_1) + 0.04566(X_2) + e$$

우리는 총 3개의 추정치(절편, X_1 의 기울기, X_2 의 기울기)를 갖는다.

- 절편 : X_1 과 X_2 가 모두 0일때, Y 의 값 $9.63316 = 9.63316 + 2.61870 * 0 + 0.04566 * 0$
- X_1 의 기울기(회귀계수) : 회귀식을 X_1 으로 편미분한 값. 해석은 다음과 같이 다양함 ** X_2 를 상수(constant)로 두었을 때, X_1 한단위 변화할때 Y 의

변화량 ** X2를 고정했을 때, X1 한단위 변화할때 Y의 변화량 ** X2를 통제했을 때, X1 한단위 변화할때 Y의 변화량 ** X2가 random하게 assigned 되었을때, X1 한단위 변화할때 Y의 변화량

- X2의 기울기(회귀계수) : 회귀식을 X2으로 편미분한 값. ** X1을 상수(constant)로 두었을 때, X2 한단위 변화할때 Y의 변화량 ** X1을 고정했을 때, X2 한단위 변화할때 Y의 변화량 ** X1을 통제했을 때, X2 한단위 변화할때 Y의 변화량 ** X1이 random하게 assigned되었을때, X2 한단위 변화할때 Y의 변화량

이제 회귀식이 눈에 익을것이라고 생각한다. 이상의 내용을 종합해서 기본적인 선형 회귀식은 (8.3)과 같이 쓸 수 있다.

$$Y = \beta_0 + \beta_1 * X_1 + \beta_2 * X_2 + \cdots + \beta_i * X_i + e \quad (8.3)$$

8.2.5 added variable plot

많은 사람들이 다중회귀분석을 해석할때 통제 변수에 대한 해석을 어려워한다. 좀더 간편한 이해를 위해 예를 들어 설명해보려고 한다.


만일 독립변수가 두 개인 경우라면, (8.4)와 같이 쓸 수 있다.

$$Y = \beta_0 + \beta_1 * X_1 + \beta_2 * X_2 + e \quad (8.4)$$

또한 이때 독립변수 두개는 정적인 상관관계를 가진다고 가정하자(대부분의 사회과학의 변수가 상관관계가 있다는 걸 염두에 두자). 또한 X_1 과 Y , X_2 와 Y 는 모두 정적인 관계를 갖는다고 가정한다. 이때 β_1 와 β_2 를 어떻게 해석해야 할까? 먼저 β_1 을 해석해보자.

(8.4)에서 β_1 는 X_2 를 고정했을때(또는 통제했을때의, X_1 이 Y 에 미치는 영향이다. 반대로 오직 X_1 만 투입한 단순회귀분석을 생각해보면 다음과 같다. $Y = \beta_0' + \beta_1' * X_1 + e'$ 당연히 절편, 기울기, 잔차 모두 (8.4)와 달라진다. 이때 β_1' 는 X_2 를 고정하지 않았을 때의 회귀식이다. 만일 X_2 와 Y 가 정적인 영향관계가 있다면 $\beta_1 > 0$ 이다. 하지만 X_1 이 증가할수록 X_2 가 함께 증가하고(두 변수가 positively correlated), $\beta_2 > 0$ 이므로, Y 의 평균값은 X_1 만 단독 투입했을 때보다 증가한다. 따라서 $\beta_1 < \beta_1'$ 이 된다. 만일 X_1 과 X_2 의 상관관계가 강하다면, 이러한 경향성은 더욱 강화된다.

따라서 하나의 독립변수와 종속변수의 simple regression graph를 그려 설명하는 것은 매우 위험하다. 대신에 나머지 변수들을 통제하고 관심변수와 종속변수의 관계를 설명할 수 있는 그래프인 'added variable plot', 'partial regression plot'을 활용하는 것이 좋다. Frisch-Waugh-Lovell theorem을 활용하여 다른 독립변수의 영향력을 'partial out'시킨 결과를 그래프에 표시하는 것이다.



위의 value added 그래프의 좌측은 $X1$ - Y 의 관계, 우측은 $X2$ - Y 의 관계를 의미한다. 좌측을 중심으로 설명하면 Y 축은 ' $Y < X2$ ' 회귀식의 잔차를 나타내고 있다. X 축은 ' $X1 < X2$ ' 회귀식의 잔차를 나타낸다. 종속변수와 독립변수 모두 $X2$ 가 미치는 영향을 partial out 한 것이다.

8.3 회귀분석과 2차함수

8.3.1 비선형 회귀분석

지금까지 우리가 다른 회귀분석은 선형적(linear)이었다. 이때 선형이라는 뜻은 X 값에 관계없이 X - Y 의 관계가 일정하다, 다시 말해 기울기값이 동일하다는 뜻이다. $Y = a + bx$ 의 간단한 1차함수를 떠올려보면, X 와 Y 의 관계는 언제나 일정하다.


비선형관계의 회귀분석은 보통 2차 함수부터 시작한다. 중학교때 배웠던 2차 함수

의 포물선을 생각해보자. 가장 기본적인 형태의 2차함수는 다음과 같이 표현한다.

$$Y = aX^2 + bX + c.$$

아래 그래프는 $Y = X^2 + 2X - 24$ 를 그래프로 표현한 것이다. 그래프를 그리기 위해 중요한 값 3개가 있다.

- 'X 절편' = $Y=0$ 의 값을 갖는 X 값 예: $0 = X^2 + 2X - 24 = (X + 4)(X - 6)$ 이므로 '-4'와 '6'이다.
- 'Y 절편' = $X=0$ 의 값을 갖는 Y 값 $y = a * 0^2 + b * 0 + c$ 이므로 ' $c=-24$ '이다.
- 꼭지점 : Y 가 최대($a < 0$) 또는 최소($a > 0$)의 값을 갖는 지점 $X = -\frac{b}{2a}, Y = f(-\frac{b}{2a})$ 따라서 $(-1, -25)$ 이다.





2차함수의 모양은 a, b, c 의 값에 따라 달라진다. 아래 그래프를 보면 각 계수의 부호에 따라 그래프의 모양과 위치가 달라지는 것을 알 수 있다. 중학교 시절 수학을 떠올려보면 다음과 같이 정리가 가능하다.


- 2차항의 계수 ' a '의 부호 : 그래프의 오목함과 볼록함을 결정
 - $a > 0$: 볼록한 비선형
 - $a < 0$: 오목한 비선형
- 1차항의 계수 ' b '의 부호 : y 축을 지날때 상승/하강

- $b > 0$: 좌에서 우로 y 축을 지날때 상승
- $b < 0$: 좌에서 우로 y 축을 지날때 하강

- 상수항의 계수 'c'의 부호 : 그래프의 Y절편을 결정함

- $c > 0$: y 절편이 양의 값
- $c < 0$: y 절편이 음의 값





예를 들어 개인의 시험점수(Y)와 학습시간(X)의 관계를 2차 함수로 설명해보자. 첫번째 그래프의 함수인 $Y = 2X^2 + 20X + 100$ 를 회귀식으로 쓰면(8.5)와 같다.

$$\hat{Y} = 100 + (20 * X) + 2X^2 \quad (8.5)$$

8.3.2 절편의 의미

여기서 Y 절편은 100으로, 'X가 0일때 Y의 값'이다. 그래프에서 포물선이 Y축을 지날때 Y값이 100인것을 확인하자. 이 연구문제에서는 학습시간이 0인 사람의 예측된 시험점수(predicted Y, $\hat{y}$)가 100점이라는 뜻이다.

8.3.3 1차항및 2차항의 기울기의 의미

선형 회귀분석(1차함수)와 달리 비선형 회귀분석에서는 기울기를 나타내는 항이 2개 이상으로 늘어난다. 2차함수를 기준으로 살펴보면, 기울기를 나타내는 항은 $20X$ 와 $2X^2$ 의 두개의 계수 값을 모두 해석해야 한다.

가장 간단하게 기울기를 확인할 수 있는 방법은 미분(differentiation)을 하는 것이다. 미분이란 어떤 면을 미세하게 층층히 쪼개었을때, 각각의 층을 '미세한 부분'이라고 하여 미분이라고 부르는 것이 어원이다. 좀더 간단히 설명하면 '한 점에서의

기울기'라고 할 수 있다. $Y = F(x)$ 라는 함수 위의 $(a, f(a))$ 라는 특정한 점에서의 기울기이고 $f'(a)$ 로 표시한다. 이때 $f'(a)$ 는 다음과 같은 뜻이다.


- $X=a$ 인 점에서의 기울기
- $X=a$ 인 점에서의 접선의 기울기
- $X=a$ 인 점에서의 미분값
- $X=a$ 인 점에서의 미분계수

다시 원래의 회귀식(8.5)로 돌아와 생각해보자. 이 함수의 기울기(X 단위 변화시 Y 의 변화량)을 구하기 위해서는 X 로 미분한다. 고등학교때 배웠던 간단한 미분공식을 활용해보면 아래와 같다.¹.

$$\frac{d}{dx}f(x) = f'(x) = 2 * 2 * X + 20 = 4X + 20$$

따라서 이 2차함수의 기울기는 $4X+20$ 이다. 2차항이 존재하기 때문에 X 로 한번 미분했을 때 상수가 아닌 X 가 포함된 값이 나온다. 이것은 무엇을 의미할까? 이는 X 의 값에 따라 기울기의 값이 변화한다는 비선형함수의 특징을 나타낸다. 잘 이해가 안될때는 X 에 특정 값을 반복해서 넣고, 이를 그래프로 이해해보자.

¹1차 함수의 기울기도 미분의 방식으로 생각해보면 이해에 도움이 된다. $Y = 3x + 10$ 을 미분하면, 기울기는 3인 상수이다. 직선인 1차함수의 그래프를 생각해보면 x 의 값에 관계없이 기울기가 일정하다



- $X=0$ 일때, 기울기 $= 4 * 0 + 20 = 20$
- $X=1$ 일때, 기울기 $= 4 * 1 + 20 = 24$
- $X=2$ 일때, 기울기 $= 4 * 2 + 20 = 28$
- $X=3$ 일때, 기울기 $= 4 * 3 + 20 = 32$

그림과 대입값에서 볼수 있듯이 기울기는 고정(constant)되지 않고, 계속 변화한다.

구체적으로는 X 가 증가할 수록 기울기는 점차 증가한다.


여기서 ‘기울기는 변화한다’는 뜻은 기울기의 ‘변화량’이 존재한다는 뜻이다. 이때 기울기의 변화량은 X 가 한단위 증가할때, Y 의 변화량의 변화량이다. 이는 $f(x)$ 를 X 로 두 번 미분한 값, 다시 말해 $f''(x)$ 이다. 종합해보면 다음과 같다.

$$\frac{d}{dx}f'(x)=f''(x)=4$$

이 2차 함수를 두 번 미분한 값, 다시 말해 기울기의 변화량은 ‘4’이다. 위의 그림에서 X 가 0일때 기울기가 20, X 가 1일때 기울기가 24, X 가 2일때 기울기가 28로, x 가 한단위 변화할때 기울기는 ‘4’씩 변화하는 것을 볼 수 있다.

8.3.4 임금방정식으로 이해하는 비선형 회귀분석

비선형 회귀분석은 사회과학에서 빈번하게 활용된다. 가장 대표적인 사례는 Mincer (19##)의 임금 방정식일 것이다. 개인의 임금은 보통 연령에 따라 증가하지만 선형적인 관계는 아니다. 다시 말해 나이가 들수록 임금이 상승하지만 기울기는 변화하다가, 특정한 나이에 정점을 찍고 살짝 감소하는 비선형 관계를 갖고 있다. Mincer의 임금방정식은 연령-임금의 관계를 기초로 교육연한, 경력연한 등의 관계를 구명하는 목적을 갖고 있지만, 우리는 단순화하여 연령-임금의 관계만 국한해서 설명해보자.



좌측의 그림은 1차함수($Y(\check{\Phi}) = 5 * X + 100$), 우측의 그림은 2차함수 ($Y(\check{\Phi}) = -0.04 * X^2 + 5 * X + 200$)을 나타낸다. 선형관계인 1차함수는 나이가 증가할 수록 일정한 비율로 임금이 증가한다. 결국 20세에 200만원이었던 임금은 30세에 250만원, 40세에 300만원씩 올라가서 80세에는 500만원까지 끊임없이 증가하는 비현실적인 모습을 보인다. 실제 노동시장에서의 개인의 임금은 우측의 그림과 가깝다. 연령이 증가할수록 임금은 증가하긴 하지만 증가율은 점차 감소하는 것이다.

8.3.4.1 선형 관계인 1차함수의 계수 해석

- 회귀식 :

$$Y(\check{\Phi}) = 5 * X(\partial 9) + 100$$

- X 절편 : 100
 - 연령(X)가 0일때, Y(임금)의 값은 100만원이다.
- 기울기 :

$$\frac{d}{dx}f(x) = 5$$

- 애매한 해석:
 - 임금과 연령은 정적인 관계가 있다.
 - 연령이 증가할 수록 임금이 상승한다.
- 선명한 해석:
 - 연령(X)이 1살 증가하면, Y(임금)은 5만원씩 증가한다.
 - 이밖에도 특정 연령의 예측 임금도 해석할 수 있다. 예) 40세일때 임금은 $5 * 40 + 100 = 300$ 만원이다.

8.3.4.2 비선형 관계인 2차 함수의 계수 해석

- 회귀식:

$$Y(\check{\Phi}) = -0.04 * X^2 + 5 * X + 200$$

- X 절편 : 100
 - 연령(X)가 0일때, Y(임금)의 값은 200만원이다.
- 기울기 :

$$\frac{d}{dx}f(x) = -0.04 * 2 * X + 5 = -0.08X + 5$$

- 기울기의 변화량 :

$$\frac{d}{dx}f'(x) = f''(x) = -0.08$$

- 애매한 해석:

- 연령과 임금의 관계는 정적이다(x의 계수가 양의 값이므로), 그러나 이 기울기는 점점 감소한다 (X^2 의 계수가 음의 값이므로)

- 선명한 해석 :

- 연령이 0세일때, 연령과 임금의 기울기는 5이다.
- 이 기울기는 10세에 $4.2 = -0.08 * 10 + 5$, 20세에 $3.4 = -0.08 * 20 + 5$ 로 양의 값을 갖지만, 그 크기가 점차 줄어든다.
- 연령과 임금의 기울기는 62.5세($-0.08*62.5+5=0$)에 0의 값을 갖는다. 다시 말해 62.5세에 임금은 최고값을 갖는다.
- 기울기는 62.5세 이후에 0.08씩 하락해서 음의 값을 갖는다. 예를 들어 70세에는 $-0.6(-0.08*70+5)$ 의 값을 갖는다.

8.4 회귀분석에서 더미변수 활용

8.4.1 회귀분석에 적합한 변수의 척도

초보연구자들이 자주 하는 실수 중에 하나는 회귀분석에 적합하지 않은 변수를 연구에 사용하는 것이다. 1장에서 다뤘던 것처럼 우리가 통상 사용하는 변수의 척도(scale)는 크게 네가지 이다.

- 명목척도 (categorical scale) : 숫자로 표현할 수 없다. 예) 색깔 (빨간색, 파란색, 노란색 등), 성별(남자, 여자), 통학방식(도보, 자가용, 대중교통 등)
- 서열척도 (ordinal scale) : 숫자로 표현할 수 있고, 방향이 있다 (크고, 작고). 그러나 숫자간의 간격이 동간이 아니기때문에 덧셈, 뺄셈을 할 수 없다. 예) 올림픽성적(1등, 2등, 3등), 총선투표결과 (1등, 2등, 3등)
- 등간 척도(interval scale): 숫자로 표현할 수 있고, 방향이 있으며, 숫자간의 간격이 동간이다. 따라서 덧셈, 뺄셈을 할 수 있다. 예) 리커트 척도로 측정된 자기보고점수, 시험성적 등
- 비율척도(ratio scale): 숫자로 표현할 수 있고, 방향이 있으며, 숫자간의 간격도 동간이다. 또한 절대 0점을 포함한다. 예) 몸무게, 키 등

변수의 척도가 서열척도라면 회귀분석에 포함될 수 없다. 앞서 살펴본 1차 함수

가 회귀식의 원형이라는 점을 기억해보면 너무나 당연할 것이다. 독립변수(X)가 명목척도인 다음의 예를 생각해보자. 혈액형은 A형=1, B형=2, O형=3으로 코딩하였다.

ID	X(혈액형)	Y(직무성과)
1	1	12
2	1	11
3	1	18
4	1	19
5	2	21
6	2	18.5
7	2	21.5
8	2	23.5
9	3	22.5
10	3	25

```
##
## Call:
## lm(formula = Y ~ X, data = bloodLearning)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.5000 -2.0938  0.5625  2.2188  3.5000
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   10.875      2.485   4.376  0.00236 **
## X              4.625      1.275   3.628  0.00671 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.017 on 8 degrees of freedom
## Multiple R-squared:  0.6219, Adjusted R-squared:  0.5747
## F-statistic: 13.16 on 1 and 8 DF, p-value: 0.006706
```

##	1	2	3	4	5	6	7	8	9	10
##	-3.500	-4.500	2.500	3.500	0.875	-1.625	1.375	3.375	-2.250	0.250

위의 분석결과처럼 혈액형과 같은 명목척도를 투입하더라도, 1, 2, 3과 같이 숫자로 코딩되어 있기 때문에 결과는 도출된다. 통계패키지는 이 변수가 명목척도라는 것을 알 수 없다. 따라서 그럴듯해보이지만 엉터리 분석결과가 산출되었다. 위의 결과표를 이용해 회귀식을 만들어보자.

$$\bullet Y = 10.875 + 4.625 * X(\Phi a^{\vee}) + e$$

회귀식을 만들지 않는다면, 결과표를 보고 “혈액형이 직무성가에 정적인 영향을 미친다” 같은 엉뚱한 분석을 할 수도 있다. 하지만 이제 우리는 4.625가 기울기라는 것을 안다. 다시 말해 X 가 한 단위 변화할 때 Y 가 4.625만큼 증가한다는 것이다. 하지만 명목척도인 X 의 한 단위 변화량은 어떠한 의미도 없다. 먼저 X 의 절대값이 커지는 것에 의미가 있는가? A형에서 B형, O형으로의 변화가 의미가 있는가? 또한 한 단위의 변화, 다시 말해 A형->B형, 또는 B형->O형으로의 변화가 의미가 있는가?

따라서 회귀분석에는 반드시 등간척도 이상의 변수만이 투입이 가능하다. 서열척도의 경우 방향이 있기 때문에 투입가능하다고 생각하지만, 1등과 2등, 2등과 3등의 차이가 일정하지 않기 때문에 X 한단위 변화량의 의미가 없다.

[그림삽입]- 엑스축은 혈액형, 와이축은 성과 엑스축은 등수(등간 X) 와이축은 성과 점수

8.4.2 범주형 변수가 독립변수로 투입될 때

그렇다면 회귀분석에는 범주형 변수 투입이 불가능한가? 불가능하다기 보다는 우회하는 경로가 있다. '종속변수(dependent variable, Y)'가 범주형 변수일 때는 '로지스틱 회귀분석'을 실시해야하기 때문에 이 장에서는 다루지 않는다. '독립변수(independent variables, Xs)'가 범주형 변수일 때는 반드시 더미화해야 하며, 해석 또한 달라진다.

8.4.2.1 이분형(dichotomous) 척도가 독립변수일 때

이분형 척도는 범주가 두 개인 척도를 의미한다. 대표적으로 성별(남/여), 취업/진학, 합격/불합격 등과 같은 변수가 이에 해당된다. 이분형 척도는 범주가 세 개 이상인 척도에 비해 다루기 쉬운 편이다.

이분형 척도는 범주가 두개 이므로 기준 범주는 '0', 그리고 반대의 범주는 '1'로 코딩하는 것이 원칙이다. 아래 표와 같이 성별(남/여)이 직무성과에 미치는 영향을 확인하고 싶은 데이터가 있다고 가정해보자. 여성을 기준집단(0으로 코딩)으로 두고, 남성은 비교집단(1로 코딩)하였다.

ID	X(성별)	Y(직무성과)
1	1	12
2	1	11
3	1	18
4	1	19
5	1	21
6	0	18.5
7	0	21.5
8	0	23.5
9	0	22.5
10	0	25

```
##
## Call:
## lm(formula = Y ~ X, data = genderLearning)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.20  -2.95   0.80   2.55   4.80
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   22.200      1.602   13.861 7.09e-07 ***
## X              -6.000      2.265   -2.649  0.0293 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.581 on 8 degrees of freedom
## Multiple R-squared:  0.4673, Adjusted R-squared:  0.4007
```

```
## F-statistic: 7.018 on 1 and 8 DF, p-value: 0.0293
##
## Welch Two Sample t-test
##
## data: Y by X
## t = 2.6491, df = 6.2143, p-value = 0.03683
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## 0.5038568 11.4961432
## sample estimates:
## mean in group 0 mean in group 1
## 22.2 16.2
```

회귀분석결과를 바탕으로 회귀식을 써보면 다음과 같다.

$$\hat{Y}(X) = 22.200 - 6.000 * X$$

독립변수인 성별의 회귀계수는 '-6.000'으로 부적인 영향관계를 갖고 있다. 1=남성, 0=여성으로 코딩했으므로 남성일수록 여성에 비해 직무수행 점수가 낮다고 해석할 수 있다. 좀더 선명한 해석을 하기 위해서는 독립변수 X에 집단을 직접 집어 넣어 $\hat{Y}$ 을 산출하면 된다.

남성집단은 X=1 이므로, 예측되는 직무수행 점수는 16.200이다.

$$\hat{Y}(X=1) = 22.200 - 6.000 * 1 = 16.200$$

여성집단은 X=0 이므로, 예측되는 직무수행 점수는 22.200이다.

$$\hat{Y}(X=0) = 22.200 - 6.000 * 0 = 22.200$$

다시 회귀식을 살펴보면, 기준집단(x=0)의 $\hat{Y}$ 은 회귀식의 절편과 같고, 비교집단(x=1)의 $\hat{Y}$ 은 기준집단과 회귀계수 만큼의 격차(differences)와 같다.

8.4.2.2 3집단 이상의 범주형 척도가 독립변수일 때

이분변수인 경우 한 집단은 0, 다른 집단은 1로 코딩을 할 수 있기 때문에 두 집단의 격차(difference)로 회귀분석을 실시할 수 있지만, 3개 집단부터는 불가능하다. 따라서 3개의 집단을 쌍별 비교하는 '더미코딩'을 실시해야 한다.

앞서 살펴봤던 혈액형과 직무수행과의 관계를 살펴보자. A형은 1, B형은 2, O형은 3으로 코딩되어 있다. 더미코딩의 핵심은 n 개의 집단을 ' $n-1$ '개의 변수로 재코딩하는 것이다. 더미코딩을 하기 위해서는 기준집단(reference group)을 먼저 설정해야 한다. 임의로 기준집단을 O형으로 두자. 3개의 범주는 $n-1$, 즉 2개의 더미변수를 추가로 생성해야 한다. 변수의 코딩은 아래의 표와 같다. 기준집단을 O형으로 두면, 추가되는 더미변수들은 각각 A형과 B형을 의미하게 된다.

X(혈액형)	D1(A형)	D2(B형)
A	1	0
B	0	1
O	0	0

좀더 쉬운 이해를 위해 아래에 더미코딩이 추가된 데이터 셋을 살펴보자. 변수를 추가 한다는 말은 열(column)이 추가된다는 뜻이다. 기존에 X(혈액형) 변수는 하나의 열(column)이다. 더미변수를 두개 추가하였으므로, 2개의 column이 추가로 생성되었다. 데이터를 하나 하나 살펴보자. 각 행(row)은 사람, 열(column)은 변수를 의미함을 상기하자.

- A형인 사람은 D1변수에는 1, D2변수는 0의 값을 갖는다.
- B형인 사람은 D1변수에는 0, D2변수는 1의 값을 갖는다.
- O형인 사람은 D1변수에는 0, D2변수는 0의 값을 갖는다.

이와 같이 $n-1$ 개의 더미변수를 통해 3집단을 1 또는 0의 값을 갖도록 코딩할 수 있다.

```
ID<-c(1,2,3,4,5,6,7,8,9,10)
X<-c(1, 1, 1, 1, 2, 2, 2, 2, 3, 3)
D1 <- c(1, 1, 1, 1, 0, 0, 0, 0, 0, 0)
D2 <- c(0, 0, 0, 0, 1, 1, 1, 1, 0, 0)
Y<-c(12, 11, 14, 15, 19, 20.5, 18.5, 18.5, 27, 25)
bloodLearning2 <-data.frame(ID, X, D1, D2, Y)
bloodReg2 <-lm(Y ~ D1 + D2, data=bloodLearning2)
bloodLearning2
##      ID X D1 D2      Y
## 1    1 1 1  0 12.0
## 2    2 1 1  0 11.0
```

```
## 3   3 1 1 0 14.0
## 4   4 1 1 0 15.0
## 5   5 2 0 1 19.0
## 6   6 2 0 1 20.5
## 7   7 2 0 1 18.5
## 8   8 2 0 1 18.5
## 9   9 3 0 0 27.0
## 10 10 3 0 0 25.0
summary(bloodReg2)
##
## Call:
## lm(formula = Y ~ D1 + D2, data = bloodLearning2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.0000 -0.9062 -0.3750  1.0000  2.0000
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   26.000      1.024   25.38 3.76e-08 ***
## D1            -13.000      1.254  -10.36 1.69e-05 ***
## D2             -6.875      1.254   -5.48 0.000926 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.449 on 7 degrees of freedom
## Multiple R-squared:  0.9407, Adjusted R-squared:  0.9238
## F-statistic: 55.53 on 2 and 7 DF, p-value: 5.075e-05
```

더미코딩이 완료되면, 더미변수만을 회귀식에 투입하면 된다. 이때 회귀식은 $Y = B_0 + B_1 * D_1 + B_2 + D_2 + e$ 이다. 회귀분석결과 3개의 계수가 산출되었다.

- Y절편 : 26.000
- D1의 회귀계수 : -13.000
- D2의 회귀계수 : -6.875

이 계수들을 활용하여 회귀식을 다시 써보자.

$$\hat{Y} = 26.000 - 13.000 * D1 - 6.875 * D2$$

Y절편은 D1과 D2가 모두 0일때 Y값이므로, O형의 직무수행점수이다. (O형은 D1과 D2에 모두 0으로 코딩한 집단이라는 것을 기억하자). 따라서 O형의 직무수행 점수는 26점이다. D1의 회귀 계수는 D1이 1일때와 0일때의 격차이다.

- D1이 1일때 (동시에 D2은 0) : $26.000 - 13.000 * 1 - 6.875 * 0 = 13.000$ -> A형의 직무수행점수
- D1이 0일때 (동시에 D2은 0) : $26.000 - 13.000 * 0 - 6.875 * 0 = 26.000$ -> O형의 직무수행점수

따라서 D1의 회귀계수(-13.000)를 통해, A형과 O형의 직무수행점수의 차이가 -13.000임을 알 수 있다.


마찬가지로 D2의 회귀 계수는 D2가 1일때 (B형)와 D2가 0일때 (O형)의 직무수행점수의 차이를 의미한다. 헛갈릴때는 각각의 변수에 값을 투입해보면 정확히 이해할 수 있다.

- D2이 1일때 (동시에 D1은 0) : $26.000 - 13.000 * 0 - 6.875 * 1 = 19.125$ -> B형의 직무수행점수
- D2이 0일때 (동시에 D1은 0) : $26.000 - 13.000 * 0 - 6.875 * 0 = 26.000$ -> O형의 직무수행점수

이처럼 더미변수를 투입한 회귀식에서의 회귀계수는 준거집단-비교집단의 차이 (difference)를 의미한다. 또한

```
barplot(height=datavalue, names = dataname)
```

[그래프 추가]



8.5 회귀식으로 이해하는 조절효과

8.5.1 조절효과의 개념

조절효과는 'moderation effect'라고 불리우며, Y와 X의 관계를 조절변수(M)이 변화시키는 것을 의미한다. 조절효과는 앞서 살펴본 2차 회귀식을 제대로 이해했다면 아주 손쉽게 이해할 수 있다. 2차 회귀식의 핵심은 Y와 X의 관계, 즉 기울기가 일정하지 않고 '변화'한다는 것이었다. 마찬가지로 조절효과는 어떠한 조절 변수에 의해 Y와 X의 관계, 즉 기울기(회귀계수)가 변화한다는 것을 의미한다.

산업인력개발 장면에서 조절효과분석이 필요한 사례는 쉽게 살펴볼 수 있다. 앞서 살펴본 학습시간(X)과 직무수행점수(Y)의 관계를 떠올려보자. 가장 기본적인 회귀식은 학습시간이 한 단위 증가할때, 직무수행 점수가 일정하게 증가한다는 것이다. 그러나 모든 사람이 학습시간을 늘릴수록 똑같은 속도로 직무수행시간이 늘어나지는 않는다. 예를 들어 '일 열의'라는 구인을 생각해보자. 많은 동기이론들을 통해 자신의 직무 및 일에 동기를 갖고 열의를 갖는 사람들일 수록 학습효과가 높다고 밝혀져있다. 따라서 우리는 다음과 같은 가설을 생각해볼 수 있다.

- 가설 1: 학습시간(X)이 늘어날 수록 직무수행점수(Y)는 늘어날 것이다.
- 가설 2: 일 열의(M)가 높은 사람일 수록 학습시간(X)이 직무수행점수(Y)에

미치는 정적인 영향은 증가(강화)할 것이다.

직관적으로 생각해보면, 일 열의가 높은 집단과 낮은 집단을 구분하여 회귀선을 그려보면

- 일 열의가 높은 집단은 X와 Y의 그래프가 좀더 가파를 것이다(기울기의 절대값이 크다)
- 일 열의가 낮은 집단은 X와 Y의 그래프가 좀더 완만할 것이다(기울기의 절대값이 작다)

따라서 조절효과의 핵심은 X가 Y에 미치는 영향이 M의 크기에 따라 변화한다는 점이다.

8.5.2 회귀식 만들기와 해석하기

조절효과를 분석하기 위한 기본적인 회귀식은 다음과 같다.

$$Y = B_0 + B_1 * X + B_2 * M + B_3 * X_1 * M + e \quad (8.6)$$

회귀식은 크게 네개의 파트로 구성되어 있다: (1) Y절편, (2) 독립변수 X의 회귀계수, (3) 조절변수 M의 회귀계수, (4) 독립변수 X와 조절변수 Y의 곱(interaction term)의 회귀계수. 이러한 기본 형태에서는 왜 B_3 가 조절효과를 나타내는지 이해하기가 어렵다. 따라서 이 회귀식을 (8.7)과 같이 변형해보자.

$$\begin{aligned} Y &= B_0 + B_1 * X + B_2 * M + B_3 * X * M + e \\ &= B_0 + (B_1 + B_3 * M) * X + B_2 * M \end{aligned} \quad (8.7)$$

(8.7)에서 주목해야할 부분은 X의 회귀계수인 $B_1 + B_3 * M$ 이다. X가 Y에 미치는 영향력인 회귀계수가 하나의 값으로 추정되는 것이 아니라 조절변수 M이 포함된 회귀식의 형태를 띈다. 따라서 조절효과분석은 regression-in-regression, 다시 말해 회귀분석 안에 또하나의 회귀식이 있는 형태를 띈다.

$B_1 + B_3 * M$ 는 X가 Y에 미치는 회귀계수를 종속변수로 하고, M을 독립변수로 하는 또하나의 회귀식인 것이다. 앞서 언급한 가설 2: 일 열의(M)가 높은 사람일 수록 학습시간(X)이 직무수행점수(Y)에 미치는 정적인 영향은 증가(강화)할 것이다가 바로 이 회귀식을 의미한다. 가설을 찬찬히 살펴보면 영향을

받는 쪽(종속변수)은 X와 Y의 기울기이고, 영향을 주는 쪽(독립변수)는 일 열의 (M)이다.

8.5.3 분석결과 해석 예제

실제 데이터를 활용하여 조절효과를 분석해보자. 이번에는 20명의 사람의 학습시간 (X), 일 열의(M), 직무수행점수(Y)의 데이터를 수집했다. 우리가 수집한 데이터는 행이 20개(사례수), 열이 4개 (ID를 포함하여 변수 4개)의 20 * 4 의 매트릭스 형태이다.

조절효과의 기본 회귀식을 생각해보면 변수 하나가 더 필요하다. $X * M$, 즉 독립변수와 조절변수의 상호작용항이다. 여러가지 방법이 있지만 통상적으로는 데이터 프레임에 이 상호작용항을 새로운 변수로 추가한다. R에서는 기존 변수(old variable)을 연산하여 새로운 변수(new variable) 로 간단히 추가할 수 있다. 아래 R 코드를 보면 `moderLearningXM <- -moderLearningX * moderLearning$M` 의 구분이 X과 M을 곱하여 XM을 만들고 있다. 최종적으로 만들어진 데이터프레임은 변수 열이 추가되어 20*5의 행렬이다.

```
ID<-c(1:20)
X<-c(1, 0.5, 2, 3, 3, 3.5, 4, 4, 4.5, 5, 1.2, 0.7, 2.2, 3.3, 3.1, 3.7, 4.1, 3.9, 4.3, 5)
M<-c(2, 1, 1.2, 1, 1, 1.1, 1, 1.5, 1, 2, 5, 7, 7, 6, 7, 7, 6, 7, 4, 5)
Y<-c(12, 11, 18, 19, 21, 18.5, 21.5, 23.5, 22.5, 25, 12, 11, 18, 19, 28, 29, 26, 27.5, 27.5, 28)
moderLearning <-data.frame(ID, X1, M, Y)
moderLearning$XM <-moderLearning$X * moderLearning$M
moderLearning
```

##	ID	X1	M	Y	XM
## 1	1	1.0	2.0	12.0	2.00
## 2	2	0.5	1.0	11.0	0.50
## 3	3	2.0	1.2	18.0	2.40
## 4	4	3.0	1.0	19.0	3.00
## 5	5	3.0	1.0	21.0	3.00
## 6	6	3.5	1.1	18.5	3.85
## 7	7	4.0	1.0	21.5	4.00
## 8	8	4.0	1.5	23.5	6.00
## 9	9	4.5	1.0	22.5	4.50
## 10	10	5.0	2.0	25.0	10.00

```
## 11 11 1.0 5.0 12.0 5.00
## 12 12 0.5 7.0 11.0 3.50
## 13 13 2.0 7.0 18.0 14.00
## 14 14 3.0 6.0 19.0 18.00
## 15 15 3.0 7.0 28.0 21.00
## 16 16 3.5 7.0 29.0 24.50
## 17 17 4.0 6.0 26.0 24.00
## 18 18 4.0 7.0 27.5 28.00
## 19 19 4.5 4.0 27.5 18.00
## 20 20 5.0 5.0 30.0 25.00
moderReg <-lm(Y ~ X+M+ XM, data=moderLearning)
summary(moderReg)
##
## Call:
## lm(formula = Y ~ X + M + XM, data = moderLearning)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.2673 -0.9477 -0.4419  1.0102  4.4372
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.8869     1.9740   5.515 4.7e-05 ***
## X              2.3572     0.6012   3.921 0.00122 **
## M             -0.4978     0.4213  -1.182 0.25457
## XM              0.4216     0.1357   3.106 0.00679 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.068 on 16 degrees of freedom
## Multiple R-squared:  0.9053, Adjusted R-squared:  0.8876
## F-statistic:    51 on 3 and 16 DF,  p-value: 2.062e-08
```

분석결과 X(학습시간)과 XM(학습시간 * 일열의)가 Y(직무수행점수)에 유의미한


영향을 미치는 것으로 나타났다. 구체적으로 해석하기 위해서 추정된 회귀계수를 활용하여 회귀식을 구성해보자.

$$\hat{Y} = 10.8737 + 2.3928 * X - 0.5915 * M + 0.4309 * XM$$

$$\hat{Y} = 10.8737 + (2.3928 + 0.4309 * M) * X - 0.5915 * M$$

* Y 절편 : X(학습시간)과 M(일열의)가 0인 경우 Y(직무수행점수)가 10.8737 이다.

- M의 회귀계수 : X(학습시간)이 0일때, M(직무 열의)가 한 단위 증가할때 Y(직무수행점수)는 0.5915만큼 감소한다. 다만 통계적으로 유의하지 않다 (이는 M의 회귀계수 $H_1: B_3$ is not equal to zero 가 기각되었음을 의미한다)
- X의 회귀계수 : $2.3928 + 0.4309 * M$
 - X의 회귀계수는 M에 따라 변화한다.
 - M=0일때 X가 한단위 변화할때 Y는 2.3928만큼 커진다 ($2.3928 + 0.4309 * 0$)
 - M이 한단위 커질 수록 X의 Y에 대한 기울기는 0.4309 만큼 커진다.
 - 예를 들어 M=1일때 X의 기울기는 $2.3928 + 0.4309$ (purple), M=2(blue)일때 X의 기울기는 $2.3928 + 0.4309 * 2$ 이다.
 - 거꾸로 X가 Y에 미치는 영향이 0인 점도 찾을 수 있다. $2.3928 + 0.4309 * M = 0$ 을 풀면, $M = -5.553$ 이다. 이는 M이 -5.553인 집단은 X와 Y의 관계가 0이라는 것을 뜻한다.



8.6 회귀식으로 이해하는 매개효과

8.6.1 매개효과의 개념

8.6.2 회귀식 만들기과 해석하기

8.6.3 분석결과 해석 예제

'가설 1: 학습시간(X)이 늘어날 수록 직무수행점수(Y)는 늘어날 것이다'을 회귀식으로 써보면 다음 (8.7)과 같다. 이제는 $y=a+bx$ 의 회귀식이 눈에 익었을 것이라 생각한다. 이제는 회귀식을 쓸때 하나의 규칙을 더하도록 하겠다. y 절편은 항상 B_0 으로 1번째 독립변수(X_1)의 회귀계수는 B_1 , 2번째 독립변수(X_2)의 회귀계수는 B_2 , n번째 독립변수(X_n)의 회귀계수는 B_n 으로 작성하도록 한다.

제 9 장

회귀분석 심화 및 기본가정

- simple regression analysis
 - 단순회귀분석의 개념
 - 최소자승법을 이용한 회귀계수 도출
 - 회귀분석의 설명력 및 적합도 분석
 - 단순회귀분석 r 실습
- multiple regression analysis
 - 다중회귀분석의 개념
 - 다중회귀분석의 회귀계수 도출
 - 더미변수를 활용한 다중회귀분석과 해석
 - 다중회귀분석 r 실습
- 회귀분석의 기본가정
 - 선형성
 - 정규성
 - 등분산성
 - 독립성
 - 다중공선성
 - 극단치 탐지
 - 회귀분석 기본가정 r 실습

9.1 simple regression analysis

9.1.1 단순회귀분석의 개념

9.1.2 최소자승법을 활용한 회귀계수 도출

how to find appropriate intercept(a) and slope(b)?

$$y_i = a + bx_i + e_i$$

$$\hat{y}_i = a + bx_i$$

$$e_i = y - \hat{y}$$

위의 잔차를 최소화하기 위해서는 잔차의 제곱합을 최소화해야한다.

$$\text{minimize } \sum_{i=1}^n e_i^2$$

$$\sum (y_i - \hat{y}_i)^2 = \sum (y_i - a - bx_i)^2$$

minimize를 위해 위의 함수를 각각 a와 b로 미분하여 0이 되는 값을 구한다.

a로 미분하면 다음과 같다.

$$\frac{dF}{da} = -2 \sum (y_i - a - bx_i) = 0$$

$$\sum y_i - an - b \sum x_i = 0$$

n으로 전체를 나눠주면

$$\bar{y} - a - b\bar{x} = 0$$

$$a = \bar{y} - b\bar{x}$$

따라서 위의 식에서 회귀식은 $\bar{x}$ 와 $\bar{y}$ 를 지난다는 것을 알 수 있다.

b로 미분하면 다음과 같다.

$$\frac{df}{db} = -2 \sum (y_i - a - bx_i)x_i = 0$$

$y = (f(x))^n$ 를 미분하면 $y' = n(f(x))^{n-1} \cdot f'(x)$ 을 기억!

$$\sum x_i(y_i - a - bx_i) = 0$$

$$\sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0$$

$$\sum x_i y_i - (\bar{y} - b\bar{x}) \sum x_i - b \sum x_i^2 = 0$$

$$\sum x_i y_i - \bar{y} \sum x_i = b \sum x_i^2 - b\bar{x} \sum x_i$$

좌변을 먼저 정리하면 $\sum x_i = n \cdot \bar{x}$ 이므로

$$\sum x_i y_i - n \bar{x} \bar{y} = b \sum x_i^2 - b \bar{x} \sum x_i$$

이를 n으로 먼저 나누면

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - \frac{(\sum x_i)^2}{n^2} \right)$$

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - \left(\frac{\sum x_i}{n} \right)^2 \right)$$

정리를 위해 $\text{var}(x)$ 에 대한 새로운 식을 가져온다.

$$\begin{aligned} \text{var}(x) &= \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum (x_i)^2 - 2\bar{x} \sum x_i + n(\bar{x})^2}{n} = \frac{\sum (x_i)^2}{n} - 2\bar{x} \frac{\sum x_i}{n} + (\bar{x})^2 = \\ &= \frac{\sum (x_i)^2}{n} - (\bar{x})^2 \end{aligned}$$

이식으로 우변을 정리해보면

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - (\bar{x})^2 \right) = b \cdot (SD_x)^2$$

좌변을 정리하기 위해서는 $\text{cov}(x, y)$ 에 대한 식을 다음과 같이 변형한다.

$$\begin{aligned} \text{Cov}(X, Y) &= E((X - EX)(Y - EY)) = E[XY - X(EY) - (EX)Y + \\ &+ (EX)(EY)] = E[XY] - (EX)(EY) - (EX)(EY) + (EX)(EY) = \\ &= E[XY] - (EX)(EY) \end{aligned}$$

$$\text{Cov}(X, Y) = \left(\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} \right)$$

이를 활용하여 좌변을 정리하면 다음과 같다.

$$\text{Cov}(x, y) = b \cdot (SD_x)^2$$

$$b = \frac{\text{Cov}(x, y)}{(SD_x)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \text{Cor}(x, y) \cdot \frac{SD_y}{SD_x}$$

만일 x 와 y 를 표준화한다면 $\bar{x}$ 와 $\bar{y}$ 는 0, SD_x 와 SD_y 는 1이다.

$$a = \bar{y} - b\bar{x} = 0$$

$$\therefore \hat{y} = r \cdot x$$

9.2 multiple regression analysis

9.2.1 다중회귀분석의 회귀계수 도출

9.2.1.1 matrix of variance and covariane

다음의 두개의 변인(X_1, X_2)가 각각 3개의 관측치를 갖고 있다고 생각해보자

X1	X2
1	1
2	4
2	7
mean of X1=2	mean of X2=4

$$X_d = \begin{matrix} X \\ \text{Deviationscores} \end{matrix} = \begin{bmatrix} 1 & 1 \\ 3 & 4 \\ 2 & 7 \end{bmatrix} - \begin{bmatrix} \bar{X} \\ 2 & 4 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} -1 & -3 \\ 1 & 0 \\ 0 & 3 \end{bmatrix}$$

$$X_d' = \begin{matrix} \text{transpose of } X_d \end{matrix} = \begin{bmatrix} -1 & 1 & 0 \\ -3 & 0 & 3 \end{bmatrix}$$

$$SSCP = \begin{matrix} \text{Sums of squares and crossproducts} \end{matrix} = \begin{matrix} X_d' \\ \begin{bmatrix} -1 & -1 & 0 \\ -3 & 0 & 3 \end{bmatrix} \end{matrix} \times \begin{matrix} X_d \\ \begin{bmatrix} -1 & -3 \\ 1 & 0 \\ 0 & 3 \end{bmatrix} \end{matrix} = \begin{bmatrix} SS_{11} & SS_{12} \\ SS_{21} & SS_{22} \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 3 & 18 \end{bmatrix}$$

because

$$SS_{11} = (-1)^2 + 1^2 + 0^2 = 2$$

$$SS_{22} = (-3)^2 + 0^2 + 3^2 = 18$$

$$SS_{12} = SS_{21} = (-1)(-3) + (1)(0) + (0)(3) = 3$$

$$S = \frac{SSCP}{n-1} = \frac{1}{2} \begin{bmatrix} 2 & 3 \\ 3 & 18 \end{bmatrix} = \begin{bmatrix} 1 & 1.5 \\ 1.5 & 9 \end{bmatrix} = \begin{bmatrix} \text{variance of } X_1 & \text{covariance} \\ \text{covariance} & \text{variance of } X_2 \end{bmatrix}$$

이처럼 X_d 와 X_d^T 의 곱은 X_1 과 X_n 의 분산과 공분산의 행렬로 표현됨을 알 수 있다.

9.2.1.2 multiple regression의 회귀계수(beta) 계산

다중회귀분석은 2개 이상의 변수가 동시에 계산되어야 하기 때문에 회귀식이 행렬로 표현된다. 예를 들어 우리가 아래와 같은 1개의 종속변수, 2개의 독립변수를 가지고 회귀식을 다음과 같이 구성했다고 생각해보자.

y	X1	X2
4	1	3
5	4	4
6	7	8
8	8	9

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + e_i$$

각 데이터를 위의 회귀식에 넣어보면 총 4개의 식이 생긴다

$$y_1 = 4 = 1 \cdot \beta_0 + 1 \cdot \beta_1 + 3 \cdot \beta_2 + e_1$$

$$y_2 = 5 = 1 \cdot \beta_0 + 4 \cdot \beta_1 + 4 \cdot \beta_2 + e_2$$

$$y_3 = 6 = 1 \cdot \beta_0 + 7 \cdot \beta_1 + 8 \cdot \beta_2 + e_3$$

$$y_4 = 8 = 1 \cdot \beta_0 + 8 \cdot \beta_1 + 9 \cdot \beta_2 + e_4$$

이는 다음과 같은 행렬로 표현할 수 있다.

$$y = \begin{bmatrix} 4 \\ 5 \\ 6 \\ 8 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 3 \\ 1 & 4 & 4 \\ 1 & 7 & 8 \\ 1 & 8 & 9 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix}$$

$$y = X\beta + e$$

회귀계수인 β 행렬의 해를 찾기 위해서는 단순회귀와 마찬가지로 잔차(e)의 제곱합을 최소화하는 β 행렬을 찾아야 한다.

잔차제곱합은 다음과 같이 transpose 행렬을 곱해줌으로서 간단히 만들 수 있다

$$e^T e = (y - X\beta)^T (y - X\beta)$$

$$\text{note that } e^T e = \begin{bmatrix} e_1 & e_2 & e_3 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix} = e_1^2 + e_2^2 + e_3^2$$

잔차제곱합은 2차 함수이기 때문에 최소값은 β 로 미분한 값이 0인 지점을 찾으면 된다. (convex 형태의 2차함수를 생각해 보면 기울기가 0인 지점이 y 의 최소값임을 기억하자!)

잔차제곱합을 미분하기 위해서는 아래의 두개의 공식을 이해해야 한다.

$$\frac{\partial a^T \beta}{\partial \beta} = a$$

$$\frac{\partial \beta^T A \beta}{\partial \beta} = (A + A^T) \beta = 2A\beta (\text{when } A \text{ is symmetric})$$

잔차 제곱합을 β 로 미분한 값이 0일때의 β 값을 찾아보면 다음과 같다.

$$\begin{aligned} \frac{\partial L}{\partial \beta} &= \frac{\partial}{\partial \beta} (y - X\beta)^T (y - X\beta) = \frac{\partial}{\partial \beta} (y^T y - y^T X\beta - (X\beta)^T y + (X\beta)^T X\beta) = \\ &= \frac{\partial}{\partial \beta} (y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta) = 0 - X^T y - X^T y + 2X^T X\beta = 0 \end{aligned}$$

좌변과 우변으로 정리하면

$$X^T X\beta = X^T y$$

$$\beta = (X^T X)^{-1} X^T y$$

제 10 장

regression

- simple regression analysis
 - 단순회귀분석의 개념
 - 최소자승법을 이용한 회귀계수 도출
 - 회귀분석의 설명력 및 적합도 분석
 - 단순회귀분석 r 실습
- multiple regression analysis
 - 다중회귀분석의 개념
 - 다중회귀분석의 회귀계수 도출
 - 더미변수를 활용한 다중회귀분석과 해석
 - 다중회귀분석 r 실습
- 회귀분석의 기본가정
 - 선형성
 - 정규성
 - 등분산성
 - 독립성
 - 다중공선성
 - 극단치 탐지
 - 회귀분석 기본가정 r 실습

10.1 simple regression anlysis

10.1.1 단순회귀분석의 개념

10.1.2 최소자승법을 활용한 회귀계수 도출

how to find appropriate intercept(a) and slope(b)?

$$y_i = a + bx_i + e_i$$

$$\hat{y}_i = a + bx_i$$

$$e_i = y - \hat{y}$$

위의 잔차를 최소화하기 위해서는 잔차의 제곱합을 최소화해야한다.

$$\text{minimize } \sum_{i=1}^n e_i^2$$

$$\sum (y_i - \hat{y}_i)^2 = \sum (y_i - a - bx_i)^2$$

minimize를 위해 위의 함수를 각각 a와 b로 미분하여 0이 되는 값을 구한다.

a로 미분하면 다음과 같다.

$$\frac{dF}{da} = -2 \sum (y_i - a - bx_i) = 0$$

$$\sum y_i - an - b \sum x_i = 0$$

n으로 전체를 나눠주면

$$\bar{y} - a - b\bar{x} = 0$$

$$a = \bar{y} - b\bar{x}$$

따라서 위의 식에서 회귀식은 $\bar{x}$ 와 $\bar{y}$ 를 지난다는 것을 알 수 있다.

b로 미분하면 다음과 같다.

$$\frac{df}{db} = -2 \sum (y_i - a - bx_i)x_i = 0$$

$y = (f(x))^n$ 를 미분하면 $y' = n(f(x))^{n-1} \cdot f'(x)$ 을 기억!

$$\sum x_i(y_i - a - bx_i) = 0$$

$$\sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0$$

$$\sum x_i y_i - (\bar{y} - b\bar{x}) \sum x_i - b \sum x_i^2 = 0$$

$$\sum x_i y_i - \bar{y} \sum x_i = b \sum x_i^2 - b\bar{x} \sum x_i$$

좌변을 먼저 정리하면 $\sum x_i = n \cdot \bar{x}$ 이므로

$$\sum x_i y_i - n \bar{x} \bar{y} = b \sum x_i^2 - b \bar{x} \sum x_i$$

이를 n으로 먼저 나누면

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - \frac{(\sum x_i)^2}{n^2} \right)$$

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - \left(\frac{\sum x_i}{n} \right)^2 \right)$$

정리를 위해 $\text{var}(x)$ 에 대한 새로운 식을 가져온다.

$$\begin{aligned} \text{var}(x) &= \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum (x_i)^2 - 2\bar{x} \sum x_i + n(\bar{x})^2}{n} = \frac{\sum (x_i)^2}{n} - 2\bar{x} \frac{\sum x_i}{n} + (\bar{x})^2 = \\ &= \frac{\sum (x_i)^2}{n} - (\bar{x})^2 \end{aligned}$$

이식으로 우변을 정리해보면

$$\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} = b \left(\frac{\sum x_i^2}{n} - (\bar{x})^2 \right) = b \cdot (SD_x)^2$$

좌변을 정리하기 위해서는 $\text{cov}(x, y)$ 에 대한 식을 다음과 같이 변형한다.

$$\begin{aligned} \text{Cov}(X, Y) &= E((X - EX)(Y - EY)) = E[XY - X(EY) - (EX)Y + \\ &+ (EX)(EY)] = E[XY] - (EX)(EY) - (EX)(EY) + (EX)(EY) = \\ &= E[XY] - (EX)(EY) \end{aligned}$$

$$\text{Cov}(X, Y) = \left(\frac{\sum x_i y_i}{n} - \bar{x} \bar{y} \right)$$

이를 활용하여 좌변을 정리하면 다음과 같다.

$$\text{Cov}(x, y) = b \cdot (SD_x)^2$$

$$b = \frac{\text{Cov}(x, y)}{(SD_x)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \text{Cor}(x, y) \cdot \frac{SD_y}{SD_x}$$

만일 x 와 y 를 표준화한다면 $\bar{x}$ 와 $\bar{y}$ 는 0, SD_x 와 SD_y 는 1이다.

$$a = \bar{y} - b\bar{x} = 0$$

$$\therefore \hat{y} = r \cdot x$$

10.2 multiple regression analysis

10.2.1 다중회귀분석의 회귀계수 도출

10.2.1.1 matrix of variance and covariane

다음의 두개의 변인(X_1, X_2)가 각각 3개의 관측치를 갖고 있다고 생각해보자

X1	X2
1	1
2	4
2	7
mean of X1=2	mean of X2=4

$$X_d = \begin{matrix} X \\ \text{Deviation scores} \end{matrix} = \begin{bmatrix} 1 & 1 \\ 3 & 4 \\ 2 & 7 \end{bmatrix} - \begin{bmatrix} \bar{X} \\ 2 & 4 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} -1 & -3 \\ 1 & 0 \\ 0 & 3 \end{bmatrix}$$

$$X_d' = \begin{matrix} X_d' \\ \text{transpose of } X_d \end{matrix} = \begin{bmatrix} -1 & 1 & 0 \\ -3 & 0 & 3 \end{bmatrix}$$

$$SSCP = \begin{matrix} SSCP \\ \text{Sums of squares and crossproducts} \end{matrix} = \begin{matrix} X_d' \\ \begin{bmatrix} -1 & -1 & 0 \\ -3 & 0 & 3 \end{bmatrix} \end{matrix} \times \begin{matrix} X_d \\ \begin{bmatrix} -1 & -3 \\ 1 & 0 \\ 0 & 3 \end{bmatrix} \end{matrix} = \begin{bmatrix} SS_{11} & SS_{12} \\ SS_{21} & SS_{22} \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 3 & 18 \end{bmatrix}$$

because

$$SS_{11} = (-1)^2 + 1^2 + 0^2 = 2$$

$$SS_{22} = (-3)^2 + 0^2 + 3^2 = 18$$

$$SS_{12} = SS_{21} = (-1)(-3) + (1)(0) + (0)(3) = 3$$

$$S = \frac{SSCP}{n-1} = \frac{1}{2} \begin{bmatrix} 2 & 3 \\ 3 & 18 \end{bmatrix} = \begin{bmatrix} 1 & 1.5 \\ 1.5 & 9 \end{bmatrix} = \begin{bmatrix} \text{variance of } X_1 & \text{covariance} \\ \text{covariance} & \text{variance of } X_2 \end{bmatrix}$$

이처럼 X_d 와 X_d^T 의 곱은 X_1 과 X_n 의 분산과 공분산의 행렬로 표현됨을 알 수 있다.

10.2.1.2 multiple regression의 회귀계수(beta) 계산

다중회귀분석은 2개 이상의 변수가 동시에 계산되어야 하기 때문에 회귀식이 행렬로 표현된다. 예를 들어 우리가 아래와 같은 1개의 종속변수, 2개의 독립변수를 가지고 회귀식을 다음과 같이 구성했다고 생각해보자.

y	X1	X2
4	1	3
5	4	4
6	7	8
8	8	9

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + e_i$$

각 데이터를 위의 회귀식에 넣어보면 총 4개의 식이 생긴다

$$y_1 = 4 = 1 \cdot \beta_0 + 1 \cdot \beta_1 + 3 \cdot \beta_2 + e_1$$

$$y_2 = 5 = 1 \cdot \beta_0 + 4 \cdot \beta_1 + 4 \cdot \beta_2 + e_2$$

$$y_3 = 6 = 1 \cdot \beta_0 + 7 \cdot \beta_1 + 8 \cdot \beta_2 + e_3$$

$$y_4 = 8 = 1 \cdot \beta_0 + 8 \cdot \beta_1 + 9 \cdot \beta_2 + e_4$$

이는 다음과 같은 행렬로 표현할 수 있다.

$$y = \begin{bmatrix} 4 \\ 5 \\ 6 \\ 8 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 3 \\ 1 & 4 & 4 \\ 1 & 7 & 8 \\ 1 & 8 & 9 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix}$$

$$y = X\beta + e$$

회귀계수인 β 행렬의 해를 찾기 위해서는 단순회귀와 마찬가지로 잔차(e)의 제곱합을 최소화하는 β 행렬을 찾아야 한다.

잔차제곱합은 다음과 같이 transpose 행렬을 곱해줌으로서 간단히 만들 수 있다

$$e^T e = (y - X\beta)^T (y - X\beta)$$

$$\text{note that } e^T e = \begin{bmatrix} e_1 & e_2 & e_3 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix} = e_1^2 + e_2^2 + e_3^2$$

잔차제곱합은 2차 함수이기 때문에 최소값은 β 로 미분한 값이 0인 지점을 찾으면 된다. (convex 형태의 2차함수를 생각해 보면 기울기가 0인 지점이 y 의 최소값임을 기억하자!)

잔차제곱합을 미분하기 위해서는 아래의 두개의 공식을 이해해야 한다.

$$\frac{\partial a^T \beta}{\partial \beta} = a$$

$$\frac{\partial \beta^T A \beta}{\partial \beta} = (A + A^T) \beta = 2A\beta (\text{when } A \text{ is symmetric})$$

잔차 제곱합을 β 로 미분한 값이 0일때의 β 값을 찾아보면 다음과 같다.

$$\begin{aligned} \frac{\partial L}{\partial \beta} &= \frac{\partial}{\partial \beta} (y - X\beta)^T (y - X\beta) = \frac{\partial}{\partial \beta} (y^T y - y^T X\beta - (X\beta)^T y + (X\beta)^T X\beta) = \\ &= \frac{\partial}{\partial \beta} (y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta) = 0 - X^T y - X^T y + 2X^T X\beta = 0 \end{aligned}$$

좌변과 우변으로 정리하면

$$X^T X\beta = X^T y$$

$$\beta = (X^T X)^{-1} X^T y$$